

Universidad Nacional del Este.
Facultad Politécnica.



**Sistema web para identificar
patrones de motricidad
relacionados con TEA,
mediante arquitectura
CNN-LSTM**

**Bella Luz Benítez González.
Martin Escobar Azcona.**

Año 2026.

**Universidad Nacional del Este.
Facultad Politécnica.**

**Carrera Ingeniería de Sistemas.
Cátedra Trabajo Final de Grado 2.**

**Sistema web para identificar
patrones de motricidad
relacionados con TEA,
mediante arquitectura CNN
LSTM.**

Por: Bella Luz Benítez González y Martin Escobar Azcona.

Profesor Orientador: Ing. Katia Andrea Ayala.

Trabajo final de grado presentado a la Facultad Politécnica de la Universidad Nacional del Este como parte de los requisitos para optar al título Ingeniero de sistemas.

Ciudad del Este, Alto Paraná. Paraguay.

2026

FICHA CATALOGRÁFICA
BIBLIOTECA DE LA FACULTAD POLITÉCNICA
DE LA UNIVERSIDAD NACIONAL DEL ESTE

Benítez González, Bella

Luz, 2001.

Escobar Azcona, Martin

2001.

Sistema web para identificar patrones de motricidad relacionados con TEA, mediante arquitectura CNN LSTM.

Orientador: Ing. Katia Andrea Ayala Díaz.

Ciudad del Este, Alto Paraná. Año: 2026.

Páginas:

Área de estudio: Aprendizaje Profundo y Visión por Computadora.

Carrera: Ingeniería de Sistemas.

Titulación: Ingeniero de Sistemas.

Trabajo Final de Grado. Universidad Nacional del Este,

Facultad Politécnica.

Descriptores: 1. Trastorno del espectro autista (TEA), 2. Patrones de motricidad, 3. Arquitectura CNN-LSTM.

Web system for identifying motor patterns related to ASD using CNN-LSTM architecture.

Key words: 1. Autism spectrum disorder (ASD), 2. Motor patterns
3. CNN-LSTM architecture.

Yo, <nombre del Profesor Orientador>, documento de identidad No. <No. de documento de identidad del Profesor Orientador>, Profesor Orientador del TFG titulado “<título del TFG>”, del Alumno <nombre del Alumno>, documento de identidad No. <No. de documento de identidad del Alumno>, de la carrera <nombre de la carrera> de la Facultad Politécnica de la Universidad Nacional del Este; certifico que el mencionado Trabajo Final de Grado ha sido realizado por dicho Alumno, de lo cual doy fe y en mi opinión reúne las condiciones para su presentación y defensa ante la Mesa Examinadora designada por la institución.

<fecha>

<nombre del Profesor Orientador>

Nosotros, los miembros de la Mesa Examinadora del Trabajo Final de Grado titulado “<título del TFG>”, de la carrera <nombre de la carrera> de la Facultad Politécnica de la Universidad Nacional del Este, hacemos constar que el citado trabajo ha sido evaluado en fondo y forma por esta Mesa, la que por _____ ha resuelto asignar la calificación _____

Ciudad del Este, ____ de _____ de 2014

Profesor _____
Presidente de la Mesa Examinadora

Profesor _____

Miembro de la Mesa Examinadora

Profesor _____

Miembro de la Mesa Examinadora

*Escribir aquí la dedicatoria.
Su extensión no debería exceder de una página.*

<Escribir aquí los agradecimientos.>
<Su extensión no debería exceder de una página.>

<Escribir aquí el epígrafe (frase u oración favorita).>
<Su extensión no debería exceder de una página.>

Resumen

...

Descriptores: 1. <descriptor1>, 2. <descriptor2>, 3. <descriptor3>.

Abstract

...

Key words: 1. <keyword1>, 2. <keyword2>, 3. <keyword3>.

Índice general

Resumen	IX
Abstract	X
Índice de figuras	XIV
Índice de tablas	XV
Acrónimos y símbolos	XV
1. Introducción	1
1.1. Motivación	2
1.2. Definición del problema	2
1.3. Objetivos	4
1.3.1. Objetivo General	4
1.3.2. Objetivos Específicos	4
1.4. Hipótesis	5
1.5. Justificación	5
1.6. Delimitación del alcance del trabajo	6
1.7. Descripción de los contenidos por capítulo	8
2. Conceptos fundamentales, teorías y antecedentes	10
2.1. Trastorno del espectro autista	10
2.2. El Contexto de la Salud Pediátrica en Paraguay	13
2.3. Inteligencia Artificial	14
2.3.1. Definición y fundamentos	14
2.3.2. Ramas de la IA aplicadas a la ingeniería	14
2.4. Aprendizaje automático	14
2.4.1. Definición y fundamentos	14
2.4.2. Aprendizaje supervisado	15
2.4.3. Aplicación en diagnóstico clínico	15
2.5. Visión artificial	16

2.5.1.	Definición y evolución	16
2.5.2.	Aplicación en análisis de comportamiento	16
2.6.	Arquitectura Híbrida CNN-LSTM para Reconocimiento de Patrones	17
2.6.1.	Fundamentos de la Combinación Espacio-Temporal	17
2.6.2.	Extracción de Características con CNN (Capa Espacial)	17
2.6.3.	Procesamiento de Secuencias con LSTM (Capa Temporal)	17
2.6.4.	Flujo de Datos y Clasificación de Patrones de motricidad	18
2.7.	Diseño web	18
2.7.1.	Interfaz de Usuario y Arquitectura de Integración Web	18
2.7.2.	Arquitectura del Lado del Cliente (Frontend)	18
2.7.3.	Comunicación y Servicios de Red (Backend)	19
2.7.4.	Gestión de Seguridad y Privacidad de Datos	20
2.7.5.	Visualización de Resultados y Diseño de Interacción	20
3.	Tecnologías utilizadas	22
3.1.	Componentes de Hardware	22
3.1.1.	Tarjeta gráfica: NVIDIA GeForce RTX 4070	22
3.1.2.	Procesador: AMD Ryzen 7 7800X3D	24
3.2.	Componentes de Software	24
3.2.1.	Arquitecturas para la extracción de características	24
3.2.1.1.	CNN-LSTM	25
3.2.1.2.	ResNet50	25
3.2.1.3.	MobileNetV2	26
3.2.1.4.	Vision Transformer (ViT)	26
3.2.1.5.	Criterios de evaluación	27
3.3.	Tecnologías del Frontend	29
3.3.1.	Next.js	29
3.3.2.	React	29
3.3.3.	TypeScript	29
3.3.4.	Tailwind CSS	29
3.3.5.	Recharts	30
3.3.6.	Axios	30
3.4.	Tecnologías del Backend	30
3.4.1.	FastAPI	30
3.4.2.	Uvicorn	31
3.4.3.	Pydantic	31
3.4.4.	python-multipart	31
3.4.5.	TensorFlow / Keras (motor de inferencia)	31
3.4.6.	OpenCV (preprocesamiento en el backend)	32

3.4.7. python-jose	32
3.5. Servicios en la Nube	32
3.5.1. Google Drive	32
3.5.2. Firebase Firestore	32
3.6. Herramientas de Desarrollo	33
3.6.1. Entorno de cómputo: Google Colaboratory	33
4. Método	35
4.1. Tipo de investigación	36
4.2. Alcance de la investigación	36
4.3. Especificaciones de diseño y arquitectura del sistema	36
4.4. Obtención de datos	36
4.4.1. Delimitación del estudio de los datos	36
4.4.2. Selección de videos y fuentes	36
4.4.3. Extracción de fotogramas por ventana de conducta	36
4.5. Preprocesamiento	36
4.5.1. Normalización de imágenes	36
4.5.2. Generación de secuencias de video	36
4.6. Diseño y entrenamiento del modelo	36
4.6.1. Arquitectura CNN (capa espacial)	36
4.6.2. Arquitectura LSTM (capa temporal)	36
4.6.3. Integración del modelo CNN-LSTM	36
4.6.4. Hiperparámetros de entrenamiento y ajuste	36
4.7. Evaluación del modelo	36
4.8. Desarrollo e integración de la aplicación web	36
4.9. Diseño de pruebas	36
5. Resultados	37
5.1. Resultados del entrenamiento del modelo CNN-LSTM	37
5.2. Resultados de la evaluación del modelo	37
5.3. Resultados de las pruebas del sistema web	37
6. Discusión	38
6.1. Logros alcanzados	38
6.2. Solución del problema de investigación	38
6.3. Sugerencias para futuras investigaciones	38
Glosario	40
Anexos	40

Referencias bibliográficas

41

Índice de figuras

3.1. Tarjeta gráfica NVIDIA GeForce RTX 4070.	23
---	----

Índice de Tablas

2.1. Signos de alarma de alteración del desarrollo [1]	12
3.1. Comparativa de stacks de frontend y backend	28

Capítulo 1

Introducción

El trastorno del espectro autista (TEA) es una condición del neurodesarrollo que puede manifestarse desde las primeras etapas de la vida y presentar características que varían entre cada individuo. Entre sus posibles manifestaciones se encuentran determinados patrones de motricidad y movimientos repetitivos, los cuales pueden ser observados durante diferentes actividades y situaciones.

La identificación de estas manifestaciones forma parte de los procesos de evaluación del TEA y requiere la participación de profesionales especializados. La detección oportuna puede facilitar el acceso temprano a evaluaciones, orientaciones y apoyos adecuados, aspectos que pueden favorecer el desarrollo y bienestar del niño. En este sentido, el uso de herramientas que contribuyan al reconocimiento de patrones observables puede representar un apoyo dentro de estos procesos.

En este contexto, el presente Trabajo Final de Grado propone el desarrollo de un sistema web orientado a la identificación de patrones de motricidad relacionados con el TEA mediante el análisis de secuencias de video. El sistema considera tres patrones de interés: el aleteo de manos, el balanceo corporal y los movimientos repetitivos de cabeza. Para ello, se plantea el empleo de una arquitectura CNN-LSTM, capaz de extraer características de los fotogramas y considerar su evolución a lo largo de una secuencia.

La propuesta se plantea como una herramienta de apoyo a los procesos de evaluación, sin sustituir la valoración de profesionales especializados ni emitir un diagnóstico clínico definitivo. A través de este desarrollo se busca explorar el potencial de las técnicas de aprendizaje profundo para contribuir a la identificación de manifestaciones observables asociadas al TEA y favorecer el acceso oportuno a procesos de evaluación y apoyo.

1.1. Motivación

La motivación que condujo a seleccionar el tema y emprender la investigación surge de la importancia de la detección temprana del Trastorno del Espectro Autista (TEA) y de la necesidad de contar con herramientas que puedan apoyar este proceso. El TEA puede manifestarse desde edades tempranas mediante diferentes características conductuales y patrones de motricidad, entre los que se encuentran movimientos repetitivos como el aleteo de manos, el balanceo corporal y los movimientos repetitivos de cabeza.

La identificación de estas manifestaciones puede aportar información relevante durante los procesos de evaluación del desarrollo infantil. Sin embargo, su reconocimiento requiere observación y valoración por parte de profesionales especializados. En este sentido, surge el interés por desarrollar una herramienta que permita identificar determinados patrones de motricidad a partir de secuencias de video, como apoyo a la evaluación.

Desde una perspectiva académica, el desarrollo de esta investigación permite aplicar conocimientos adquiridos durante la formación en Ingeniería de Sistemas en una problemática relacionada con el área de la salud y el desarrollo infantil. Además, posibilita la integración de conocimientos relacionados con el procesamiento de imágenes, aprendizaje profundo y desarrollo de aplicaciones web para abordar una necesidad concreta.

Desde una perspectiva social, la propuesta se encuentra motivada por la posibilidad de contribuir a una detección más oportuna de señales asociadas al TEA. Una identificación temprana puede favorecer el acceso de los niños a evaluaciones especializadas y a los apoyos adecuados según sus necesidades, contribuyendo a su desarrollo, bienestar y calidad de vida, así como brindando orientación a sus familias.

Finalmente, el desarrollo de un sistema web para identificar patrones de motricidad relacionados con el TEA mediante una arquitectura CNN-LSTM representa una oportunidad para aplicar la tecnología en beneficio de los procesos de evaluación, proporcionando una herramienta de apoyo que no pretende sustituir la valoración profesional ni emitir un diagnóstico clínico definitivo.

1.2. Definición del problema

El Trastorno del Espectro Autista (TEA) es una condición del neurodesarrollo caracterizada por dificultades en la comunicación social, la interacción social y la presencia de patrones de comportamiento restringidos o repetitivos. Estas manifestaciones pueden observarse desde los primeros años de vida

y suelen evidenciarse a través de señales conductuales como escaso contacto visual, dificultades en la comunicación, ausencia de respuesta al nombre, movimientos repetitivos, intereses restringidos o conductas estereotipadas. La identificación temprana de estas características es fundamental, ya que permite iniciar intervenciones oportunas que favorecen el desarrollo cognitivo, social y comunicativo de los niños [1].

En Paraguay, el Trastorno del Espectro Autista representa un desafío creciente para el sistema de salud y para las familias. De acuerdo con información difundida por el Instituto de Previsión Social, se estima que entre 45.000 y 133.000 personas podrían encontrarse dentro del espectro autista en el país, lo que evidencia la necesidad de fortalecer las estrategias de detección y atención temprana [2].

Muchos padres o cuidadores acuden a consulta cuando observan señales conductuales en sus hijos, tales como juego solitario, dificultades en la interacción social, rigidez en el comportamiento, caminar en puntillas, aleteo de manos o movimientos repetitivos. Estas señales pueden manifestarse desde edades tempranas y constituyen indicadores relevantes para la evaluación del desarrollo infantil.

A pesar de los avances en protocolos de atención y en la concienciación sobre el autismo, diversos estudios señalan que el TEA ha sido históricamente subdiagnosticado, y que en muchos casos el diagnóstico formal se realiza varios años después de la aparición de los primeros signos. En América Latina, los síntomas suelen identificarse alrededor de los 18 meses de edad; sin embargo, el diagnóstico definitivo puede confirmarse aproximadamente a los cuatro años, lo que retrasa el inicio de intervenciones especializadas [3].

En Paraguay, el protocolo nacional para la atención del Trastorno del Espectro Autista recomienda la vigilancia del desarrollo infantil mediante evaluaciones periódicas y la identificación de signos de alerta en edades tempranas, con el fin de facilitar la derivación oportuna a servicios especializados [1]. No obstante, en la práctica pueden existir dificultades para sistematizar la observación de conductas, registrar adecuadamente los patrones de motricidad y apoyar el proceso de evaluación clínica con herramientas tecnológicas que permitan analizar de manera más objetiva las manifestaciones conductuales.

En este contexto, surge la necesidad de explorar herramientas basadas en aprendizaje automático que permitan reconocer patrones de motricidad asociados al Trastorno del Espectro Autista, con el propósito de brindar apoyo al proceso de evaluación temprana realizado por profesionales de la salud. Estas herramientas no pretenden reemplazar el diagnóstico clínico, sino contribuir a la identificación temprana de señales conductuales relevantes que puedan facilitar la toma de decisiones en el ámbito clínico y educativo.

Por tanto, se define como problema de investigación del TFG propuesto la necesidad de desarrollar un sistema web para identificar patrones de motricidad relacionados con TEA, mediante el empleo de una arquitectura CNN-LSTM.

1.3. Objetivos

1.3.1. Objetivo General

Desarrollar un sistema web de apoyo al diagnóstico del TEA mediante el empleo de una arquitectura CNN-LSTM capaz de identificar patrones de motricidad a partir del análisis de secuencias de video.

1.3.2. Objetivos Específicos

1. Adquirir conocimiento sobre la tecnología CNN-LSTM aplicada a la identificación de patrones de motricidad asociados al TEA, mediante el estudio de redes neuronales convolucionales y redes de memoria a largo y corto plazo.
2. Recolectar datos de motricidad asociados al TEA mediante la selección y organización de secuencias de video que presenten patrones de aleteo de manos, balanceo corporal y movimientos repetitivos de cabeza.
3. Diseñar la arquitectura de un modelo basado en redes neuronales CNN-LSTM para el reconocimiento de patrones de motricidad asociados al TEA, considerando la extracción de características espaciales y el procesamiento de la información temporal.
4. Preprocesar los fotogramas obtenidos de las secuencias de video mediante técnicas de normalización, organización y generación de secuencias, posibilitando la extracción de características relevantes para el modelo.
5. Entrenar el modelo CNN-LSTM utilizando los datos previamente preparados, con el propósito de aprender las características espaciales y temporales asociadas a los patrones de motricidad seleccionados.
6. Evaluar el desempeño del modelo mediante métricas de clasificación, considerando su capacidad para identificar los patrones de motricidad asociados al TEA.

7. Elaborar una plataforma web que integre el modelo CNN-LSTM, incorporando las funcionalidades necesarias para la carga de secuencias de video, procesamiento e identificación de los patrones de motricidad.
8. Validar el funcionamiento del sistema mediante pruebas de identificación de patrones de motricidad asociados al TEA, considerando el procesamiento de videos y la generación de resultados.

1.4. Hipótesis

El algoritmo propuesto, que implementa arquitectura CNN-LSTM, para detectar tempranamente trastorno del espectro autista, basado en patrones de motricidad identificados en secuencias de video, tendría eficiencia en la detección, al menos igual a 85 %, según referente humano experto.

1.5. Justificación

En el contexto actual de la atención relacionada con el Trastorno del Espectro Autista (TEA), donde la identificación oportuna de sus manifestaciones puede favorecer el acceso temprano a evaluación y apoyo especializado, el desarrollo de herramientas tecnológicas representa una oportunidad para contribuir a los procesos de detección. El TEA puede presentar diversas manifestaciones conductuales y patrones de motricidad que pueden ser observados desde edades tempranas, entre ellos el aleteo de manos, el balanceo corporal y los movimientos repetitivos de cabeza.

Este trabajo se justifica por la necesidad de explorar alternativas que permitan apoyar la identificación de estos patrones mediante el análisis de secuencias de video. La observación de movimientos repetitivos puede requerir el análisis de diferentes momentos y situaciones, por lo que una herramienta capaz de procesar información audiovisual podría facilitar la identificación de determinadas manifestaciones y proporcionar información complementaria durante los procesos de evaluación realizados por profesionales especializados.

La propuesta busca contribuir en los siguientes aspectos:

- Facilitar la identificación de determinados patrones de motricidad relacionados con el TEA a partir de secuencias de video.

““

- Proporcionar una herramienta de apoyo que contribuya al proceso de evaluación de manifestaciones observables asociadas al TEA.

- Favorecer una identificación más oportuna de señales que puedan motivar una evaluación especializada.
- Contribuir al desarrollo de herramientas tecnológicas aplicadas al análisis de manifestaciones relacionadas con el desarrollo infantil.
- Generar una base para futuras investigaciones sobre el reconocimiento automatizado de patrones de motricidad asociados al TEA mediante inteligencia artificial. “

Desde una perspectiva académica y tecnológica, el desarrollo del sistema permite aplicar técnicas de aprendizaje profundo para el análisis de secuencias de video, integrando una arquitectura CNN-LSTM en una plataforma web. Esto posibilita abordar una problemática relacionada con el área de la salud mediante conocimientos propios de la Ingeniería de Sistemas y explorar la aplicación de inteligencia artificial en el reconocimiento de patrones de motricidad.

Desde una perspectiva social, la propuesta adquiere relevancia debido a que una identificación más oportuna de determinadas señales asociadas al TEA puede favorecer el acceso temprano a procesos de evaluación y a los apoyos correspondientes según las necesidades de cada niño. De esta manera, el sistema busca constituirse como una herramienta complementaria que pueda contribuir indirectamente al bienestar y desarrollo infantil, sin sustituir la evaluación de profesionales especializados ni emitir un diagnóstico clínico definitivo.

En síntesis, este trabajo busca integrar conocimientos académicos y tecnológicos para abordar una problemática relacionada con la identificación de manifestaciones del TEA, mediante el desarrollo de una herramienta web orientada al reconocimiento de patrones de motricidad a partir de secuencias de video, procurando aportar al fortalecimiento de los procesos de evaluación y a la detección oportuna de señales relevantes.

1.6. Delimitación del alcance del trabajo

La investigación se centra en el desarrollo de un prototipo de sistema web orientado a la identificación de patrones de motricidad relacionados con el Trastorno del Espectro Autista (TEA), mediante el análisis de secuencias de video y el empleo de una arquitectura CNN-LSTM. El trabajo contempla la identificación de tres patrones de motricidad visualmente observables: aleteo de manos, balanceo corporal y movimientos repetitivos de cabeza.

El estudio se establece considerando las siguientes delimitaciones específicas:

Delimitación temática: El trabajo se limita a la identificación de los tres patrones de motricidad mencionados, sin abarcar otras manifestaciones conductuales, características clínicas, trastornos del neurodesarrollo u otras condiciones médicas. El análisis se centra exclusivamente en patrones que puedan ser observados visualmente en secuencias de video.

Delimitación de los datos: Los datos utilizados para el desarrollo del modelo corresponden a secuencias de video obtenidas de fuentes de acceso público, principalmente plataformas audiovisuales, así como a videos de recolección propia. Los videos serán seleccionados de acuerdo con los patrones de motricidad definidos y organizados mediante etiquetado manual para su posterior procesamiento, entrenamiento y evaluación del modelo.

Delimitación tecnológica: La investigación se limita al empleo de una arquitectura CNN-LSTM, utilizando una red neuronal convolucional (CNN) para la extracción de características espaciales de los fotogramas y una red LSTM para el procesamiento de la información temporal presente en las secuencias. No se contempla una comparación exhaustiva con otras arquitecturas de aprendizaje profundo.

Delimitación del análisis: El procesamiento se realizará exclusivamente sobre información visual obtenida de secuencias de video. No se contemplan señales de audio, cuestionarios clínicos, entrevistas, antecedentes médicos, historial clínico ni otras variables utilizadas en procesos de diagnóstico del TEA.

Delimitación geográfica: El trabajo se desarrolla en el contexto académico y tecnológico de Paraguay, considerando datos audiovisuales disponibles públicamente y material de recolección propia. El prototipo no contempla una validación clínica a nivel nacional ni la implementación del sistema en instituciones de salud.

Delimitación temporal: El desarrollo del prototipo, la preparación de los datos, el entrenamiento del modelo, la integración con la plataforma web y las pruebas de funcionamiento se realizarán durante el período establecido para el desarrollo del Trabajo Final de Grado.

La validación se limitará a la evaluación del desempeño técnico del modelo mediante métricas de clasificación y a pruebas de funcionamiento del sistema. Los resultados obtenidos no serán considerados como un diagnóstico clínico de TEA ni sustituirán la evaluación realizada por profesionales especializados.

En síntesis, la investigación establece como límite el desarrollo y evaluación de un prototipo web capaz de identificar determinados patrones de motricidad asociados al TEA a partir de secuencias de video, constituyendo una herramienta de apoyo que podrá servir como base para futuras investi-

gaciones y desarrollos orientados a la detección temprana de manifestaciones relacionadas con el trastorno.

1.7. Descripción de los contenidos por capítulo

El Capítulo 2: Conceptos fundamentales, teorías y antecedentes desarrolla el marco teórico y conceptual de la investigación, presentando los principales conceptos relacionados con el Trastorno del Espectro Autista (TEA), sus características y los patrones de motricidad asociados. Asimismo, se abordan los fundamentos de la Inteligencia Artificial, el aprendizaje automático y el aprendizaje profundo, junto con los conceptos de visión artificial y procesamiento de imágenes y secuencias de video. También se presentan las redes neuronales convolucionales (CNN), las redes neuronales recurrentes (RNN), las redes LSTM y la arquitectura híbrida CNN-LSTM utilizada para el reconocimiento de patrones de motricidad. Finalmente, se incluyen antecedentes de investigaciones relacionadas con el uso de inteligencia artificial y análisis de video en el estudio del TEA.

El Capítulo 3: Tecnologías utilizadas presenta las herramientas y componentes empleados para el desarrollo del sistema. Se describen los recursos de hardware utilizados durante el desarrollo y entrenamiento del modelo, así como las tecnologías de software empleadas. También se detallan las herramientas utilizadas para el procesamiento de videos e imágenes, el desarrollo del modelo CNN-LSTM y la implementación de la plataforma web. Se incluyen las tecnologías utilizadas para el frontend, backend, servicios REST y las bibliotecas necesarias para la integración del modelo de inteligencia artificial.

El Capítulo 4: Método describe el proceso metodológico empleado para el desarrollo de la investigación. Se presenta el enfoque y alcance del estudio, así como el diseño utilizado para el desarrollo de la solución propuesta. Se detalla el proceso de selección, organización y etiquetado de los videos, el preprocesamiento mediante extracción de fotogramas y normalización de imágenes, el diseño y desarrollo de la arquitectura CNN-LSTM, el entrenamiento y evaluación del modelo, y finalmente su integración en la plataforma web.

El Capítulo 5: Resultados presenta los resultados obtenidos durante el desarrollo y evaluación del sistema. Se incluyen los resultados del procesamiento y entrenamiento del modelo CNN-LSTM, así como las métricas utilizadas para evaluar su desempeño. También se presentan los resultados de las pruebas de funcionamiento del sistema, incluyendo la clasificación de

los patrones de motricidad definidos: aleteo de manos, balanceo corporal y movimientos repetitivos de cabeza. Además, se muestran los resultados de la integración del modelo en la plataforma web y las pruebas relacionadas con su funcionamiento y rendimiento.

El Capítulo 6: Discusión analiza e interpreta los resultados obtenidos durante la investigación, relacionándolos con los objetivos planteados y los antecedentes estudiados. Se analizan los resultados obtenidos por el modelo CNN-LSTM y su capacidad para reconocer los patrones de motricidad considerados. También se abordan las limitaciones encontradas durante el desarrollo, los principales aportes de la investigación y las posibles mejoras y líneas de trabajo futuro relacionadas con el uso de inteligencia artificial y análisis de video como herramienta de apoyo para la evaluación de patrones de motricidad asociados al TEA.

Capítulo 2

Conceptos fundamentales, teorías y antecedentes

En este capítulo se desarrolla el marco teórico, conceptual y referencial de la investigación. Se presentan los conceptos relacionados con el TEA, la inteligencia artificial, el aprendizaje profundo, la visión artificial y la arquitectura CNN-LSTM. Finalmente, se incluyen antecedentes de investigaciones relacionadas con algunos de los enfoques y tecnologías utilizados en el desarrollo del proyecto.

2.1. Trastorno del espectro autista

El Trastorno del Espectro Autista es comprendido actualmente como una condición del neurodesarrollo de base neurobiológica y genética que se manifiesta en los primeros años de vida. De acuerdo con el Ministerio de Salud Pública y Bienestar Social, esta condición se define por una organización atípica de las funciones cerebrales que impacta severamente en la capacidad de comunicación social y en la flexibilidad del pensamiento y la conducta [1]. El marco técnico nacional destaca que la transición hacia el concepto de “espectro” permite integrar bajo un mismo paraguas clínico una amplia diversidad de manifestaciones. No obstante, todas comparten dos dimensiones nucleares: las deficiencias persistentes en la comunicación y la interacción social en diversos contextos, y la presencia de patrones de motricidad, intereses o actividades restrictivas y repetitivas [1]. En Paraguay, se enfatiza que el TEA no es una enfermedad que requiera una “cura”, sino una condición de vida que demanda apoyos específicos y ajustes del entorno para garantizar el ejercicio pleno de derechos de la persona [2].

Síntomas del Trastorno del Espectro Autista

Uno de los principales grupos de síntomas del TEA corresponde a las dificultades en la interacción social. Estas pueden manifestarse como una limitada capacidad para establecer relaciones con otras personas, escaso contacto visual, dificultad para comprender normas sociales y poca respuesta emocional hacia los demás. En Paraguay, especialistas señalan que estas dificultades pueden observarse desde la infancia, incluyendo la falta de apego o la escasa búsqueda de atención por parte de los cuidadores [3].

Otro conjunto importante de síntomas se relaciona con la comunicación. Las personas con TEA pueden presentar retrasos en el desarrollo del lenguaje, dificultades para iniciar o mantener conversaciones, o utilizar formas atípicas de comunicación como la ecolalia (repetición de palabras o frases). En algunos casos, incluso pueden no responder a estímulos verbales, lo que genera la percepción errónea de problemas auditivos .

Asimismo, el TEA se caracteriza por la presencia de comportamientos repetitivos e intereses restringidos. Estos pueden incluir movimientos estereotipados, como girar sobre sí mismos o manipular objetos de forma repetitiva, así como una fuerte resistencia a los cambios en la rutina. Esta rigidez conductual puede generar ansiedad intensa ante situaciones nuevas o imprevistas.

Otro aspecto relevante dentro de los síntomas es la alteración en el procesamiento sensorial. Las personas con TEA pueden mostrar hipersensibilidad o hiposensibilidad a estímulos como sonidos, luces, texturas o dolor. Esto puede influir en su comportamiento diario, generando respuestas inusuales o evitación de ciertos entornos

Es importante destacar que los síntomas del TEA aparecen en las primeras etapas del desarrollo, generalmente antes de los 2 o 3 años de edad, aunque en algunos casos pueden hacerse más evidentes cuando las demandas sociales aumentan. En Paraguay, se ha observado que la detección suele ser tardía en comparación con otros países, lo que puede retrasar la intervención temprana y afectar el desarrollo del niño .

Finalmente, cabe resaltar que el TEA es un espectro, lo que significa que los síntomas varían ampliamente en tipo e intensidad entre individuos. Algunas personas pueden presentar síntomas leves y llevar una vida relativamente independiente, mientras que otras requieren apoyo significativo. Esta variabilidad hace necesario un enfoque diagnóstico individualizado y multidisciplinario [1].

Se describen signos de alarma para sospechar alteraciones del desarrollo infantil, los cuales pueden ser identificados en diferentes etapas tempranas de la vida (ver Tabla 1).

Tabla 2.1: Signos de alarma de alteración del desarrollo
[1]

EDAD	ALARMA
6 MESES	No trata de agarrar cosas que están a su alcance, no mira a la madre durante la lactancia. No demuestra afecto por quienes le cuidan. No reacciona ante los sonidos a su alrededor. Tiene dificultad para llevarse cosas a la boca. No emite sonidos (vocales: “a”, “e”, “o”). No gira en ninguna dirección (rueda). No se ríe ni hace sonidos de placer al ser estimulado por sus cuidadores frecuentes. Se ve rígido y con los músculos tensos. Se ve sin fuerza como un muñeco de trapo.
12 MESES	No gatea. No puede permanecer de pie con ayuda. No busca un objeto que se le esconde. No dice palabras sencillas como “mamá” o “papá”. No aprende a usar gestos como saludar con la mano o mover la cabeza. No señala cosas.
18 MESES	Pierde habilidades que había adquirido. No señala cosas para mostrarlas a otras personas. No puede caminar solo. No sabe para qué sirven las cosas familiares. No imita lo que hacen las demás personas. No aprende nuevas palabras. No sabe por lo menos 6 palabras. No se da cuenta ni parece importarle si la persona que le cuida se va o regresa.
2 AÑOS	Pierde habilidades que había adquirido. No usa frases de dos palabras. No conoce el uso de objetos cotidianos. No imita acciones o palabras. No sigue instrucciones simples.

Continúa en la siguiente página...

EDAD	ALARMA
3 AÑOS	Se cae mucho o tiene problemas para subir y bajar escaleras. No se le entiende cuando habla. No sabe utilizar juguetes sencillos. No usa oraciones para hablar. No entiende instrucciones sencillas. No imita ni usa la imaginación en sus juegos.
4 AÑOS	No salta en un solo pie. No muestra interés en juegos interactivos o de imaginación. Ignora a otros niños o no responde a personas fuera de la familia. No puede relatar su cuento favorito. No sigue instrucciones de 3 acciones. No entiende lo que quieren decir “igual” y “diferente”. No usa correctamente las palabras “yo” y “tú”. No habla claro. Pierde habilidades que había adquirido.

2.2. El Contexto de la Salud Pediátrica en Paraguay

La detección del Trastorno del Espectro Autista (TEA) en Paraguay se fundamenta actualmente en un modelo de vigilancia del desarrollo que busca romper con la tradición del “diagnóstico por sospecha tardía”. Bajo el marco de la Ley N° 6103/2018, el sistema de salud nacional ha pasado a reconocer que las desviaciones en el neurodesarrollo deben identificarse en la etapa de máxima plasticidad cerebral. Esto sitúa la relevancia de cualquier sistema de detección dentro de las Unidades de Salud de la Familia (USF) y los centros de atención primaria, donde el objetivo es captar señales de alerta antes de que las barreras sociales y comunicativas se consoliden.

En la realidad paraguaya, la detección se enfrenta al desafío de la centralización de especialistas. Por ello, el marco teórico de un sistema tecnológico debe sustentarse en la capacidad de objetivar síntomas que, a menudo, son pasados por alto en consultas pediátricas breves. La normativa vigente (Decreto N° 3624/20) respalda la implementación de protocolos que permitan

una derivación oportuna a centros de mayor complejidad como el Hospital Pediátrico Niños de Acosta Ñu, asegurando que el proceso de identificación sea el primer eslabón de una cadena de intervención integral [4].

2.3. Inteligencia Artificial

2.3.1. Definición y fundamentos

La Inteligencia Artificial se define como el campo de la ciencia computacional dedicado al desarrollo de sistemas capaces de realizar tareas que tradicionalmente requieren de la inteligencia humana, tales como el razonamiento, el aprendizaje y la percepción visual [5]. En el ámbito de la ingeniería, la IA presenta una evolución significativa, pasando de sistemas basados en reglas lógicas hacia modelos capaces de extraer conocimiento directamente a partir de los datos [6]. Esta transformación permite que la disciplina deje de depender de heurísticas rígidas y se consolide como un marco robusto de aprendizaje estadístico y computacional.

2.3.2. Ramas de la IA aplicadas a la ingeniería

Actualmente, la Inteligencia Artificial se divide en diversas áreas de especialización, destacándose el Aprendizaje Automático (Machine Learning) y el Aprendizaje Profundo (Deep Learning) como las ramas de mayor impacto en la ingeniería moderna. Estos enfoques permiten a los sistemas no solo procesar información, sino también aprender de grandes volúmenes de datos y generalizar soluciones a partir de patrones complejos [7]. En el área de la salud, estas capacidades facilitarán la identificación de biomarcadores y patrones de motricidad que resultarán imperceptibles mediante métodos tradicionales, posicionando a la IA como una herramienta clave de apoyo en el diagnóstico clínico [8].

2.4. Aprendizaje automático

2.4.1. Definición y fundamentos

El Aprendizaje Automático constituye una subdisciplina fundamental dentro del campo de la Inteligencia Artificial, cuyo propósito es desarrollar modelos capaces de aprender patrones a partir de datos sin ser programados de forma explícita para cada tarea. En este sentido, los algoritmos permiten identificar relaciones complejas dentro de grandes volúmenes de información,

facilitando la automatización de procesos de análisis y toma de decisiones [9]. Los fundamentos del aprendizaje automático se basan en el uso de datos de entrada, modelos matemáticos y procesos de entrenamiento mediante los cuales el sistema ajustará sus parámetros internos con el objetivo de minimizar el error. Este proceso implicará el uso de funciones de pérdida y algoritmos de optimización, así como técnicas de validación para garantizar la capacidad de generalización del modelo frente a datos no vistos previamente [10]. Asimismo, se considerarán aspectos clave como la calidad de los datos, el preprocesamiento, la selección de características y la evaluación del rendimiento mediante métricas específicas, factores que influirán directamente en la eficacia del modelo desarrollado.

2.4.2. Aprendizaje supervisado

El aprendizaje supervisado representa uno de los enfoques más utilizados dentro del aprendizaje automático, caracterizándose por el uso de datos previamente etiquetados. En este tipo de aprendizaje, el modelo será entrenado a partir de pares de entrada y salida esperada, permitiendo que el sistema aprenda a predecir resultados en función de nuevos datos [9]. Dentro de este enfoque, se emplearán técnicas de clasificación y regresión. En el contexto del presente estudio, se priorizarán los modelos de clasificación, ya que permitirán determinar la presencia o ausencia de características asociadas al TEA. El proceso de entrenamiento incluirá la división del conjunto de datos en subconjuntos de entrenamiento y prueba, así como la validación del modelo mediante métricas como precisión, sensibilidad (recall), especificidad y F1-score. Estas métricas permitirán evaluar la capacidad del sistema para identificar correctamente patrones conductuales relevantes [10].

2.4.3. Aplicación en diagnóstico clínico

El aprendizaje automático será aplicado en el ámbito del diagnóstico clínico como una herramienta de apoyo para la detección temprana de diversas condiciones, incluyendo el Trastorno del Espectro Autista. En este contexto, los modelos permitirán analizar datos complejos, como videos de comportamiento, con el objetivo de identificar patrones que podrían no ser fácilmente perceptibles mediante la observación humana [11]. En el presente trabajo, se propondrá la utilización de modelos basados en redes neuronales profundas, incluyendo arquitecturas híbridas que integren redes convolucionales y recurrentes, lo que permitirá procesar información espacial y temporal de manera conjunta. Esto facilitará el análisis de gestos, movimientos repetitivos y patrones de interacción social presentes en los videos [12]. La implementación de

estas técnicas contribuirá a mejorar la precisión y objetividad en el proceso de evaluación clínica, sirviendo como complemento a los métodos tradicionales de diagnóstico. Sin embargo, se considerará que estos sistemas no reemplazarán la intervención de profesionales de la salud, sino que actuarán como herramientas de apoyo en la toma de decisiones clínicas [13].

2.5. Visión artificial

2.5.1. Definición y evolución

La Visión Artificial (Computer Vision) se define como un campo interdisciplinario de la Inteligencia Artificial que busca otorgar a los sistemas computacionales la capacidad de adquirir, procesar, analizar y comprender el contenido visual del mundo real a partir de imágenes digitales y secuencias de video [14]. En el ámbito de la ingeniería, esta disciplina presenta una evolución significativa, pasando de enfoques tradicionales basados en el diseño manual de algoritmos matemáticos complejos para la extracción de características visuales como la detección de bordes o formas geométricas hacia la implementación de arquitecturas de aprendizaje profundo, las cuales permiten la extracción automatizada de representaciones visuales de alto nivel [15].

2.5.2. Aplicación en análisis de comportamiento

En el contexto clínico y del análisis de comportamiento, la Visión Artificial se consolidará como una herramienta tecnológica fundamental para el soporte diagnóstico. En tareas de reconocimiento de acciones motoras, los sistemas analizarán flujos de video en tiempo real con el objetivo de estimar la postura corporal del individuo y rastrear la evolución dinámica de sus movimientos [16]. Mediante el uso de redes neuronales especializadas, será posible procesar estos datos para identificar, cuantificar y analizar biomarcadores y patrones de motricidad que podrían no ser perceptibles mediante la observación humana convencional, transformando la evaluación en un proceso objetivo, estandarizado y escalable [17].

2.6. Arquitectura Híbrida CNN-LSTM para Reconocimiento de Patrones

2.6.1. Fundamentos de la Combinación Espacio-Temporal

A diferencia de las imágenes estáticas, el video será considerado como una secuencia de fotogramas ordenados cronológicamente. Para detectar patrones como giros o balanceos, no será suficiente analizar una imagen aislada; será necesario observar la evolución de la postura en el tiempo. Modelos como las Redes Convolucionales Recurrentes a Largo Plazo (LRCN) demostrarán ser altamente efectivos para esta tarea, ya que permitirán procesar características visuales y secuenciales de forma simultánea [18].

2.6.2. Extracción de Características con CNN (Capa Espacial)

En la primera etapa, cada fotograma del video será procesado individualmente por una Red Neuronal Convolutiva (CNN). En arquitecturas de clasificación de video a gran escala, la CNN actuará como un extractor automático de características. Mediante operaciones matemáticas de convolución y agrupación (pooling), la red identificará puntos clave como:

- **Bordes y silueta:** aislará el cuerpo del infante del fondo.
- **Postura:** determinará la posición de las extremidades y la orientación de la cabeza.

En esta fase, el modelo generará un vector de características unidimensionales por cada instante de tiempo, eliminando información irrelevante del entorno [19].

2.6.3. Procesamiento de Secuencias con LSTM (Capa Temporal)

Los vectores espaciales generados por la CNN serán entregados en orden cronológico a la red LSTM. Esta red recurrente será diseñada para modelar dependencias a largo plazo y mitigar el problema del desvanecimiento del gradiente.

En el contexto del TEA, la LSTM analizará la periodicidad de los movimientos. Si los vectores indican posiciones repetitivas de manera rítmica a lo largo de varios cuadros, la red identificará estos patrones como comportamientos estereotipados, como el aleteo de manos. Su arquitectura de

“puertas de olvido” permitirá descartar movimientos esporádicos y centrarse en patrones relevantes [20].

2.6.4. Flujo de Datos y Clasificación de Patrones de motricidad

El flujo de la arquitectura culminará en una capa densamente conectada con una función de activación, como Softmax. Esta capa recibirá el resumen temporal generado por la LSTM y calculará una probabilidad estadística. Como resultado, el sistema emitirá un porcentaje de confianza que indicará si la secuencia de video corresponderá a un patrón conductual típico o a un marcador motor asociado al autismo, sirviendo como herramienta de apoyo para el especialista clínico [21].

2.7. Diseño web

2.7.1. Interfaz de Usuario y Arquitectura de Integración Web

La efectividad de un sistema de detección temprana del Trastorno del Espectro Autista (TEA) no dependerá únicamente de la precisión del modelo de inteligencia artificial, sino también de la calidad de la interacción entre el usuario y la plataforma. En este contexto, la interfaz web será concebida como un componente esencial que permitirá la integración eficiente entre el especialista clínico y el motor de inferencia basado en redes CNN-LSTM.

El sistema web será diseñado para gestionar de manera estructurada el flujo de datos, desde la carga de secuencias de video hasta la visualización de resultados interpretables. Esta integración permitirá que el usuario pueda utilizar la herramienta sin requerir conocimientos técnicos avanzados en inteligencia artificial, facilitando su adopción en entornos clínicos y educativos.

Además, la arquitectura de la plataforma priorizará la usabilidad, accesibilidad y eficiencia, aspectos fundamentales en sistemas de apoyo a la toma de decisiones médicas, donde la claridad en la presentación de la información influye directamente en la interpretación de los resultados [22].

2.7.2. Arquitectura del Lado del Cliente (Frontend)

El frontend será desarrollado bajo un enfoque basado en componentes reutilizables, empleando tecnologías modernas como Next.js, que permiten optimizar el rendimiento mediante renderizado híbrido (SSR y CSR). Este

enfoque será clave para mejorar los tiempos de carga y garantizar una experiencia de usuario fluida, especialmente al trabajar con archivos multimedia de gran tamaño como videos.

La interfaz estará diseñada específicamente para soportar el flujo de trabajo del sistema de detección de TEA, permitiendo al usuario:

- Cargar videos de comportamiento infantil de manera sencilla e intuitiva.
- Visualizar el estado del procesamiento en tiempo real.
- Recibir retroalimentación clara durante el análisis.
- Acceder a los resultados generados por el modelo.

Asimismo, el sistema gestionará procesos asíncronos relacionados con la carga y análisis de videos, utilizando técnicas de manejo de estado que permitan informar al usuario sobre el progreso del procesamiento. Esto resulta fundamental considerando que los modelos de aprendizaje profundo, como CNN-LSTM, requieren tiempos de inferencia variables dependiendo de la longitud del video [10].

El diseño de la interfaz priorizará la simplicidad y claridad visual, reduciendo la carga cognitiva del usuario y facilitando la interpretación de los resultados obtenidos.

2.7.3. Comunicación y Servicios de Red (Backend)

La comunicación entre el frontend y el sistema de inteligencia artificial se implementará mediante una arquitectura cliente-servidor basada en el estilo REST (Representational State Transfer), ampliamente utilizado en aplicaciones web modernas por su escalabilidad y simplicidad.

El backend será desarrollado utilizando FastAPI, un framework de alto rendimiento para la construcción de APIs, que permitirá gestionar de manera eficiente las solicitudes de procesamiento de video. Este componente actuará como un intermediario entre la interfaz de usuario y el modelo CNN-LSTM, organizando el flujo de datos en diferentes etapas:

1. Recepción del video cargado por el usuario.
2. Preprocesamiento de los datos (extracción de fotogramas, normalización, etc.).
3. Envío de los datos al modelo CNN para la extracción de características espaciales.

4. Procesamiento secuencial mediante la red LSTM.

Este enfoque desacoplado permitirá que el modelo de inteligencia artificial evolucione independientemente del sistema web, facilitando futuras mejoras en términos de precisión, escalabilidad y mantenimiento del sistema [23].

2.7.4. Gestión de Seguridad y Privacidad de Datos

Dado que el sistema trabajará con datos sensibles relacionados con menores de edad, la seguridad y privacidad serán aspectos críticos en su diseño. En este sentido, se implementarán mecanismos de autenticación y autorización que restringirán el acceso únicamente a usuarios autorizados, como profesionales de la salud o investigadores.

Asimismo, se establecerán políticas de protección de datos que garanticen la confidencialidad de la información, incluyendo el almacenamiento seguro de los videos y resultados generados. Este enfoque será coherente con principios internacionales de protección de datos y ética en sistemas de salud digital [24].

Además, se considerará la trazabilidad de las operaciones realizadas en el sistema, permitiendo registrar el acceso y uso de la información, lo cual es fundamental en contextos clínicos donde la transparencia y la responsabilidad son requisitos esenciales.

2.7.5. Visualización de Resultados y Diseño de Interacción

La visualización de resultados constituirá una de las etapas más importantes del sistema, ya que permitirá traducir la salida del modelo CNN-LSTM en información comprensible para el especialista. En este sentido, el diseño de la interacción estará orientado a facilitar la interpretación de patrones de motricidad detectados en los videos.

El sistema presentará los resultados mediante diferentes elementos visuales, tales como:

- Cargar videos de comportamiento infantil de manera sencilla e intuitiva.
- Visualizar el estado del procesamiento en tiempo real.
- Recibir retroalimentación clara durante el análisis.
- Acceder a los resultados generados por el modelo.

Este enfoque permitirá al usuario correlacionar los resultados del modelo con evidencia visual directa, fortaleciendo la confianza en el sistema y mejorando la toma de decisiones clínicas.

Además, el uso de técnicas de visualización interactiva contribuirá a reducir la ambigüedad en la interpretación de los resultados, transformando datos complejos en información clara y accesible [25].

De esta manera, el sistema no solo funcionará como una herramienta automatizada, sino como un soporte inteligente que complementará el criterio del especialista en la detección temprana del TEA.

Capítulo 3

Tecnologías utilizadas

El presente capítulo detalla las tecnologías de hardware y software seleccionadas para el desarrollo del proyecto. Se describe en primer lugar el hardware local disponible para el desarrollo del proyecto: la tarjeta gráfica NVIDIA GeForce RTX 4070 y el procesador AMD Ryzen 7 7800X3D. Posteriormente, se justifica la selección de cuatro arquitecturas de redes neuronales evaluadas para la extracción de características espaciales: una arquitectura CNN propia entrenada desde cero, y tres arquitecturas preentrenadas incorporadas mediante transferencia de aprendizaje (ResNet50, MobileNetV2 y Vision Transformer). Finalmente, se describen las herramientas complementarias del flujo de trabajo: YouTube como fuente de los videos que conforman el conjunto de datos y Google Drive para el almacenamiento centralizado del conjunto de datos.

3.1. Componentes de Hardware

Los componentes de hardware abarcan los dispositivos físicos disponibles en el equipo de desarrollo, utilizados tanto para las etapas de programación y preprocesamiento de video como, potencialmente, para el entrenamiento de los modelos de inteligencia artificial.

3.1.1. Tarjeta gráfica: NVIDIA GeForce RTX 4070

La NVIDIA GeForce RTX 4070 es una unidad de procesamiento gráfico (GPU) de gama alta para consumidores, basada en la arquitectura Ada Lovelace de NVIDIA. Cuenta con 12 GB de memoria VRAM tipo GDDR6X y núcleos Tensor de cuarta generación, orientados a acelerar operaciones de multiplicación de matrices propias del entrenamiento de redes neuronales

profundas mediante precisión mixta (FP16/BF16).



Figura 3.1: Tarjeta gráfica NVIDIA GeForce RTX 4070.

Esta tarjeta gráfica forma parte del equipo de desarrollo utilizado por el equipo de trabajo, y representa una capacidad de cómputo considerable para tareas de inteligencia artificial a nivel local. Su memoria VRAM y sus núcleos Tensor la hacen, en principio, adecuada para acelerar tanto el entrenamiento de la arquitectura CNN-LSTM propia como la extracción de características mediante las arquitecturas preentrenadas consideradas en este trabajo (ResNet50, MobileNetV2 y ViT) [26].

Los beneficios que ofrece esta tarjeta gráfica para el proyecto incluyen:

- **Aceleración por núcleos Tensor:** permite acelerar significativamente las operaciones matriciales del entrenamiento mediante precisión mixta (FP16/BF16), reduciendo los tiempos de cómputo respecto a un procesador convencional.
- **Amplia memoria VRAM (12 GB):** posibilita procesar lotes de video de mayor tamaño y modelos más grandes (como ResNet50 o ViT) sin quedar limitado por la memoria disponible.
- **Disponibilidad inmediata sin costo adicional:** al formar parte del equipo ya adquirido por el grupo de trabajo, no representa un gasto adicional para el proyecto.
- **Independencia de servicios externos a futuro:** configurando el entorno adecuado (WSL2), permitiría eliminar la dependencia de plataformas en la nube y sus limitaciones de cuota y disponibilidad.

3.1.2. Procesador: AMD Ryzen 7 7800X3D

El procesador AMD Ryzen 7 7800X3D, basado en la arquitectura Zen 4, complementa el equipo de desarrollo local. Se utiliza para la ejecución de las tareas que no dependen de aceleración por GPU: la extracción y el preprocesamiento de fotogramas de video (incluyendo la detección y el recorte del sujeto mediante YOLOv8n y la normalización de iluminación mediante CLAHE, detalladas en la sección 3.4), la programación y depuración del código del proyecto, y el entrenamiento de los componentes más livianos del sistema [27].

Los beneficios que ofrece este procesador para el proyecto incluyen:

- **Múltiples núcleos e hilos de procesamiento:** permite ejecutar en paralelo tareas de preprocesamiento de video (extracción de fotogramas, detección con YOLOv8n, normalización con CLAHE) sin generar cuellos de botella durante el desarrollo.
- **Suficiente para el entrenamiento de componentes livianos:** la capa LSTM, al entrenarse sobre vectores de características ya extraídos (y no sobre los fotogramas crudos), no requiere GPU y se ejecuta en tiempos razonables directamente en este procesador.
- **Estabilidad para tareas de desarrollo continuo:** adecuado para la programación, depuración y pruebas automatizadas del código del proyecto (los casos de prueba de la CNN y la LSTM, por ejemplo) sin necesidad de recursos especializados.
- **Ya disponible en el equipo de desarrollo:** al igual que la GPU, no representa un costo adicional para el proyecto.

3.2. Componentes de Software

Los componentes de software proporcionan las herramientas, plataformas y algoritmos necesarios para diseñar, entrenar y evaluar los modelos de inteligencia artificial del proyecto.

3.2.1. Arquitecturas para la extracción de características

Para la etapa de extracción de características espaciales de cada fotograma, se evaluaron cuatro arquitecturas de redes neuronales, seleccionadas por

representar enfoques complementarios: una arquitectura convolucional propia entrenada desde cero, y tres arquitecturas preentrenadas incorporadas mediante transferencia de aprendizaje.

3.2.1.1. CNN-LSTM

Arquitectura desarrollada específicamente para este proyecto, compuesta por cuatro bloques convolucionales, encargados de la extracción de características espaciales, seguidos de una capa LSTM para el análisis temporal. La arquitectura es entrenada completamente desde cero sobre el conjunto de datos de videos de conductas motoras.

Sus características principales son:

- **Diseño a medida:** arquitectura ajustada específicamente a la resolución y las características del conjunto de datos, utilizando fotogramas de 64×64 píxeles y secuencias de 40 fotogramas.
- **Sin dependencia de pesos preentrenados:** aprende representaciones específicas del dominio de estudio en lugar de heredar representaciones obtenidas a partir de un conjunto de datos genérico como ImageNet.
- **Bajo costo computacional:** presenta una cantidad reducida de parámetros en comparación con las arquitecturas preentrenadas, lo que permite un entrenamiento con menor requerimiento computacional.
- **Control total sobre el diseño:** permite ajustar cada hiperparámetro, incluyendo el número de filtros, dropout y regularización, en función de los resultados obtenidos durante el proceso experimental.

3.2.1.2. ResNet50

ResNet50 (Residual Network de 50 capas) es una arquitectura de red neuronal convolucional profunda que introduce conexiones residuales para abordar el problema de degradación en redes de gran profundidad, permitiendo que la información fluya directamente a través de la red mediante conexiones de atajo [28].

Sus características principales son:

- **Conexiones residuales:** facilitan la convergencia del modelo y permiten entrenar redes más profundas reduciendo los problemas asociados a la degradación del gradiente.

- **Transferencia de aprendizaje:** dispone de pesos preentrenados en ImageNet, que pueden aprovecharse para extraer características visuales generales sin necesidad de entrenar la arquitectura completamente desde cero.
- **Rendimiento comprobado:** es una arquitectura ampliamente utilizada y validada en tareas de clasificación y extracción de características de imágenes.
- **Mayor costo computacional:** produce 2048 características por fotograma y cuenta con aproximadamente 23 millones de parámetros, representando una de las alternativas de mayor costo computacional evaluadas.

3.2.1.3. MobileNetV2

MobileNetV2 es una arquitectura de red neuronal convolucional diseñada para ofrecer un buen equilibrio entre rendimiento y eficiencia computacional. Utiliza convoluciones separables en profundidad y bloques residuales invertidos para reducir la cantidad de operaciones y parámetros necesarios durante el procesamiento.

Sus características principales son:

- **Eficiencia computacional:** requiere una menor cantidad de operaciones y parámetros en comparación con arquitecturas convolucionales más profundas.
- **Transferencia de aprendizaje:** dispone de pesos preentrenados en ImageNet, permitiendo utilizar características visuales previamente aprendidas.
- **Menor requerimiento de memoria:** su diseño permite realizar la extracción de características con un consumo reducido de recursos computacionales.
- **Adecuada para recursos limitados:** representa una alternativa eficiente para el procesamiento de videos y la extracción de características en equipos con recursos computacionales moderados.

3.2.1.4. Vision Transformer (ViT)

Vision Transformer (ViT) aplica la arquitectura Transformer, originalmente desarrollada para tareas de procesamiento de lenguaje natural, al do-

minio de la visión por computadora. Para ello, divide cada imagen en pequeños parches que son tratados como tokens dentro de una secuencia [29].

Sus características principales son:

- **Mecanismo de atención:** permite capturar relaciones globales entre distintas regiones del fotograma de forma directa, a diferencia de las operaciones convolucionales tradicionales.
- **Paradigma alternativo:** representa una familia de arquitecturas diferente a las redes convolucionales, permitiendo evaluar si el mecanismo de atención global resulta adecuado para la identificación de patrones de motricidad.
- **Mayor necesidad de datos:** su entrenamiento completo requiere grandes volúmenes de datos, por lo que en este trabajo se emplea mediante transferencia de aprendizaje utilizando pesos preentrenados.
- **Costo computacional considerable:** presenta un requerimiento computacional significativo durante la extracción de características, comparable al de arquitecturas convolucionales profundas como ResNet50.

3.2.1.5. Criterios de evaluación

Con el fin de comparar las cuatro arquitecturas de forma sistemática, se establecieron los siguientes criterios:

- **Precisión:** capacidad para distinguir correctamente las clases de conducta motora consideradas en el conjunto de datos.
- **Eficiencia computacional:** relación entre el rendimiento obtenido y los recursos de cómputo requeridos, particularmente relevante debido al tamaño reducido del conjunto de datos, compuesto por 57 videos.
- **Velocidad de extracción de características:** tiempo necesario para procesar cada video durante la etapa de extracción de características.
- **Capacidad de generalización:** desempeño del modelo sobre datos no utilizados durante el entrenamiento, considerando el tamaño limitado del conjunto de datos.
- **Transferencia de aprendizaje:** disponibilidad y aprovechamiento de pesos preentrenados para la extracción de características visuales.

Tabla 3.1: Comparativa de stacks de frontend y backend

Criterio	Next.js + FastAPI	Next.js + Django (DRF)	React + NextJS	Django (full-stack)
Integración con el modelo de IA	3	3	1	3
Rendimiento con contenido multimedia	3	2	3	2
Tipado y mantenibilidad	3	2	3	1
Curva de aprendizaje	2	1	1	2
Documentación y ecosistema	3	3	2	3
Total	14	11	10	11

De acuerdo con los resultados obtenidos, la combinación de Next.js con FastAPI resultó la de mejor puntaje total. El criterio determinante fue la integración con el modelo de inteligencia artificial: al estar desarrollado íntegramente en Python, FastAPI permite importarlo y ejecutarlo de forma directa dentro de la misma API, sin necesidad de desplegarlo como un servicio separado ni de recurrir a bindings de aprendizaje automático para otros lenguajes, como ocurriría con React + NestJS (Node.js/TypeScript). Adicionalmente, Next.js aporta tipado estático (TypeScript) que mejora la mantenibilidad del código, junto con un esquema de renderizado híbrido (SSR y CSR) que favorece específicamente los tiempos de carga de archivos multimedia de gran tamaño, como los videos de comportamiento infantil que maneja el sistema. Django, ya sea combinado con Next.js o utilizado como framework full-stack, comparte la ventaja de ser Python, pero agrega una complejidad estructural (ORM, panel de administración, serializadores) que no resulta estrictamente necesaria para un sistema cuya función principal es recibir un video y devolver una clasificación, sin requerir una capa de persistencia de datos compleja.

3.3. Tecnologías del Frontend

A partir del stack seleccionado en la sección anterior, se detallan a continuación las tecnologías específicas que componen la capa de frontend de la plataforma web.

3.3.1. Next.js

Next.js es un framework de desarrollo web basado en React, que incorpora capacidades de renderizado del lado del servidor (SSR) y del lado del cliente (CSR) de forma híbrida. Se seleccionó como base del frontend porque su esquema de renderizado híbrido reduce los tiempos de carga percibidos al trabajar con archivos multimedia de gran tamaño –como los videos de comportamiento infantil que constituyen la entrada principal del sistema–, y porque incluye de forma nativa el ruteo de páginas y la optimización de recursos estáticos, sin requerir configuración adicional.

3.3.2. React

React es una biblioteca de JavaScript para la construcción de interfaces de usuario basada en componentes reutilizables, y constituye la base sobre la cual se construye Next.js. Su modelo de componentes resulta adecuado para estructurar las distintas vistas de la plataforma (carga de video, seguimiento del procesamiento, visualización de resultados) como unidades independientes y reutilizables, facilitando el mantenimiento del código a medida que el sistema incorpore nuevas funcionalidades.

3.3.3. TypeScript

TypeScript es un superconjunto de JavaScript que incorpora tipado estático opcional. Se utiliza en el desarrollo del frontend para detectar errores en tiempo de desarrollo –antes de que el código llegue a producción–, lo cual resulta particularmente relevante en un sistema que maneja datos sensibles de menores, donde un error de manejo de datos no detectado podría tener consecuencias mayores que en una aplicación convencional.

3.3.4. Tailwind CSS

Tailwind CSS es un framework de estilos basado en clases de utilidad, que permite construir interfaces personalizadas sin necesidad de escribir hojas de estilo (CSS) desde cero. Se seleccionó por su integración directa con Next.js

y por permitir un desarrollo más ágil de una interfaz simple y clara, alineada con el objetivo de reducir la carga cognitiva del usuario planteado en el diseño de interacción del sistema (sección 7.7.5 del Marco Teórico).

3.3.5. Recharts

Recharts es una biblioteca de visualización de datos para React, construida sobre gráficos vectoriales (SVG). Se incorpora al frontend para representar de forma visual el nivel de confianza que el modelo asigna a cada una de las clases de conducta motora evaluadas (aleteo de manos, balanceo corporal, giros), facilitando su interpretación por parte del profesional de la salud que utiliza el sistema como apoyo a la evaluación clínica.

3.3.6. Axios

Axios es un cliente HTTP basado en promesas, utilizado para gestionar la comunicación entre el frontend y el backend expuesto mediante FastAPI. Se seleccionó frente a la API nativa `fetch` de JavaScript por su manejo simplificado de solicitudes con archivos de gran tamaño (como los videos a subir) y por su soporte incorporado para el seguimiento del progreso de carga, relevante para informar al usuario sobre el estado del procesamiento de su video, tal como se plantea en el diseño de la interfaz (sección 7.7.2 del Marco Teórico).

3.4. Tecnologías del Backend

A partir del stack seleccionado en la sección 3.3, se detallan a continuación las tecnologías específicas que componen la capa de backend de la plataforma web, encargada de recibir los videos, ejecutar el preprocesamiento y el modelo de inteligencia artificial, y devolver los resultados al frontend.

3.4.1. FastAPI

FastAPI es un framework web moderno para Python, orientado a la construcción de APIs de alto rendimiento a partir de las anotaciones de tipo (*type hints*) nativas del lenguaje. Tal como se justificó en la sección 3.3, se seleccionó frente a alternativas como Django o NestJS principalmente por permitir importar y ejecutar el modelo CNN-LSTM directamente dentro de la misma API, sin *bridges* entre lenguajes, además de generar automáticamente do-

cumentación interactiva de los *endpoints* (Swagger/OpenAPI), útil para la validación y prueba del servicio durante el desarrollo.

3.4.2. Uvicorn

Uvicorn es un servidor ASGI (*Asynchronous Server Gateway Interface*) liviano y de alto rendimiento, requerido para ejecutar aplicaciones FastAPI. Se seleccionó por ser el servidor recomendado oficialmente para este framework, y por su soporte nativo de manejo asíncrono de solicitudes, lo cual permite que el servidor continúe atendiendo otras solicitudes mientras se ejecuta la inferencia del modelo sobre un video, evitando que el sistema quede bloqueado durante ese proceso.

3.4.3. Pydantic

Pydantic es una biblioteca de validación de datos basada en las anotaciones de tipo de Python, integrada de forma nativa en FastAPI. Se utiliza para validar la estructura de las solicitudes entrantes y para definir de forma explícita el esquema de la respuesta del servicio (por ejemplo, la conducta identificada junto con el nivel de confianza asociado a cada clase), reduciendo el riesgo de errores de formato al comunicar el backend con el frontend.

3.4.4. python-multipart

`python-multipart` es la biblioteca requerida por FastAPI para procesar datos de tipo `multipart/form-data`, formato necesario para la recepción de archivos a través de una API REST. Se incorpora específicamente para habilitar la funcionalidad de carga de videos desde el frontend hacia el backend.

3.4.5. TensorFlow / Keras (motor de inferencia)

Tal como se detalla en la sección 3.2, TensorFlow y Keras constituyen el framework principal utilizado para el desarrollo de los modelos de este trabajo. En el contexto del backend, específicamente, el modelo CNN-LSTM ya entrenado se carga una única vez al iniciar el servicio (mediante la función `load_model` de Keras) y se mantiene en memoria para ejecutar la inferencia sobre cada video recibido, evitando el costo de recargar el modelo en cada solicitud.

3.4.6. OpenCV (preprocesamiento en el backend)

OpenCV, ya utilizado en la etapa de entrenamiento para la extracción de fotogramas (sección 3.2), se reutiliza dentro del backend para aplicar exactamente el mismo preprocesamiento sobre los videos que suben los usuarios del sistema (extracción de fotogramas, recorte con YOLOv8n y normalización con CLAHE, detalladas en la sección 3.6). Mantener el mismo pipeline de preprocesamiento entre el entrenamiento y la inferencia resulta indispensable para que el modelo reciba datos con las mismas características con las que fue entrenado.

3.4.7. python-jose

`python-jose` es una biblioteca para la generación y validación de JSON Web Tokens (JWT). Se incorpora al backend para implementar los mecanismos de autenticación y autorización que restringen el acceso al sistema únicamente a usuarios autorizados —profesionales de la salud e investigadores—, tal como se establece en la sección 7.7.4 del Marco Teórico sobre gestión de seguridad y privacidad de datos, dado que el sistema procesa videos de menores de edad.

3.5. Servicios en la Nube

3.5.1. Google Drive

Google Drive es un servicio de almacenamiento en la nube que permite guardar y compartir archivos de forma centralizada. Se incorpora al flujo de trabajo del proyecto para almacenar el conjunto de datos (videos originales, fotogramas extraídos y modelos entrenados), por dos razones concretas: centralización entre los integrantes del equipo e integración directa con Google Colab.

3.5.2. Firebase Firestore

Firebase Firestore es una base de datos NoSQL orientada a documentos, alojada en la nube y ofrecida por Google como parte de la plataforma Firebase. Se incorpora al sistema para almacenar la información generada en cada análisis: el identificador del video procesado, la conducta identificada, el nivel de confianza asignado a cada una de las tres clases evaluadas y la fecha del análisis.

Esta información resulta necesaria para sostener la etapa de **Validación Externa** planteada en el diseño del sistema, en la cual un profesional de la salud revisa los resultados generados por el modelo de forma posterior al procesamiento del video, y no únicamente en el momento en que este se lleva a cabo. Se seleccionó Firestore, en lugar de una base de datos relacional tradicional, por dos motivos: la información a almacenar tiene una estructura simple y no requiere relaciones complejas entre tablas, y su integración nativa con el ecosistema de Google simplifica la configuración del backend mediante el SDK oficial de Firebase para Python.

3.6. Herramientas de Desarrollo

Las herramientas de desarrollo comprenden tanto el entorno de cómputo en la nube utilizado para el entrenamiento (Google Colaboratory), como las herramientas empleadas para la escritura, depuración y control de versiones del código del proyecto.

3.6.1. Entorno de cómputo: Google Colaboratory

Google Colaboratory (Colab) es un servicio de Google que permite ejecutar código Python en un entorno de tipo Jupyter Notebook alojado en la nube, con acceso gratuito a unidades de procesamiento gráfico (GPU) para tareas de cómputo intensivo. En su nivel gratuito, Colab asigna típicamente una GPU NVIDIA Tesla T4, dotada de 16 GB de memoria VRAM GDDR6 y núcleos Tensor de primera generación, orientados a acelerar operaciones de aprendizaje profundo mediante precisión mixta (FP16) [30].

La selección de Colab como entorno de entrenamiento, frente al uso de la GPU local (RTX 4070, no aprovechable de forma nativa en Windows) o del procesador local (Ryzen 7 7800, sin aceleración por GPU), se fundamentó en un análisis comparativo considerando los siguientes criterios:

- **Rendimiento computacional:** capacidad para acelerar el entrenamiento y la extracción de características mediante las arquitecturas preentrenadas.
- **Memoria disponible:** cantidad de VRAM necesaria para procesar secuencias de video de forma eficiente.
- **Soporte para frameworks:** compatibilidad nativa con TensorFlow y Keras sin requerir configuración adicional.

- **Disponibilidad:** continuidad de acceso al recurso de cómputo a lo largo de las distintas etapas del proyecto.
- **Costo:** gastos asociados al uso del recurso de cómputo.
- **Facilidad de configuración:** tiempo y complejidad necesarios para dejar el entorno operativo.

Para reflejar el desempeño relativo de cada opción, se empleó una escala del 1 al 3, donde 3 indica el mejor desempeño y 1 el más limitado:

Tabla 3.2: Comparativa de entornos de cómputo

Criterio	CPU local (Ryzen 7 7800)	Google Colab (GPU T4)	GPU local vía WSL2 (RTX 4070)
Rendimiento computacional	1	3	3
Memoria disponible	2	3	2
Soporte para frameworks	3	3	2
Disponibilidad	3	2	3
Costo	3	3	3
Facilidad de configuración	3	3	1
Total	15	17	14

De acuerdo con los resultados obtenidos, Google Colab resultó la opción con mejor puntaje total, al combinar un rendimiento computacional equivalente al de una GPU local con una configuración inmediata, sin costo y sin requerir instalación alguna en el equipo de trabajo. La GPU local mediante WSL2 queda contemplada como una posible mejora a futuro si las limitaciones de sesión y cuota dinámica de Colab llegaran a interferir con el desarrollo del proyecto.

3.6.2. Entorno de desarrollo integrado: Visual Studio Code

Visual Studio Code (VS Code) es un editor de código fuente liviano y extensible, desarrollado por Microsoft. Se utiliza para el desarrollo local de

los distintos scripts de Python que conforman el proyecto: extracción de fotografías, construcción del conjunto de datos, definición de las arquitecturas de los modelos y scripts de entrenamiento, aprovechando extensiones específicas para Python (resaltado de sintaxis, autocompletado, depuración integrada) que facilitan la iteración rápida sobre el código antes de ejecutar las etapas de mayor costo computacional en Google Colab.

3.6.3. Git y GitHub

Git es un sistema de control de versiones distribuido, y GitHub es la plataforma utilizada para alojar el repositorio del proyecto de forma remota. Se incorporan al flujo de trabajo para que los integrantes del equipo puedan colaborar sobre el mismo código de forma organizada, llevar un registro de los cambios realizados a lo largo del proceso iterativo de ajuste de las arquitecturas (por ejemplo, las sucesivas modificaciones a la arquitectura CNN-LSTM documentadas en este trabajo), y recuperar versiones anteriores del código en caso de que un cambio introduzca un error.

3.7. Librerías Especializadas

A continuación se detallan las bibliotecas de Python que cumplen funciones específicas dentro del pipeline de procesamiento de video y evaluación de los modelos, complementando a TensorFlow/Keras (sección 3.2) como herramientas de propósito más acotado.

3.7.1. YOLOv8n (Ultralytics)

YOLOv8n es la versión “nano” —la más liviana— de la familia de modelos YOLOv8 (You Only Look Once) para detección de objetos en tiempo real, distribuida a través de la biblioteca Ultralytics [06]. Se incorpora al pipeline de preprocesamiento para detectar y recortar al sujeto dentro de cada fotografía, antes de que este sea procesado por las arquitecturas de extracción de características.

Capítulo 4

Método

- 4.1. Tipo de investigación
- 4.2. Alcance de la investigación
- 4.3. Especificaciones de diseño y arquitectura del sistema
- 4.4. Obtención de datos
 - 4.4.1. Delimitación del estudio de los datos
 - 4.4.2. Selección de videos y fuentes
 - 4.4.3. Extracción de fotogramas por ventana de conducta
- 4.5. Preprocesamiento
 - 4.5.1. Normalización de imágenes
 - 4.5.2. Generación de secuencias de video
- 4.6. Diseño y entrenamiento del modelo
 - 4.6.1. Arquitectura CNN (capa espacial)
 - 4.6.2. Arquitectura LSTM (capa temporal)
 - 4.6.3. Integración del modelo CNN-LSTM
 - 4.6.4. Hiperparámetros de entrenamiento y ajuste
- 4.7. Evaluación del modelo
- 4.8. Desarrollo e integración de la aplicación

Capítulo 5

Resultados

- 5.1. Resultados del entrenamiento del modelo CNN-LSTM
- 5.2. Resultados de la evaluación del modelo
- 5.3. Resultados de las pruebas del sistema web

Capítulo 6

Discusión

- 6.1. Logros alcanzados
- 6.2. Solución del problema de investigación
- 6.3. Sugerencias para futuras investigaciones

Referencias bibliográficas

- [1] Ministerio de Salud Pública y Bienestar Social, “Protocolo para la atención del trastorno del espectro autista en paraguay,” 2023, [En línea]. Disponible: <https://www.mspbs.gov.py/dependencias/progsalud/adjunto/54eaa6-protocoloTEA.pdf>.
- [2] Congreso de la Nación Paraguaya, “Ley n° 6103 que crea el programa nacional de atención integral a los trastornos del espectro autista (PNAITEA),” Asunción, Paraguay, 2018.
- [3] Diario Hoy, “Autismo: Desafíos pendientes en diagnóstico, educación e inclusión laboral,” [En línea]. Disponible: <https://www.hoy.com.py/nacionales/2025/04/06/autismo-desafios-pendientes-en-diagnostico-educacion-e-inclusion-laboral>, 2025.
- [4] Poder Ejecutivo de la República del Paraguay, “Decreto n° 3624 por el cual se reglamenta la ley n° 6103/2018,” Asunción, Paraguay, 2020.
- [5] S. Russell y P. Norvig, *Artificial Intelligence: A Modern Approach*, 4th ed. Upper Saddle River, NJ: Pearson, 2020.
- [6] T. M. Mitchell, *Machine Learning*. New York, NY: McGraw-Hill, 1997.
- [7] I. Goodfellow, Y. Bengio, y A. Courville, *Deep Learning*. Cambridge, MA: MIT Press, 2016.
- [8] Z. Sherkatghanad *et al.*, “Automated detection of autism spectrum disorder using a convolutional neural network,” *Frontiers in Neurology*, vol. 10, p. 1325, 2020.
- [9] C. M. Bishop, *Pattern Recognition and Machine Learning*. New York, NY: Springer, 2006.
- [10] I. Goodfellow, Y. Bengio, y A. Courville, *Deep Learning*. MIT Press, 2016.

-
- [11] K. P. Murphy, *Machine Learning: A Probabilistic Perspective*. MIT Press, 2012.
- [12] World Health Organization, “Use of artificial intelligence in health care,” 2021.
- [13] “Machine learning aplicado a diagnóstico médico, diversos estudios en detección de TEA mediante análisis de video y comportamiento,” referencia genérica.
- [14] R. Szeliski, *Computer Vision: Algorithms and Applications*, 2nd ed. Cham, Suiza: Springer, 2022.
- [15] D. A. Forsyth y J. Ponce, *Computer Vision: A Modern Approach*, 2nd ed. Upper Saddle River, NJ: Pearson, 2011.
- [16] A. Voulodimos, N. Doulamis, A. Doulamis, y E. Protopapadakis, “Deep learning for computer vision: A brief review,” *Computational Intelligence and Neuroscience*, vol. 2018, p. Art. ID 7068349, 2018.
- [17] IBM Education, “What is computer vision?” [En línea]. Disponible: <https://www.ibm.com/topics/computer-vision>, 2023.
- [18] C. I. Orozco, M. E. Buemi, y J. J. Berlles, “CNN-LSTM con mecanismo de atención para el reconocimiento de acciones en video,” *Revista Elektron*, vol. 5, no. 1, pp. 37–44, 2021.
- [19] G. P. Martinsanz, P. J. H. Caro, y E. B. Porlas, *Aprendizaje profundo*. México: Alfaomega, 2018.
- [20] J. Patterson y A. Gibson, *Aprendizaje profundo: fundamentos y aplicaciones*. O’Reilly / Ediciones Paraninfo, 2024.
- [21] C. Bishop, *Reconocimiento de patrones y aprendizaje automático*. Springer, 2006.
- [22] ISO/IEC, “Systems and software engineering — systems and software quality requirements and evaluation (SQuaRE) — system and software quality models,” 2011, iSO/IEC 25010:2011.
- [23] L. Bass, P. Clements, y R. Kazman, *Software Architecture in Practice*, 3rd ed. Addison-Wesley Professional, 2012.
- [24] World Health Organization (WHO), “Ethics and governance of artificial intelligence for health,” Ginebra, 2021.

-
- [25] C. Ware, *Information Visualization: Perception for Design*, 3rd ed. Morgan Kaufmann, 2013.
- [26] NVIDIA Corporation, “GeForce RTX 4070 Family,” 2023, [En línea]. Disponible: <https://www.nvidia.com/en-us/geforce/graphics-cards/40-series/rtx-4070/>. [Accedido: 24-sep-2026].
- [27] Advanced Micro Devices, Inc., “AMD Ryzen 7 7800X3D,” 2023, [En línea]. Disponible: <https://www.amd.com/en/products/processors/desktops/ryzen/7000-series/amd-ryzen-7-7800x3d.html>. [Accedido: 24-sep-2026].
- [28] K. He, X. Zhang, S. Ren, y J. Sun, “Deep residual learning for image recognition,” in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, Las Vegas, NV, EE.UU., 2016, pp. 770–778.
- [29] A. Dosovitskiy *et al.*, “An image is worth 16x16 words: Transformers for image recognition at scale,” arXiv:2010.11929, 2020.
- [30] E. Bisong, “Google Colaboratory,” in *Building Machine Learning and Deep Learning Models on Google Cloud Platform*. Berkeley, CA, EE.UU.: Apress, 2019, pp. 59–64.
- [31] Instituto de Previsión Social, “Datos sobre el trastorno del espectro autista en paraguay,” 2024, [En línea]. Disponible: <https://portal.ips.gov.py/sistemas/ipsportal/noticia.php?cod=2999>.
- [32] C. A. y V. Ruggieri, “Autismo. aspectos genéticos y biológicos,” *Medicina*, vol. 79, no. Supl. 1, pp. 16–21, 2019.
- [33] Organización Mundial de la Salud, “Trastornos del espectro autista,” Hoja informativa, 2024, [En línea]. Disponible: <https://www.who.int/es/news-room/fact-sheets/detail/autism-spectrum-disorders>.
- [34] Naciones Unidas, “Transformar nuestro mundo: la agenda 2030 para el desarrollo sostenible,” 2015, [En línea]. Disponible: <https://sdgs.un.org/goals>.
- [35] A. Vaswani *et al.*, “Attention is all you need,” arXiv, 2024, [En línea]. Disponible: <https://arxiv.org/html/2408.16924v1>.
- [36] G. I. M. Pintle, “Análisis de patrones gestuales para la identificación del trastorno del espectro autista mediante interfaces elásticas,” Master’s thesis, Centro de Investigación Científica y de Educación Superior de

Ensenada, Ensenada, Mexico, 2018, [En línea]. Disponible: https://cicese.repositorioinstitucional.mx/jspui/bitstream/1007/2441/1/tesis_Monarca%20Pintle_Gloria%20Ivonne_05_sep_2018B.pdf.

- [37] —, “Detección de comportamientos repetitivos en niños con autismo mediante visión artificial,” Master’s thesis, CICESE, México, 2018, [En línea]. Disponible: https://cicese.repositorioinstitucional.mx/jspui/bitstream/1007/2441/1/tesis_Monarca%20Pintle_Gloria%20Ivonne_05_sep_2018B.pdf.