Universidad Nacional del Este.
Facultad Politécnica.



Sistema web para identificar patrones de motricidad relacionados con TEA, mediante arquitectura CNN-LSTM

Bella Luz Benítez González.
Martin Escobar Azcona.

Año 2026.

Universidad Nacional del Este.
Facultad Politécnica.

Carrera Ingeniería de Sistemas.
Cátedra Trabajo Final de Grado 2.

Sistema web para identificar patrones de motricidad relacionados con TEA, mediante arquitectura CNN LSTM.

Por: **Bella Luz Benítez González y Martin Escobar Azcona.**

Profesor Orientador: **Ing. Katia Andrea Ayala.**

Trabajo final de grado presentado a la Facultad Politécnica de la Universidad Nacional del Este como parte de los requisitos para optar al título Ingeniero de sistemas.

Ciudad del Este, Alto Paraná. Paraguay.

2026

FICHA CATALOGRÁFICA
BIBLIOTECA DE LA FACULTAD POLITÉCNICA
DE LA UNIVERSIDAD NACIONAL DEL ESTE

Benítez González, Bella
Luz, 2001.
Escobar Azcona, Martin
2001.
Sistema web para identificar patrones de motricidad relacionados con TEA, mediante arquitectura CNN LSTM.
Orientador: Ing. Katia Andrea Ayala Díaz.
Ciudad del Este, Alto Paraná. Año: 2026.
Páginas:

Área de estudio: Aprendizaje Profundo y Visión por Computadora.
Carrera: Ingeniería de Sistemas.
Titulación: Ingeniero de Sistemas.
Trabajo Final de Grado. Universidad Nacional del Este,
Facultad Politécnica.

Descriptores: 1. Trastorno del espectro autista (TEA), 2. Patrones de motricidad, 3. Arquitectura CNN-LSTM.
Web system for identifying motor patterns related to ASD using CNN-LSTM architecture.
Key words: 1. Autism spectrum disorder (ASD), 2. Motor patterns
3. CNN-LSTM architecture.

Yo, <nombre del Profesor Orientador>, documento de identidad No. <No. de documento de identidad del Profesor Orientador>, Profesor Orientador del TFG titulado "<*título del TFG*>", del Alumno <nombre del Alumno>, documento de identidad No. <No. de documento de identidad del Alumno>, de la carrera <nombre de la carrera> de la Facultad Politécnica de la Universidad Nacional del Este; certifico que el mencionado Trabajo Final de Grado ha sido realizado por dicho Alumno, de lo cual doy fe y en mi opinión reúne las condiciones para su presentación y defensa ante la Mesa Examinadora designada por la institución.

<fecha>

_____

<nombre del Profesor Orientador>

Nosotros, los miembros de la Mesa Examinadora del Trabajo Final de Grado titulado "<*título del TFG*>", de la carrera <nombre de la carrera> de la Facultad Politécnica de la Universidad Nacional del Este, hacemos constar que el citado trabajo ha sido evaluado en fondo y forma por esta Mesa, la que por _____ ha resuelto asignar la calificación _____

Ciudad del Este, ____ de _____ de 2014

_____

Profesor _____
Presidente de la Mesa Examinadora

_____	_____
Profesor _____	Profesor _____
Miembro de la Mesa Examinadora	Miembro de la Mesa Examinadora

Escribir aquí la dedicatoria.
Su extensión no debería exceder de una página.

<Escribir aquí los agradecimientos.>
<Su extensión no debería exceder de una página.>

<Escribir aquí el epígrafe (frase u oración favorita).>
<Su extensión no debería exceder de una página.>

Resumen

...

Descriptores: 1. <descriptor1>, 2. <descriptor2>, 3. <descriptor3>.

Abstract

...

Key words: 1. <keyword1>, 2. <keyword2>, 3. <keyword3>.

Índice general

Resumen ix

Abstract x

Índice de figuras xiv

Índice de tablas xv

Acrónimos y símbolos xv

1. Introducción 1
- 1.1. Motivación . . . 2
- 1.2. Definición del problema . . . 2
- 1.3. Objetivos . . . 4
  - 1.3.1. Objetivo General . . . 4
  - 1.3.2. Objetivos Específicos . . . 4
- 1.4. Hipótesis . . . 5
- 1.5. Justificación . . . 5
- 1.6. Delimitación del alcance del trabajo . . . 6
- 1.7. Descripción de los contenidos por capítulo . . . 8

2. Conceptos fundamentales, teorías y antecedentes 10
- 2.1. Conceptos fundamentales . . . 10
  - 2.1.1. Trastorno del espectro autista . . . 10
  - 2.1.2. El Contexto de la Salud Pediátrica en Paraguay . . . 13
  - 2.1.3. Inteligencia Artificial . . . 14
    - 2.1.3.1. Definición y fundamentos . . . 14
    - 2.1.3.2. Ramas de la IA aplicadas a la ingeniería . . . 14
  - 2.1.4. Aprendizaje automático . . . 14
    - 2.1.4.1. Definición y fundamentos . . . 14
    - 2.1.4.2. Aprendizaje supervisado . . . 15
    - 2.1.4.3. Aplicación en diagnóstico clínico . . . 15

2.1.5. Visión artificial 16
2.1.5.1. Definición y evolución 16
2.1.5.2. Aplicación en análisis de comportamiento . . 16
2.1.6. Arquitectura Híbrida CNN-LSTM para Reconocimiento de Patrones 16
2.1.6.1. Fundamentos de la Combinación Espacio-Temporal 16
2.1.6.2. Extracción de Características con CNN (Capa Espacial) 17
2.1.6.3. Procesamiento de Secuencias con LSTM (Capa Temporal) 17
2.1.6.4. Flujo de Datos y Clasificación de Patrones de motricidad 17
2.1.7. Diseño web 18
2.1.7.1. Interfaz de Usuario y Arquitectura de Integración Web 18
2.1.7.2. Arquitectura del Lado del Cliente (Frontend) 18
2.1.8. Comunicación y Servicios de Red (Backend) 19
2.1.8.1. Gestión de Seguridad y Privacidad de Datos . 19
2.1.8.2. Visualización de Resultados y Diseño de Interacción 20
2.2. Antecendentes 20

3. Tecnologías utilizadas 24
3.1. Componentes de Hardware 24
3.1.1. Tarjeta gráfica: NVIDIA GeForce RTX 4070 24
3.1.2. Procesador: AMD Ryzen 7 7800X3D 26
3.2. Componentes de Software 26
3.2.1. Arquitecturas para la extracción de características . . . 26
3.3. Tecnologías del Frontend 29
3.3.1. Next.js 31
3.3.2. React 31
3.3.3. TypeScript 31
3.3.4. Tailwind CSS 32
3.3.5. Recharts 32
3.3.6. Axios 32
3.4. Tecnologías del Backend 32
3.4.1. FastAPI 33
3.4.2. Uvicorn 33
3.4.3. Pydantic 33
3.4.4. python-multipart 33
3.4.5. TensorFlow / Keras (motor de inferencia) 33

3.4.6. OpenCV (preprocesamiento en el backend) 34
3.4.7. python-jose 34
3.5. Servicios en la Nube 34
3.5.1. Google Drive 34
3.5.2. Firebase Firestore 35
3.6. Herramientas de Desarrollo 35
3.6.1. Entorno de cómputo: Google Colaboratory 35
3.6.2. Entorno de desarrollo integrado: Visual Studio Code . 37
3.6.3. Git y GitHub 37
3.7. Librerías Especializadas 37
3.7.1. YOLOv8n (Ultralytics) 37
3.7.2. CLAHE (OpenCV) 38
3.7.3. NumPy 38
3.7.4. scikit-learn 38

4. Método **39**
4.1. Tipo de investigación 39
4.2. Alcance de la investigación 39
4.3. Especificaciones de diseño y arquitectura del sistema 39
4.4. Obtención de datos 42
4.4.1. Delimitación del estudio de los datos 42
4.4.2. Selección de videos y fuentes 42
4.4.3. Criterios de selección, exclusión y verificación de los videos 43
4.4.4. Extracción de fotogramas por ventana de conducta . . 45
4.5. Preprocesamiento 46
4.5.1. Normalización de imágenes 46
4.5.2. Generación de secuencias de video 48
4.6. Diseño y entrenamiento del modelo 50
4.6.1. Extractor espacial: ResNet50 (capa espacial) 50
4.6.2. Extractor alternativo: CNN propia (desde cero) 53
4.6.3. Arquitectura LSTM (capa temporal) 54
4.6.4. Integración del modelo y selección de la arquitectura . 54
4.6.5. Hiperparámetros de entrenamiento y épocas 55
4.7. Evaluación del modelo 58
4.8. Desarrollo e integración de la aplicación web 59
4.8.1. Análisis de requisitos 59
4.8.2. Arquitectura tecnológica 60
4.8.3. Integración del modelo 60
4.8.4. Interfaz de usuario 60
4.8.5. Protección de datos y validación 62

4.9. Diseño de pruebas 62

5. Resultados **60**
5.1. Resultados de la evaluación de los modelos 60
5.2. Resultados de las pruebas del sistema web. 65

6. Discusión **66**
6.1. Logros alcanzados 66
6.2. Solución del problema de investigación 68
6.2.1. Análisis de las métricas de los modelos 68
6.2.2. Limitaciones del trabajo 69
6.3. Sugerencias para futuras investigaciones 70

Glosario **75**

Anexos **75**

Referencias bibliográficas **76**

Índice de figuras

3.1. Tarjeta gráfica NVIDIA GeForce RTX 4070. 25

4.1. Arquitectura funcional para el prototipo web de apoyo a la identificación de patrones de motricidad. 41
4.2. Flujo de preprocesamiento: de la ventana anotada al tensor de entrada del modelo. 46
4.3. Efecto de cada etapa del preprocesamiento sobre dos fotogramas de un video de *HeadBanging* ($t = 11$ y $t = 31$). De izquierda a derecha: original, tras CLAHE, normalizado a 64×64 con valores en $[0, 1]$, ampliado a 224×224 (entrada de la ResNet50) y tras la normalización de ImageNet. *Reescalada solo para su visualización. 48
4.4. Secuencia de 40 fotogramas de 64×64 píxeles generada para un video de *HeadBanging* (lectura de izquierda a derecha y de arriba abajo, $t = 1, \ldots, 40$). 49
4.5. Aumento de datos por reflexión horizontal: fotogramas de una secuencia original (arriba) y su versión especular (abajo). . . . 50
4.6. Diagrama de flujo del proceso de entrenamiento y evaluación. . 52
4.7. Arquitectura CNN-LSTM propia, entrenada desde cero (modelo de referencia). 54
4.8. Definición de hiperparámetros y parámetros en el archivo de configuración (`config.py`). 57
4.9. Pantalla de inicio del prototipo. 61
4.10. Paso 1 del análisis: carga del video. 61
4.11. Paso 2 del análisis: resultado preliminar con nivel de confianza. 62

5.1. Matriz de confusión del modelo CNN. 63
5.2. Matriz de confusión del modelo ResNet50 + LSTM. 64

Índice de Tablas

2.1. Signos de alarma de alteración del desarrollo [1] 12

3.1. Comparación de arquitecturas de modelos de inteligencia artificial. 29
3.2. Comparativa de herramientas seleccionadas. 30
3.3. Comparativa de entornos de cómputo 36

4.1. Distribución de videos y fotogramas por categoría. 44
4.2. División de los videos en entrenamiento, validación y prueba. . 45
4.3. Arquitecturas evaluadas. 51
4.4. Capas del extractor CNN propio (por fotograma). 53
4.5. Capas del modelo ResNet50 + LSTM. 55
4.6. Hiperparámetros de entrenamiento (comunes a ambos modelos). 56
4.7. Requisitos y características del prototipo. 59
4.8. Diseño de pruebas del sistema. 63

5.1. Métricas de evaluación para ResNet50 + LSTM 60
5.2. Métricas de evaluación para CNN 61
5.3. Comparación de métricas entre CNN y ResNet50 + LSTM . . 61

Capítulo 1

Introducción

El trastorno del espectro autista (TEA) es una condición del neurodesarrollo que puede manifestarse desde las primeras etapas de la vida y presentar características que varían entre cada individuo. Entre sus posibles manifestaciones se encuentran determinados patrones de motricidad y movimientos repetitivos, los cuales pueden ser observados durante diferentes actividades y situaciones [1].

La identificación de estas manifestaciones forma parte de los procesos de evaluación del TEA y requiere la participación de profesionales especializados. La detección oportuna puede facilitar el acceso temprano a evaluaciones, orientaciones y apoyos adecuados, aspectos que pueden favorecer el desarrollo y bienestar del niño. En este sentido, el uso de herramientas que contribuyan al reconocimiento de patrones observables puede representar un apoyo dentro de estos procesos.

En este contexto, el presente Trabajo Final de Grado propone el desarrollo de un sistema web orientado a la identificación de patrones de motricidad relacionados con el TEA mediante el análisis de secuencias de video. El sistema considera tres patrones de interés: el aleteo de manos, el balanceo corporal y los movimientos repetitivos de cabeza. Para ello, se plantea el empleo de una arquitectura CNN-LSTM, capaz de extraer características de los fotogramas y considerar su evolución a lo largo de una secuencia.

La propuesta se plantea como una herramienta de apoyo a los procesos de evaluación, sin sustituir la valoración de profesionales especializados ni emitir un diagnóstico clínico definitivo. A través de este desarrollo se busca explorar el potencial de las técnicas de aprendizaje profundo para contribuir a la identificación de manifestaciones observables asociadas al TEA y favorecer el acceso oportuno a procesos de evaluación y apoyo.

1.1. Motivación

La motivación que condujo a seleccionar el tema y emprender la investigación surge de la importancia de la detección temprana del Trastorno del Espectro Autista (TEA) y de la necesidad de contar con herramientas que puedan apoyar este proceso. El TEA puede manifestarse desde edades tempranas mediante diferentes características conductuales y patrones de motricidad, entre los que se encuentran movimientos repetitivos como el aleteo de manos, el balanceo corporal y los movimientos repetitivos de cabeza.

La identificación de estas manifestaciones puede aportar información relevante durante los procesos de evaluación del desarrollo infantil. Sin embargo, su reconocimiento requiere observación y valoración por parte de profesionales especializados. En este sentido, surge el interés por desarrollar una herramienta que permita identificar determinados patrones de motricidad a partir de secuencias de video, como apoyo a la evaluación.

Desde una perspectiva académica, el desarrollo de esta investigación permite aplicar conocimientos adquiridos durante la formación en Ingeniería de Sistemas en una problemática relacionada con el área de la salud y el desarrollo infantil. Además, posibilita la integración de conocimientos relacionados con el procesamiento de imágenes, aprendizaje profundo y desarrollo de aplicaciones web para abordar una necesidad concreta.

Desde una perspectiva social, la propuesta se encuentra motivada por la posibilidad de contribuir a una detección más oportuna de señales asociadas al TEA. Una identificación temprana puede favorecer el acceso de los niños a evaluaciones especializadas y a los apoyos adecuados según sus necesidades, contribuyendo a su desarrollo, bienestar y calidad de vida, así como brindando orientación a sus familias.

Finalmente, el desarrollo de un sistema web para identificar patrones de motricidad relacionados con el TEA mediante una arquitectura CNN-LSTM representa una oportunidad para aplicar la tecnología en beneficio de los procesos de evaluación, proporcionando una herramienta de apoyo que no pretende sustituir la valoración profesional ni emitir un diagnóstico clínico definitivo.

1.2. Definición del problema

El Trastorno del Espectro Autista (TEA) es una condición del neurodesarrollo caracterizada por dificultades en la comunicación social, la interacción social y la presencia de patrones de comportamiento restringidos o repetitivos. Estas manifestaciones pueden observarse desde los primeros años de vida

y suelen evidenciarse a través de señales conductuales como escaso contacto visual, dificultades en la comunicación, ausencia de respuesta al nombre, movimientos repetitivos, intereses restringidos o conductas estereotipadas. La identificación temprana de estas características es fundamental, ya que permite iniciar intervenciones oportunas que favorecen el desarrollo cognitivo, social y comunicativo de los niños [2].

En Paraguay, el Trastorno del Espectro Autista representa un desafío creciente para el sistema de salud y para las familias. De acuerdo con información difundida por el Instituto de Previsión Social, se estima que entre 45.000 y 133.000 personas podrían encontrarse dentro del espectro autista en el país, lo que evidencia la necesidad de fortalecer las estrategias de detección y atención temprana [3].

Muchos padres o cuidadores acuden a consulta cuando observan señales conductuales en sus hijos, tales como juego solitario, dificultades en la interacción social, rigidez en el comportamiento, caminar en puntillas, aleteo de manos o movimientos repetitivos. Estas señales pueden manifestarse desde edades tempranas y constituyen indicadores relevantes para la evaluación del desarrollo infantil [1].

A pesar de los avances en protocolos de atención y en la concienciación sobre el autismo, diversos estudios señalan que el TEA ha sido históricamente subdiagnosticado, y que en muchos casos el diagnóstico formal se realiza varios años después de la aparición de los primeros signos. En América Latina, los síntomas suelen identificarse alrededor de los 18 meses de edad; sin embargo, el diagnóstico definitivo puede confirmarse aproximadamente a los cuatro años, lo que retrasa el inicio de intervenciones especializadas.

En Paraguay, el protocolo nacional para la atención del Trastorno del Espectro Autista recomienda la vigilancia del desarrollo infantil mediante evaluaciones periódicas y la identificación de signos de alerta en edades tempranas, con el fin de facilitar la derivación oportuna a servicios especializado. No obstante, en la práctica pueden existir dificultades para sistematizar la observación de conductas, registrar adecuadamente los patrones de motricidad y apoyar el proceso de evaluación clínica con herramientas tecnológicas que permitan analizar de manera más objetiva las manifestaciones conductuales.

En este contexto, surge la necesidad de explorar herramientas basadas en aprendizaje automático que permitan reconocer patrones de motricidad asociados al Trastorno del Espectro Autista, con el propósito de brindar apoyo al proceso de evaluación temprana realizado por profesionales de la salud. Estas herramientas no pretenden reemplazar el diagnóstico clínico, sino contribuir a la identificación temprana de señales conductuales relevantes que puedan facilitar la toma de decisiones en el ámbito clínico y educativo.

Por tanto, se define como problema de investigación del TFG propues-

to la necesidad de desarrollar un sistema web para identificar patrones de motricidad relacionados con TEA, mediante el empleo de una arquitectura CNN-LSTM.

1.3. Objetivos

1.3.1. Objetivo General

Desarrollar un sistema web de apoyo al diagnóstico del TEA mediante el empleo de una arquitectura CNN-LSTM capaz de identificar patrones de motricidad a partir del análisis de secuencias de video.

1.3.2. Objetivos Específicos

1. Adquirir conocimiento sobre la tecnología CNN-LSTM aplicada a la identificación de patrones de motricidad asociados al TEA, mediante el estudio de redes neuronales convolucionales y redes de memoria a largo y corto plazo.

2. Recolectar datos de motricidad asociados al TEA mediante la selección y organización de secuencias de video que presenten patrones de aleteo de manos, balanceo corporal y movimientos repetitivos de cabeza.

3. Diseñar la arquitectura de un modelo basado en redes neuronales CNN-LSTM para el reconocimiento de patrones de motricidad asociados al TEA, considerando la extracción de características espaciales y el procesamiento de la información temporal.

4. Preprocesar los fotogramas obtenidos de las secuencias de video mediante técnicas de normalización, organización y generación de secuencias, posibilitando la extracción de características relevantes para el modelo.

5. Entrenar el modelo CNN-LSTM utilizando los datos previamente preparados, con el propósito de aprender las características espaciales y temporales asociadas a los patrones de motricidad seleccionados.

6. Evaluar el desempeño del modelo mediante métricas de clasificación, considerando su capacidad para identificar los patrones de motricidad asociados al TEA.

7. Elaborar una plataforma web que integre el modelo CNN-LSTM, incorporando las funcionalidades necesarias para la carga de secuencias de video, procesamiento e identificación de los patrones de motricidad.

8. Validar el funcionamiento del sistema mediante pruebas de identificación de patrones de motricidad asociados al TEA, considerando el procesamiento de videos y la generación de resultados.

1.4. Hipótesis

El algoritmo propuesto, que implementa arquitectura CNN-LSTM, para detectar tempranamente trastorno del espectro autista, basado en patrones de motricidad identificados en secuencias de video, tendría eficiencia en la detección, al menos igual a 85 %, según referente humano experto.

1.5. Justificación

En el contexto actual de la atención relacionada con el Trastorno del Espectro Autista (TEA), donde la identificación oportuna de sus manifestaciones puede favorecer el acceso temprano a evaluación y apoyo especializado, el desarrollo de herramientas tecnológicas representa una oportunidad para contribuir a los procesos de detección. El TEA puede presentar diversas manifestaciones conductuales y patrones de motricidad que pueden ser observados desde edades tempranas, entre ellos el aleteo de manos, el balanceo corporal y los movimientos repetitivos de cabeza.

Este trabajo se justifica por la necesidad de explorar alternativas que permitan apoyar la identificación de estos patrones mediante el análisis de secuencias de video. La observación de movimientos repetitivos puede requerir el análisis de diferentes momentos y situaciones, por lo que una herramienta capaz de procesar información audiovisual podría facilitar la identificación de determinadas manifestaciones y proporcionar información complementaria durante los procesos de evaluación realizados por profesionales especializados.

La propuesta busca contribuir en los siguientes aspectos:

- Facilitar la identificación de determinados patrones de motricidad relacionados con el TEA a partir de secuencias de video.

- Proporcionar una herramienta de apoyo que contribuya al proceso de evaluación de manifestaciones observables asociadas al TEA.

- Favorecer una identificación más oportuna de señales que puedan motivar una evaluación especializada.
- Contribuir al desarrollo de herramientas tecnológicas aplicadas al análisis de manifestaciones relacionadas con el desarrollo infantil.
- Generar una base para futuras investigaciones sobre el reconocimiento automatizado de patrones de motricidad asociados al TEA mediante inteligencia artificial.

Desde una perspectiva académica y tecnológica, el desarrollo del sistema permite aplicar técnicas de aprendizaje profundo para el análisis de secuencias de video, integrando una arquitectura CNN-LSTM en una plataforma web. Esto posibilita abordar una problemática relacionada con el área de la salud mediante conocimientos propios de la Ingeniería de Sistemas y explorar la aplicación de inteligencia artificial en el reconocimiento de patrones de motricidad.

Desde una perspectiva social, la propuesta adquiere relevancia debido a que una identificación más oportuna de determinadas señales asociadas al TEA puede favorecer el acceso temprano a procesos de evaluación y a los apoyos correspondientes según las necesidades de cada niño. De esta manera, el sistema busca constituirse como una herramienta complementaria que pueda contribuir indirectamente al bienestar y desarrollo infantil, sin sustituir la evaluación de profesionales especializados ni emitir un diagnóstico clínico definitivo.

En síntesis, este trabajo busca integrar conocimientos académicos y tecnológicos para abordar una problemática relacionada con la identificación de manifestaciones del TEA, mediante el desarrollo de una herramienta web orientada al reconocimiento de patrones de motricidad a partir de secuencias de video, procurando aportar al fortalecimiento de los procesos de evaluación y a la detección oportuna de señales relevantes.

1.6. Delimitación del alcance del trabajo

La investigación se centra en el desarrollo de un prototipo de sistema web orientado a la identificación de patrones de motricidad relacionados con el Trastorno del Espectro Autista (TEA), mediante el análisis de secuencias de video y el empleo de una arquitectura CNN-LSTM. El trabajo contempla la identificación de tres patrones de motricidad visualmente observables: aleteo de manos, balanceo corporal y movimientos repetitivos de cabeza.

El estudio se establece considerando las siguientes delimitaciones específicas:

Delimitación temática: El trabajo se limita a la identificación de los tres patrones de motricidad mencionados, sin abarcar otras manifestaciones conductuales, características clínicas, trastornos del neurodesarrollo u otras condiciones médicas. El análisis se centra exclusivamente en patrones que puedan ser observados visualmente en secuencias de video.

Delimitación de los datos: Los datos utilizados para el desarrollo del modelo corresponden a secuencias de video obtenidas de fuentes de acceso público, principalmente plataformas audiovisuales, así como a videos de recolección propia. Los videos serán seleccionados de acuerdo con los patrones de motricidad definidos y organizados mediante etiquetado manual para su posterior procesamiento, entrenamiento y evaluación del modelo.

Delimitación tecnológica: La investigación se limita al empleo de una arquitectura CNN-LSTM, utilizando una red neuronal convolucional (CNN) para la extracción de características espaciales de los fotogramas y una red LSTM para el procesamiento de la información temporal presente en las secuencias. No se contempla una comparación exhaustiva con otras arquitecturas de aprendizaje profundo.

Delimitación del análisis: El procesamiento se realizará exclusivamente sobre información visual obtenida de secuencias de video. No se contemplan señales de audio, cuestionarios clínicos, entrevistas, antecedentes médicos, historial clínico ni otras variables utilizadas en procesos de diagnóstico del TEA.

Delimitación geográfica: El trabajo se desarrolla en el contexto académico y tecnológico de Paraguay, considerando datos audiovisuales disponibles públicamente y material de recolección propia. El prototipo no contempla una validación clínica a nivel nacional ni la implementación del sistema en instituciones de salud.

Delimitación temporal: El desarrollo del prototipo, la preparación de los datos, el entrenamiento del modelo, la integración con la plataforma web y las pruebas de funcionamiento se realizarán durante el período establecido para el desarrollo del Trabajo Final de Grado.

La validación se limitará a la evaluación del desempeño técnico del modelo mediante métricas de clasificación y a pruebas de funcionamiento del sistema. Los resultados obtenidos no serán considerados como un diagnóstico clínico de TEA ni sustituirán la evaluación realizada por profesionales especializados.

En síntesis, la investigación establece como límite el desarrollo y evaluación de un prototipo web capaz de identificar determinados patrones de motricidad asociados al TEA a partir de secuencias de video, constituyendo una herramienta de apoyo que podrá servir como base para futuras investi-

gaciones y desarrollos orientados a la detección temprana de manifestaciones relacionadas con el trastorno.

1.7. Descripción de los contenidos por capítulo

El Capítulo 2: Conceptos fundamentales, teorías y antecedentes desarrolla el marco teórico y conceptual de la investigación, presentando los principales conceptos relacionados con el Trastorno del Espectro Autista (TEA), sus características y los patrones de motricidad asociados. Asimismo, se abordan los fundamentos de la Inteligencia Artificial, el aprendizaje automático y el aprendizaje profundo, junto con los conceptos de visión artificial y procesamiento de imágenes y secuencias de video. También se presentan las redes neuronales convolucionales (CNN), las redes neuronales recurrentes (RNN), las redes LSTM y la arquitectura híbrida CNN-LSTM utilizada para el reconocimiento de patrones de motricidad. Finalmente, se incluyen antecedentes de investigaciones relacionadas con el uso de inteligencia artificial y análisis de video en el estudio del TEA.

El Capítulo 3: Tecnologías utilizadas presenta las herramientas y componentes empleados para el desarrollo del sistema. Se describen los recursos de hardware utilizados durante el desarrollo y entrenamiento del modelo, así como las tecnologías de software empleadas. También se detallan las herramientas utilizadas para el procesamiento de videos e imágenes, el desarrollo del modelo CNN-LSTM y la implementación de la plataforma web. Se incluyen las tecnologías utilizadas para el frontend, backend, servicios REST y las bibliotecas necesarias para la integración del modelo de inteligencia artificial.

El Capítulo 4: Método describe el proceso metodológico empleado para el desarrollo de la investigación. Se presenta el enfoque y alcance del estudio, así como el diseño utilizado para el desarrollo de la solución propuesta. Se detalla el proceso de selección, organización y etiquetado de los videos, el preprocesamiento mediante extracción de fotogramas y normalización de imágenes, el diseño y desarrollo de la arquitectura CNN-LSTM, el entrenamiento y evaluación del modelo, y finalmente su integración en la plataforma web.

El Capítulo 5: Resultados presenta los resultados obtenidos durante el desarrollo y evaluación del sistema. Se incluyen los resultados del procesamiento y entrenamiento del modelo CNN-LSTM, así como las métricas utilizadas para evaluar su desempeño. También se presentan los resultados de las pruebas de funcionamiento del sistema, incluyendo la clasificación de

los patrones de motricidad definidos: aleteo de manos, balanceo corporal y movimientos repetitivos de cabeza. Además, se muestran los resultados de la integración del modelo en la plataforma web y las pruebas relacionadas con su funcionamiento y rendimiento.

El Capítulo 6: Discusión analiza e interpreta los resultados obtenidos durante la investigación, relacionándolos con los objetivos planteados y los antecedentes estudiados. Se analizan los resultados obtenidos por el modelo CNN-LSTM y su capacidad para reconocer los patrones de motricidad considerados. También se abordan las limitaciones encontradas durante el desarrollo, los principales aportes de la investigación y las posibles mejoras y líneas de trabajo futuro relacionadas con el uso de inteligencia artificial y análisis de video como herramienta de apoyo para la evaluación de patrones de motricidad asociados al TEA.

Capítulo 2

Conceptos fundamentales, teorías y antecedentes

En este capítulo se desarrolla el marco teórico, conceptual y referencial de la investigación. Se presentan los conceptos relacionados con el TEA, la inteligencia artificial, el aprendizaje profundo, la visión artificial y la arquitectura CNN-LSTM. Finalmente, se incluyen antecedentes de investigaciones relacionadas con algunos de los enfoques y tecnologías utilizados en el desarrollo del proyecto.

2.1. Conceptos fundamentales

2.1.1. Trastorno del espectro autista

El Trastorno del Espectro Autista es comprendido actualmente como una condición del neurodesarrollo de base neurobiológica y genética que se manifiesta en los primeros años de vida. De acuerdo con el Ministerio de Salud Pública y Bienestar Social, esta condición se define por una organización atípica de las funciones cerebrales que impacta severamente en la capacidad de comunicación social y en la flexibilidad del pensamiento y la conducta [1]. El marco técnico nacional destaca que la transición hacia el concepto de "espectro" permite integrar bajo un mismo paraguas clínico una amplia diversidad de manifestaciones. No obstante, todas comparten dos dimensiones nucleares: las deficiencias persistentes en la comunicación y la interacción social en diversos contextos, y la presencia de patrones de motricidad, intereses o actividades restrictivas y repetitivas [1]. En Paraguay, se enfatiza que el TEA no es una enfermedad que requiera una "cura", sino una condición de vida que demanda apoyos específicos y ajustes del entorno para garantizar

el ejercicio pleno de derechos de la persona [4].

Síntomas del Trastorno del Espectro Autista

Uno de los principales grupos de síntomas del TEA corresponde a las dificultades en la interacción social. Estas pueden manifestarse como una limitada capacidad para establecer relaciones con otras personas, escaso contacto visual, dificultad para comprender normas sociales y poca respuesta emocional hacia los demás. En Paraguay, especialistas señalan que estas dificultades pueden observarse desde la infancia, incluyendo la falta de apego o la escasa búsqueda de atención por parte de los cuidadores [5].

Otro conjunto importante de síntomas se relaciona con la comunicación. Las personas con TEA pueden presentar retrasos en el desarrollo del lenguaje, dificultades para iniciar o mantener conversaciones, o utilizar formas atípicas de comunicación como la ecolalia (repetición de palabras o frases). En algunos casos, incluso pueden no responder a estímulos verbales, lo que genera la percepción errónea de problemas auditivos .

Asimismo, el TEA se caracteriza por la presencia de comportamientos repetitivos e intereses restringidos. Estos pueden incluir movimientos estereotipados, como girar sobre sí mismos o manipular objetos de forma repetitiva, así como una fuerte resistencia a los cambios en la rutina. Esta rigidez conductual puede generar ansiedad intensa ante situaciones nuevas o imprevistas.

Otro aspecto relevante dentro de los síntomas es la alteración en el procesamiento sensorial. Las personas con TEA pueden mostrar hipersensibilidad o hiposensibilidad a estímulos como sonidos, luces, texturas o dolor. Esto puede influir en su comportamiento diario, generando respuestas inusuales o evitación de ciertos entornos

Es importante destacar que los síntomas del TEA aparecen en las primeras etapas del desarrollo, generalmente antes de los 2 o 3 años de edad, aunque en algunos casos pueden hacerse más evidentes cuando las demandas sociales aumentan. En Paraguay, se ha observado que la detección suele ser tardía en comparación con otros países, lo que puede retrasar la intervención temprana y afectar el desarrollo del niño .

Finalmente, cabe resaltar que el TEA es un espectro, lo que significa que los síntomas varían ampliamente en tipo e intensidad entre individuos. Algunas personas pueden presentar síntomas leves y llevar una vida relativamente independiente, mientras que otras requieren apoyo significativo. Esta variabilidad hace necesario un enfoque diagnóstico individualizado y multidisciplinario [1].

Se describen signos de alarma para sospechar alteraciones del desarrollo

infantil, los cuales pueden ser identificados en diferentes etapas tempranas de la vida (ver Tabla 1).

Tabla 2.1: Signos de alarma de alteración del desarrollo [1]

EDAD	**ALARMA**
6 MESES	No trata de agarrar cosas que están a su alcance, no mira a la madre durante la lactancia. No demuestra afecto por quienes le cuidan. No reacciona ante los sonidos a su alrededor. Tiene dificultad para llevarse cosas a la boca. No emite sonidos (vocales: “a”, “e”, “o”). No gira en ninguna dirección (rueda). No se ríe ni hace sonidos de placer al ser estimulado por sus cuidadores frecuentes. Se ve rígido y con los músculos tensos. Se ve sin fuerza como un muñeco de trapo.
12 MESES	No gatea. No puede permanecer de pie con ayuda. No busca un objeto que se le esconde. No dice palabras sencillas como “mamá” o “papá”. No aprende a usar gestos como saludar con la mano o mover la cabeza. No señala cosas.
18 MESES	Pierde habilidades que había adquirido. No señala cosas para mostrarlas a otras personas. No puede caminar solo. No sabe para qué sirven las cosas familiares. No imita lo que hacen las demás personas. No aprende nuevas palabras. No sabe por lo menos 6 palabras. No se da cuenta ni parece importarle si la persona que le cuida se va o regresa.
2 AÑOS	Pierde habilidades que había adquirido. No usa frases de dos palabras. No conoce el uso de objetos cotidianos. No imita acciones o palabras. No sigue instrucciones simples.

Continúa en la siguiente página...

EDAD	ALARMA
3 AÑOS	Se cae mucho o tiene problemas para subir y bajar escaleras. No se le entiende cuando habla. No sabe utilizar juguetes sencillos. No usa oraciones para hablar. No entiende instrucciones sencillas. No imita ni usa la imaginación en sus juegos.
4 AÑOS	No salta en un solo pie. No muestra interés en juegos interactivos o de imaginación. Ignora a otros niños o no responde a personas fuera de la familia. No puede relatar su cuento favorito. No sigue instrucciones de 3 acciones. No entiende lo que quieren decir “igual” y “diferente”. No usa correctamente las palabras “yo” y “tú”. No habla claro. Pierde habilidades que había adquirido.

2.1.2. El Contexto de la Salud Pediátrica en Paraguay

La detección del Trastorno del Espectro Autista (TEA) en Paraguay se fundamenta actualmente en un modelo de vigilancia del desarrollo que busca romper con la tradición del ”diagnóstico por sospecha tardía”. Bajo el marco de la Ley N° 6103/2018, el sistema de salud nacional ha pasado a reconocer que las desviaciones en el neurodesarrollo deben identificarse en la etapa de máxima plasticidad cerebral. Esto sitúa la relevancia de cualquier sistema de detección dentro de las Unidades de Salud de la Familia (USF) y los centros de atención primaria, donde el objetivo es captar señales de alerta antes de que las barreras sociales y comunicativas se consoliden.

En la realidad paraguaya, la detección se enfrenta al desafío de la centralización de especialistas. Por ello, el marco teórico de un sistema tecnológico debe sustentarse en la capacidad de objetivar síntomas que, a menudo, son pasados por alto en consultas pediátricas breves. La normativa vigente (Decreto N° 3624/20) respalda la implementación de protocolos que permitan una derivación oportuna a centros de mayor complejidad como el Hospital Pediátrico Niños de Acosta Ñu, asegurando que el proceso de identificación

sea el primer eslabón de una cadena de intervención integral [6].

2.1.3. Inteligencia Artificial

2.1.3.1. Definición y fundamentos

La Inteligencia Artificial se define como el campo de la ciencia computacional dedicado al desarrollo de sistemas capaces de realizar tareas que tradicionalmente requieren de la inteligencia humana, tales como el razonamiento, el aprendizaje y la percepción visual [7]. En el ámbito de la ingeniería, la IA presenta una evolución significativa, pasando de sistemas basados en reglas lógicas hacia modelos capaces de extraer conocimiento directamente a partir de los datos [8]. Esta transformación permite que la disciplina deje de depender de heurísticas rígidas y se consolide como un marco robusto de aprendizaje estadístico y computacional.

2.1.3.2. Ramas de la IA aplicadas a la ingeniería

Actualmente, la Inteligencia Artificial se dividide en diversas áreas de especialización, destacándose el Aprendizaje Automático (Machine Learning) y el Aprendizaje Profundo (Deep Learning) como las ramas de mayor impacto en la ingeniería moderna. Estos enfoques permiten a los sistemas no solo procesar información, sino también aprender de grandes volúmenes de datos y generalizar soluciones a partir de patrones complejos [9]. En el área de la salud, estas capacidades facilitarán la identificación de biomarcadores y patrones de motricidad que resultarán imperceptibles mediante métodos tradicionales, posicionando a la IA como una herramienta clave de apoyo en el diagnóstico clínico [10].

2.1.4. Aprendizaje automático

2.1.4.1. Definición y fundamentos

El Aprendizaje Automático constituye una subdisciplina fundamental dentro del campo de la Inteligencia Artificial, cuyo propósito es desarrollar modelos capaces de aprender patrones a partir de datos sin ser programados de forma explícita para cada tarea. En este sentido, los algoritmos permititen identificar relaciones complejas dentro de grandes volúmenes de información, facilitando la automatización de procesos de análisis y toma de decisiones [11]. Los fundamentos del aprendizaje automático se basan en el uso de datos de entrada, modelos matemáticos y procesos de entrenamiento

mediante los cuales el sistema ajustará sus parámetros internos con el objetivo de minimizar el error. Este proceso implicará el uso de funciones de pérdida y algoritmos de optimización, así como técnicas de validación para garantizar la capacidad de generalización del modelo frente a datos no vistos previamente [12]. Asimismo, se considerarán aspectos clave como la calidad de los datos, el preprocesamiento, la selección de características y la evaluación del rendimiento mediante métricas específicas, factores que influirán directamente en la eficacia del modelo desarrollado.

2.1.4.2. Aprendizaje supervisado

El aprendizaje supervisado representa uno de los enfoques más utilizados dentro del aprendizaje automático, caracterizándose por el uso de datos previamente etiquetados. En este tipo de aprendizaje, el modelo será entrenado a partir de pares de entrada y salida esperada, permitiendo que el sistema aprenda a predecir resultados en función de nuevos datos [11]. Dentro de este enfoque, se emplearán técnicas de clasificación y regresión. En el contexto del presente estudio, se priorizarán los modelos de clasificación, ya que permitirán determinar la presencia o ausencia de características asociadas al TEA. El proceso de entrenamiento incluirá la división del conjunto de datos en subconjuntos de entrenamiento y prueba, así como la validación del modelo mediante métricas como precisión, sensibilidad (recall), especificidad y F1-score. Estas métricas permitirán evaluar la capacidad del sistema para identificar correctamente patrones conductuales relevantes [12].

2.1.4.3. Aplicación en diagnóstico clínico

El aprendizaje automático será aplicado en el ámbito del diagnóstico clínico como una herramienta de apoyo para la detección temprana de diversas condiciones, incluyendo el Trastorno del Espectro Autista. En este contexto, los modelos permitirán analizar datos complejos, como videos de comportamiento, con el objetivo de identificar patrones que podrían no ser fácilmente perceptibles mediante la observación humana [13]. En el presente trabajo, se propondrá la utilización de modelos basados en redes neuronales profundas, incluyendo arquitecturas híbridas que integren redes convolucionales y recurrentes, lo que permitirá procesar información espacial y temporal de manera conjunta. Esto facilitará el análisis de gestos, movimientos repetitivos y patrones de interacción social presentes en los videos [14]. La implementación de estas técnicas contribuirá a mejorar la precisión y objetividad en el proceso de evaluación clínica, sirviendo como complemento a los métodos tradicionales de diagnóstico. Sin embargo, se considerará que estos sistemas no reempla-

zarán la intervención de profesionales de la salud, sino que actuarán como herramientas de apoyo en la toma de decisiones clínicas [15].

2.1.5. Visión artificial

2.1.5.1. Definición y evolución

La Visión Artificial (Computer Vision) se define como un campo interdisciplinario de la Inteligencia Artificial que busca otorgar a los sistemas computacionales la capacidad de adquirir, procesar, analizar y comprender el contenido visual del mundo real a partir de imágenes digitales y secuencias de video [16]. En el ámbito de la ingeniería, esta disciplina presenta una evolución significativa, pasando de enfoques tradicionales basados en el diseño manual de algoritmos matemáticos complejos para la extracción de características visuales como la detección de bordes o formas geométricas hacia la implementación de arquitecturas de aprendizaje profundo, las cuales permiten la extracción automatizada de representaciones visuales de alto nivel [17].

2.1.5.2. Aplicación en análisis de comportamiento

En el contexto clínico y del análisis de comportamiento, la Visión Artificial se consolidará como una herramienta tecnológica fundamental para el soporte diagnóstico. En tareas de reconocimiento de acciones motoras, los sistemas analizarán flujos de video en tiempo real con el objetivo de estimar la postura corporal del individuo y rastrear la evolución dinámica de sus movimientos [18]. Mediante el uso de redes neuronales especializadas, será posible procesar estos datos para identificar, cuantificar y analizar biomarcadores y patrones de motricidad que podrían no ser perceptibles mediante la observación humana convencional, transformando la evaluación en un proceso objetivo, estandarizado y escalable [19].

2.1.6. Arquitectura Híbrida CNN-LSTM para Reconocimiento de Patrones

2.1.6.1. Fundamentos de la Combinación Espacio-Temporal

A diferencia de las imágenes estáticas, el video será considerado como una secuencia de fotogramas ordenados cronológicamente. Para detectar patrones como giros o balanceos, no será suficiente analizar una imagen aislada; será necesario observar la evolución de la postura en el tiempo. Modelos como las Redes Convolucionales Recurrentes a Largo Plazo (LRCN) demostrarán ser

altamente efectivos para esta tarea, ya que permitirán procesar características visuales y secuenciales de forma simultánea [20].

2.1.6.2. Extracción de Características con CNN (Capa Espacial)

En la primera etapa, cada fotograma del video será procesado individualmente por una Red Neuronal Convolucional (CNN). En arquitecturas de clasificación de video a gran escala, la CNN actuará como un extractor automático de características. Mediante operaciones matemáticas de convolución y agrupación (pooling), la red identificará puntos clave como:

- **Bordes y silueta:** aislará el cuerpo del infante del fondo.
- **Postura:** determinará la posición de las extremidades y la orientación de la cabeza.

En esta fase, el modelo generará un vector de características unidimensionales por cada instante de tiempo, eliminando información irrelevante del entorno [21].

2.1.6.3. Procesamiento de Secuencias con LSTM (Capa Temporal)

Los vectores espaciales generados por la CNN serán entregados en orden cronológico a la red LSTM. Esta red recurrente será diseñada para modelar dependencias a largo plazo y mitigar el problema del desvanecimiento del gradiente.

En el contexto del TEA, la LSTM analizará la periodicidad de los movimientos. Si los vectores indican posiciones repetitivas de manera rítmica a lo largo de varios cuadros, la red identificará estos patrones como comportamientos estereotipados, como el aleteo de manos. Su arquitectura de "puertas de olvido" permitirá descartar movimientos esporádicos y centrarse en patrones relevantes [22].

2.1.6.4. Flujo de Datos y Clasificación de Patrones de motricidad

El flujo de la arquitectura culminará en una capa densamente conectada con una función de activación, como Softmax. Esta capa recibirá el resumen temporal generado por la LSTM y calculará una probabilidad estadística. Como resultado, el sistema emitirá un porcentaje de confianza que indicará si la secuencia de video corresponderá a un patrón conductual típico o a un marcador motor asociado al autismo, sirviendo como herramienta de apoyo para el especialista clínico [23].

2.1.7. Diseño web

2.1.7.1. Interfaz de Usuario y Arquitectura de Integración Web

La efectividad de un sistema de detección temprana del Trastorno del Espectro Autista (TEA) no dependerá únicamente de la precisión del modelo de inteligencia artificial, sino también de la calidad de la interacción entre el usuario y la plataforma. En este contexto, la interfaz web será concebida como un componente esencial que permitirá la integración eficiente entre el especialista clínico y el motor de inferencia basado en redes CNN-LSTM.

El sistema web será diseñado para gestionar de manera estructurada el flujo de datos, desde la carga de secuencias de video hasta la visualización de resultados interpretables. Esta integración permitirá que el usuario pueda utilizar la herramienta sin requerir conocimientos técnicos avanzados en inteligencia artificial, facilitando su adopción en entornos clínicos y educativos.

Además, la arquitectura de la plataforma priorizará la usabilidad, accesibilidad y eficiencia, aspectos fundamentales en sistemas de apoyo a la toma de decisiones médicas, donde la claridad en la presentación de la información influye directamente en la interpretación de los resultados [24].

2.1.7.2. Arquitectura del Lado del Cliente (Frontend)

El frontend será desarrollado bajo un enfoque basado en componentes reutilizables, empleando tecnologías modernas como Next.js, que permiten optimizar el rendimiento mediante renderizado híbrido (SSR y CSR). Este enfoque será clave para mejorar los tiempos de carga y garantizar una experiencia de usuario fluida, especialmente al trabajar con archivos multimedia de gran tamaño como videos.

La interfaz estará diseñada específicamente para soportar el flujo de trabajo del sistema de detección de TEA, permitiendo al usuario:

- Cargar videos de comportamiento infantil de manera sencilla e intuitiva.
- Visualizar el estado del procesamiento en tiempo real.
- Recibir retroalimentación clara durante el análisis.
- Acceder a los resultados generados por el modelo.

Asimismo, el sistema gestionará procesos asíncronos relacionados con la carga y análisis de videos, utilizando técnicas de manejo de estado que permitan informar al usuario sobre el progreso del procesamiento. Esto resulta

fundamental considerando que los modelos de aprendizaje profundo, como CNN-LSTM, requieren tiempos de inferencia variables dependiendo de la longitud del video [12].

El diseño de la interfaz priorizará la simplicidad y claridad visual, reduciendo la carga cognitiva del usuario y facilitando la interpretación de los resultados obtenidos.

2.1.8. Comunicación y Servicios de Red (Backend)

La comunicación entre el frontend y el sistema de inteligencia artificial se implementará mediante una arquitectura cliente-servidor basada en el estilo REST (Representational State Transfer), ampliamente utilizado en aplicaciones web modernas por su escalabilidad y simplicidad.

El backend será desarrollado utilizando FastAPI, un framework de alto rendimiento para la construcción de APIs, que permitirá gestionar de manera eficiente las solicitudes de procesamiento de video. Este componente actuará como un intermediario entre la interfaz de usuario y el modelo CNN-LSTM, organizando el flujo de datos en diferentes etapas:

1. Recepción del video cargado por el usuario.
2. Preprocesamiento de los datos (extracción de fotogramas, normalización, etc.).
3. Envío de los datos al modelo CNN para la extracción de características espaciales.
4. Procesamiento secuencial mediante la red LSTM.

Este enfoque desacoplado permitirá que el modelo de inteligencia artificial evolucione independientemente del sistema web, facilitando futuras mejoras en términos de precisión, escalabilidad y mantenimiento del sistema [25].

2.1.8.1. Gestión de Seguridad y Privacidad de Datos

Dado que el sistema trabajará con datos sensibles relacionados con menores de edad, la seguridad y privacidad serán aspectos críticos en su diseño. En este sentido, se implementarán mecanismos de autenticación y autorización que restringirán el acceso únicamente a usuarios autorizados, como profesionales de la salud o investigadores.

Asimismo, se establecerán políticas de protección de datos que garanticen la confidencialidad de la información, incluyendo el almacenamiento seguro de

los videos y resultados generados. Este enfoque será coherente con principios internacionales de protección de datos y ética en sistemas de salud digital [26].

Además, se considerará la trazabilidad de las operaciones realizadas en el sistema, permitiendo registrar el acceso y uso de la información, lo cual es fundamental en contextos clínicos donde la transparencia y la responsabilidad son requisitos esenciales.

2.1.8.2. Visualización de Resultados y Diseño de Interacción

La visualización de resultados constituirá una de las etapas más importantes del sistema, ya que permitirá traducir la salida del modelo CNN-LSTM en información comprensible para el especialista. En este sentido, el diseño de la interacción estará orientado a facilitar la interpretación de patrones de motricidad detectados en los videos.

El sistema presentará los resultados mediante diferentes elementos visuales, tales como:

- Cargar videos de comportamiento infantil de manera sencilla e intuitiva.
- Visualizar el estado del procesamiento en tiempo real.
- Recibir retroalimentación clara durante el análisis.
- Acceder a los resultados generados por el modelo.

Este enfoque permitirá al usuario correlacionar los resultados del modelo con evidencia visual directa, fortaleciendo la confianza en el sistema y mejorando la toma de decisiones clínicas.

Además, el uso de técnicas de visualización interactiva contribuirá a reducir la ambigüedad en la interpretación de los resultados, transformando datos complejos en información clara y accesible [27].

De esta manera, el sistema no solo funcionará como una herramienta automatizada, sino como un soporte inteligente que complementará el criterio del especialista en la detección temprana del TEA.

2.2. Antecendentes

Los antecedentes revisados evidencian la aplicación de técnicas de inteligencia artificial, aprendizaje profundo y análisis de movimiento para la identificación de características asociadas al Trastorno del Espectro Autista (TEA). Los trabajos analizados emplean diferentes fuentes de información,

entre ellas patrones gestuales, secuencias de video y movimientos registrados mediante cámaras en entornos controlados. En particular, se observa el interés por utilizar características motrices y temporales como elementos complementarios para la identificación de comportamientos asociados al TEA.

Patrones gestuales para la detección de autismo en niños (Año 2018)

Desarrollado por: Gloria Ivonne Monarca Pintle, Centro de Investigación Científica y de Educación Superior de Ensenada (CICESE), México.

En [28] se desarrolló una investigación orientada a la identificación de patrones gestuales asociados al autismo mediante el análisis de movimientos realizados por niños. El trabajo estudió características relacionadas con comportamientos repetitivos y utilizó técnicas de visión artificial para obtener información a partir de los movimientos observados. El antecedente resulta relevante debido a que aborda la identificación de características observables relacionadas con el TEA mediante herramientas computacionales.

La similitud principal con el presente proyecto se encuentra en el análisis de patrones de movimiento asociados al TEA y en la utilización de técnicas de procesamiento visual para obtener información relacionada con dichos patrones. La diferencia fundamental radica en el enfoque tecnológico empleado, debido a que el presente trabajo propone el análisis de secuencias de video mediante una arquitectura CNN-LSTM integrada en un sistema web, mientras que el antecedente se orienta al análisis de patrones gestuales mediante otro enfoque de interacción y adquisición de datos. Este trabajo proporciona una base para considerar los movimientos observables como características relevantes para sistemas computacionales de apoyo a la identificación del TEA.

Enhancing Autism Spectrum Disorder Early Detection with the Parent-Child Dyads Block-Play Protocol and an Attention-enhanced GCN-xLSTM Hybrid Deep Learning Framework (Año 2024)

Desarrollado por: Xiang Li, Lizhou Fan, Hanbo Wu, Kunping Chen, Xiaoxiao Yu, Chao Che, Zhifeng Cai, Xiuhong Niu, Aihua Cao y Xin Ma.

En [29] se propuso un enfoque de aprendizaje profundo para la detección temprana del Trastorno del Espectro Autista mediante el protocolo de interacción de juego entre padres e hijos. El trabajo empleó información obtenida

durante actividades de juego y una arquitectura híbrida basada en Graph Convolutional Networks (GCN) y Long Short-Term Memory (LSTM), incorporando además un mecanismo de atención para aprovechar información espacial y temporal.

Este antecedente presenta una relación directa con el proyecto actual debido al empleo de arquitecturas capaces de procesar información espacial y temporal relacionada con el comportamiento humano. La similitud principal se encuentra en la utilización de modelos de aprendizaje profundo para identificar características asociadas al TEA a partir de información visual y temporal. La diferencia radica en que el antecedente utiliza una arquitectura GCN-xLSTM y analiza interacciones durante actividades de juego, mientras que el presente proyecto propone una arquitectura CNN-LSTM para identificar tres patrones de motricidad visualmente observables: aleteo de manos, balanceo corporal y movimientos repetitivos de cabeza. Este trabajo aporta fundamentos para considerar conjuntamente las características espaciales y temporales en la identificación automatizada de comportamientos relacionados con el TEA.

Nuevo sistema de detección temprana del autismo (Año 2025)

Desarrollado por: Universitat Politècnica de València, España.

En [30] se presentó un sistema orientado a la detección temprana del autismo mediante el empleo de tecnologías de Inteligencia Artificial y herramientas de captura y análisis de información relacionada con el comportamiento. La propuesta plantea el uso de tecnologías digitales para obtener indicadores que puedan contribuir a la identificación temprana de características asociadas al TEA.

La similitud con el presente proyecto se encuentra en el empleo de Inteligencia Artificial como herramienta de apoyo para la identificación temprana de características relacionadas con el TEA y en la utilización de información obtenida mediante tecnologías digitales. La diferencia principal radica en la arquitectura y el tipo de información procesada, ya que el presente proyecto se centra específicamente en secuencias de video y patrones de motricidad, utilizando una arquitectura CNN-LSTM integrada en una plataforma web. Este antecedente permite sustentar la aplicación de tecnologías de Inteligencia Artificial como herramientas de apoyo para procesos relacionados con la identificación temprana del TEA.

Relación de los antecedentes con la investigación

Los antecedentes revisados permiten establecer una relación entre el análisis computacional del movimiento, el procesamiento de información visual y el empleo de técnicas de aprendizaje profundo para la identificación de características asociadas al TEA. Los trabajos analizados presentan diferentes estrategias para obtener y procesar información relacionada con el comportamiento, incluyendo patrones gestuales, interacciones entre personas y sistemas digitales orientados a la detección temprana.

A partir de estos antecedentes, se establece como elemento diferenciador del presente proyecto la integración de una arquitectura **CNN-LSTM** en un **sistema web**, orientada específicamente a la identificación de tres patrones de motricidad visualmente observables: **aleteo de manos, balanceo corporal y movimientos repetitivos de cabeza**. La CNN permitirá extraer características espaciales de los fotogramas, mientras que la LSTM permitirá procesar la evolución temporal de dichas características a lo largo de una secuencia de video.

De esta manera, los antecedentes proporcionan fundamentos para la selección de técnicas de visión artificial y aprendizaje profundo, así como para el procesamiento temporal de secuencias de video, elementos que constituyen la base tecnológica del sistema propuesto.

Capítulo 3

Tecnologías utilizadas

El presente capítulo detalla las tecnologías de hardware y software seleccionadas para el desarrollo del proyecto. Se describe en primer lugar el hardware local disponible para el desarrollo del proyecto: la tarjeta gráfica NVIDIA GeForce RTX 4070 y el procesador AMD Ryzen 7 7800X3D. Posteriormente, se justifica la selección de cuatro arquitecturas de redes neuronales evaluadas para la extracción de características espaciales: una arquitectura CNN propia entrenada desde cero, y tres arquitecturas preentrenadas incorporadas mediante transferencia de aprendizaje (ResNet50, MobileNetV2 y Vision Transformer). Finalmente, se describen las herramientas complementarias del flujo de trabajo: YouTube como fuente de los videos que conforman el conjunto de datos y Google Drive para el almacenamiento centralizado del conjunto de datos.

3.1. Componentes de Hardware

Los componentes de hardware abarcan los dispositivos físicos disponibles en el equipo de desarrollo, utilizados tanto para las etapas de programación y preprocesamiento de video como, potencialmente, para el entrenamiento de los modelos de inteligencia artificial.

3.1.1. Tarjeta gráfica: NVIDIA GeForce RTX 4070

La NVIDIA GeForce RTX 4070 es una unidad de procesamiento gráfico (GPU) de gama alta para consumidores, basada en la arquitectura Ada Lovelace de NVIDIA. Cuenta con 12 GB de memoria VRAM tipo GDDR6X y núcleos Tensor de cuarta generación, orientados a acelerar operaciones de multiplicación de matrices propias del entrenamiento de redes neuronales

profundas mediante precisión mixta (FP16/BF16).



Figura 3.1: Tarjeta gráfica NVIDIA GeForce RTX 4070.

Esta tarjeta gráfica forma parte del equipo de desarrollo utilizado por el equipo de trabajo, y representa una capacidad de cómputo considerable para tareas de inteligencia artificial a nivel local. Su memoria VRAM y sus núcleos Tensor la hacen, en principio, adecuada para acelerar tanto el entrenamiento de la arquitectura CNN-LSTM propia como la extracción de características mediante las arquitecturas preentrenadas consideradas en este trabajo (ResNet50, MobileNetV2 y ViT) [31].

Los beneficios que ofrece esta tarjeta gráfica para el proyecto incluyen:

- **Aceleración por núcleos Tensor:** permite acelerar significativamente las operaciones matriciales del entrenamiento mediante precisión mixta (FP16/BF16), reduciendo los tiempos de cómputo respecto a un procesador convencional.
- **Amplia memoria VRAM (12 GB):** posibilita procesar lotes de video de mayor tamaño y modelos más grandes (como ResNet50 o ViT) sin quedar limitado por la memoria disponible.
- **Disponibilidad inmediata sin costo adicional:** al formar parte del equipo ya adquirido por el grupo de trabajo, no representa un gasto adicional para el proyecto.
- **Independencia de servicios externos a futuro:** configurando el entorno adecuado (WSL2), permitiría eliminar la dependencia de plataformas en la nube y sus limitaciones de cuota y disponibilidad.

3.1.2. Procesador: AMD Ryzen 7 7800X3D

El procesador AMD Ryzen 7 7800X3D, basado en la arquitectura Zen 4, complementa el equipo de desarrollo local. Se utiliza para la ejecución de las tareas que no dependen de aceleración por GPU: la extracción y el preprocesamiento de fotogramas de video (incluyendo la detección y el recorte del sujeto mediante YOLOv8n y la normalización de iluminación mediante CLAHE, detalladas en la sección 3.4), la programación y depuración del código del proyecto, y el entrenamiento de los componentes más livianos del sistema [32].

Los beneficios que ofrece este procesador para el proyecto incluyen:

- **Múltiples núcleos e hilos de procesamiento:** permite ejecutar en paralelo tareas de preprocesamiento de video (extracción de fotogramas, detección con YOLOv8n, normalización con CLAHE) sin generar cuellos de botella durante el desarrollo.
- **Suficiente para el entrenamiento de componentes livianos:** la capa LSTM, al entrenarse sobre vectores de características ya extraídos (y no sobre los fotogramas crudos), no requiere GPU y se ejecuta en tiempos razonables directamente en este procesador.
- **Estabilidad para tareas de desarrollo continuo:** adecuado para la programación, depuración y pruebas automatizadas del código del proyecto (los casos de prueba de la CNN y la LSTM, por ejemplo) sin necesidad de recursos especializados.
- **Ya disponible en el equipo de desarrollo:** al igual que la GPU, no representa un costo adicional para el proyecto.

3.2. Componentes de Software

Los componentes de software proporcionan las herramientas, plataformas y algoritmos necesarios para diseñar, entrenar y evaluar los modelos de inteligencia artificial del proyecto.

3.2.1. Arquitecturas para la extracción de características

Para la etapa de extracción de características espaciales de cada fotograma, se evaluaron cuatro arquitecturas de redes neuronales, seleccionadas por

representar enfoques complementarios: una arquitectura convolucional propia entrenada desde cero, y tres arquitecturas preentrenadas incorporadas mediante transferencia de aprendizaje.

CNN-LSTM

Arquitectura desarrollada específicamente para este proyecto, compuesta por cuatro bloques convolucionales, encargados de la extracción de características espaciales, seguidos de una capa LSTM para el análisis temporal. La arquitectura es entrenada completamente desde cero sobre el conjunto de datos de videos de conductas motoras.

Sus características principales son:

- **Diseño a medida:** arquitectura ajustada específicamente a la resolución y las características del conjunto de datos, utilizando fotogramas de 64×64 píxeles y secuencias de 40 fotogramas.
- **Sin dependencia de pesos preentrenados:** aprende representaciones específicas del dominio de estudio en lugar de heredar representaciones obtenidas a partir de un conjunto de datos genérico como ImageNet.
- **Bajo costo computacional:** presenta una cantidad reducida de parámetros en comparación con las arquitecturas preentrenadas, lo que permite un entrenamiento con menor requerimiento computacional.
- **Control total sobre el diseño:** permite ajustar cada hiperparámetro, incluyendo el número de filtros, dropout y regularización, en función de los resultados obtenidos durante el proceso experimental.

ResNet50

ResNet50 (Residual Network de 50 capas) es una arquitectura de red neuronal convolucional profunda que introduce conexiones residuales para abordar el problema de degradación en redes de gran profundidad, permitiendo que la información fluya directamente a través de la red mediante conexiones de atajo [33].

Sus características principales son:

- **Conexiones residuales:** facilitan la convergencia del modelo y permiten entrenar redes más profundas reduciendo los problemas asociados a la degradación del gradiente.
- **Transferencia de aprendizaje:** dispone de pesos preentrenados en ImageNet, que pueden aprovecharse para extraer características visuales generales sin necesidad de entrenar la arquitectura completamente desde cero.

- **Rendimiento comprobado:** es una arquitectura ampliamente utilizada y validada en tareas de clasificación y extracción de características de imágenes.
- **Mayor costo computacional:** produce 2048 características por fotograma y cuenta con aproximadamente 23 millones de parámetros, representando una de las alternativas de mayor costo computacional evaluadas.

Vision Transformer (ViT)

Vision Transformer (ViT) aplica la arquitectura Transformer, originalmente desarrollada para tareas de procesamiento de lenguaje natural, al dominio de la visión por computadora. Para ello, divide cada imagen en pequeños parches que son tratados como tokens dentro de una secuencia [34].

Sus características principales son:

- **Mecanismo de atención:** permite capturar relaciones globales entre distintas regiones del fotograma de forma directa, a diferencia de las operaciones convolucionales tradicionales.
- **Paradigma alternativo:** representa una familia de arquitecturas diferente a las redes convolucionales, permitiendo evaluar si el mecanismo de atención global resulta adecuado para la identificación de patrones de motricidad.
- **Mayor necesidad de datos:** su entrenamiento completo requiere grandes volúmenes de datos, por lo que en este trabajo se emplea mediante transferencia de aprendizaje utilizando pesos preentrenados.
- **Costo computacional considerable:** presenta un requerimiento computacional significativo durante la extracción de características, comparable al de arquitecturas convolucionales profundas como ResNet50.

Criterios de evaluación

Con el fin de comparar las cuatro arquitecturas de forma sistemática, se establecieron los siguientes criterios:

- **Precisión:** capacidad para distinguir correctamente las clases de conducta motora consideradas en el conjunto de datos.
- **Eficiencia computacional:** relación entre el rendimiento obtenido y los recursos de cómputo requeridos, particularmente relevante debido al tamaño reducido del conjunto de datos, compuesto por 57 videos.

- **Velocidad de extracción de características:** tiempo necesario para procesar cada video durante la etapa de extracción de características.
- **Capacidad de generalización:** desempeño del modelo sobre datos no utilizados durante el entrenamiento, considerando el tamaño limitado del conjunto de datos.
- **Transferencia de aprendizaje:** disponibilidad y aprovechamiento de pesos preentrenados para la extracción de características visuales.

Tabla 3.1: Comparación de arquitecturas de modelos de inteligencia artificial.

Criterio	**CNN propia**	**ResNet50**	**ViT**
Precisión	2	3	2
Eficiencia computacional	3	1	1
Velocidad de extracción	3	2	2
Capacidad de generalización	1	3	2
Transferencia de aprendizaje	1	3	3
Total	**10**	**12**	**10**

Como se observa en la Tabla 5.3, ResNet50 obtuvo el mayor puntaje total, con 12 puntos, frente a los 10 puntos alcanzados por la CNN propia y Vision Transformer (ViT). Este resultado se relaciona con las puntuaciones asignadas en los criterios de precisión, capacidad de generalización y transferencia de aprendizaje. Por su parte, la CNN propia destacó en eficiencia computacional y velocidad de extracción, mientras que ViT presentó un desempeño favorable en transferencia de aprendizaje.

A partir de esta comparación, se seleccionó ResNet50 como extractor de características espaciales para la arquitectura híbrida ResNet50-LSTM, con el propósito de combinar la extracción de información visual de los fotogramas con el análisis temporal de las secuencias mediante LSTM. No obstante, la selección deberá contrastarse con los resultados experimentales obtenidos durante la evaluación de los modelos.

3.3. Tecnologías del Frontend

Para la construcción de la plataforma web planteada en el diseño del sistema, encargada de la carga de videos, la comunicación con el motor de

inferencia y la visualización de resultados, se compararon distintas combinaciones de tecnologías de frontend y backend, consideradas como stacks completos.

Tabla 3.2: Comparativa de herramientas seleccionadas.

Criterio	**Next.js + FastAPI**	**Next.js + Django (DRF)**	**React + NestJS**	**Django full-stack**
Integración con el modelo de IA	3	3	1	3
Rendimiento multimedia	3	2	3	2
Tipado y mantenimiento	3	2	3	1
Curva de aprendizaje	2	1	1	2
Documentación y ecosistema	3	3	2	3
Total	**14**	**11**	**10**	**11**

Como se observa en la Tabla 3.2, la combinación de Next.js con FastAPI obtuvo el mayor puntaje total, con 14 puntos, frente a los 11 puntos de Next.js con Django (DRF), los 10 puntos de React con NestJS y los 11 puntos de Django como framework full-stack.

Uno de los principales criterios considerados fue la integración con el modelo de inteligencia artificial. Al estar desarrollado en Python, FastAPI permite incorporar directamente el modelo de aprendizaje automático en la aplicación backend, facilitando su ejecución y evitando la necesidad de implementar una capa de comunicación entre servicios independientes. En cambio, una solución basada en React y NestJS requeriría establecer un mecanismo de integración entre el backend desarrollado en TypeScript y el modelo implementado en Python.

Asimismo, Next.js permite utilizar TypeScript para mejorar la organización y mantenibilidad del código, además de ofrecer distintas estrategias de renderizado según las necesidades de la aplicación. Estas características resultan útiles para desarrollar una interfaz que permita cargar videos, enviar solicitudes de análisis y visualizar los resultados de la clasificación.

Por su parte, Django también ofrece ventajas para integrar modelos de

inteligencia artificial desarrollados en Python. Sin embargo, algunas de sus funcionalidades, como el sistema de administración y las herramientas de gestión de datos, podrían no ser prioritarias para un prototipo cuya función principal consiste en recibir videos, procesarlos mediante un modelo de clasificación y presentar los resultados.

En consecuencia, se seleccionó Next.js con FastAPI como combinación tecnológica de referencia para el desarrollo de la plataforma web, debido a su integración con el modelo de inteligencia artificial, sus posibilidades de mantenimiento y su adecuación a los requerimientos funcionales del proyecto.

A partir del stack seleccionado en la sección anterior, se detallan a continuación las tecnologías específicas que componen la capa de frontend de la plataforma web.

3.3.1. Next.js

Next.js es un framework de desarrollo web basado en React, que incorpora capacidades de renderizado del lado del servidor (SSR) y del lado del cliente (CSR) de forma híbrida. Se seleccionó como base del frontend porque su esquema de renderizado híbrido reduce los tiempos de carga percibidos al trabajar con archivos multimedia de gran tamaño –como los videos de comportamiento infantil que constituyen la entrada principal del sistema–, y porque incluye de forma nativa el ruteo de páginas y la optimización de recursos estáticos, sin requerir configuración adicional.

3.3.2. React

React es una biblioteca de JavaScript para la construcción de interfaces de usuario basada en componentes reutilizables, y constituye la base sobre la cual se construye Next.js. Su modelo de componentes resulta adecuado para estructurar las distintas vistas de la plataforma (carga de video, seguimiento del procesamiento, visualización de resultados) como unidades independientes y reutilizables, facilitando el mantenimiento del código a medida que el sistema incorpore nuevas funcionalidades.

3.3.3. TypeScript

TypeScript es un superconjunto de JavaScript que incorpora tipado estático opcional. Se utiliza en el desarrollo del frontend para detectar errores en tiempo de desarrollo –antes de que el código llegue a producción–, lo cual resulta particularmente relevante en un sistema que maneja datos sensibles

de menores, donde un error de manejo de datos no detectado podría tener consecuencias mayores que en una aplicación convencional.

3.3.4. Tailwind CSS

Tailwind CSS es un framework de estilos basado en clases de utilidad, que permite construir interfaces personalizadas sin necesidad de escribir hojas de estilo (CSS) desde cero. Se seleccionó por su integración directa con Next.js y por permitir un desarrollo más ágil de una interfaz simple y clara, alineada con el objetivo de reducir la carga cognitiva del usuario planteado en el diseño de interacción del sistema (sección 7.7.5 del Marco Teórico).

3.3.5. Recharts

Recharts es una biblioteca de visualización de datos para React, construida sobre gráficos vectoriales (SVG). Se incorpora al frontend para representar de forma visual el nivel de confianza que el modelo asigna a cada una de las clases de conducta motora evaluadas (aleteo de manos, balanceo corporal, giros), facilitando su interpretación por parte del profesional de la salud que utiliza el sistema como apoyo a la evaluación clínica.

3.3.6. Axios

Axios es un cliente HTTP basado en promesas, utilizado para gestionar la comunicación entre el frontend y el backend expuesto mediante FastAPI. Se seleccionó frente a la API nativa `fetch` de JavaScript por su manejo simplificado de solicitudes con archivos de gran tamaño (como los videos a subir) y por su soporte incorporado para el seguimiento del progreso de carga, relevante para informar al usuario sobre el estado del procesamiento de su video, tal como se plantea en el diseño de la interfaz (sección 7.7.2 del Marco Teórico).

3.4. Tecnologías del Backend

A partir del stack seleccionado en la sección 3.3, se detallan a continuación las tecnologías específicas que componen la capa de backend de la plataforma web, encargada de recibir los videos, ejecutar el preprocesamiento y el modelo de inteligencia artificial, y devolver los resultados al frontend.

3.4.1. FastAPI

FastAPI es un framework web moderno para Python, orientado a la construcción de APIs de alto rendimiento a partir de las anotaciones de tipo (*type hints*) nativas del lenguaje. Tal como se justificó en la sección 3.3, se seleccionó frente a alternativas como Django o NestJS principalmente por permitir importar y ejecutar el modelo CNN-LSTM directamente dentro de la misma API, sin *bridges* entre lenguajes, además de generar automáticamente documentación interactiva de los *endpoints* (Swagger/OpenAPI), útil para la validación y prueba del servicio durante el desarrollo.

3.4.2. Uvicorn

Uvicorn es un servidor ASGI (*Asynchronous Server Gateway Interface*) liviano y de alto rendimiento, requerido para ejecutar aplicaciones FastAPI. Se seleccionó por ser el servidor recomendado oficialmente para este framework, y por su soporte nativo de manejo asíncrono de solicitudes, lo cual permite que el servidor continúe atendiendo otras solicitudes mientras se ejecuta la inferencia del modelo sobre un video, evitando que el sistema quede bloqueado durante ese proceso.

3.4.3. Pydantic

Pydantic es una biblioteca de validación de datos basada en las anotaciones de tipo de Python, integrada de forma nativa en FastAPI. Se utiliza para validar la estructura de las solicitudes entrantes y para definir de forma explícita el esquema de la respuesta del servicio (por ejemplo, la conducta identificada junto con el nivel de confianza asociado a cada clase), reduciendo el riesgo de errores de formato al comunicar el backend con el frontend.

3.4.4. python-multipart

`python-multipart` es la biblioteca requerida por FastAPI para procesar datos de tipo `multipart/form-data`, formato necesario para la recepción de archivos a través de una API REST. Se incorpora específicamente para habilitar la funcionalidad de carga de videos desde el frontend hacia el backend.

3.4.5. TensorFlow / Keras (motor de inferencia)

Tal como se detalla en la sección 3.2, TensorFlow y Keras constituyen el framework principal utilizado para el desarrollo de los modelos de este

trabajo. En el contexto del backend, específicamente, el modelo CNN-LSTM ya entrenado se carga una única vez al iniciar el servicio (mediante la función `load_model` de Keras) y se mantiene en memoria para ejecutar la inferencia sobre cada video recibido, evitando el costo de recargar el modelo en cada solicitud.

3.4.6. OpenCV (preprocesamiento en el backend)

OpenCV, ya utilizado en la etapa de entrenamiento para la extracción de fotogramas (sección 3.2), se reutiliza dentro del backend para aplicar exactamente el mismo preprocesamiento sobre los videos que suben los usuarios del sistema (extracción de fotogramas, recorte con YOLOv8n y normalización con CLAHE, detalladas en la sección 3.6). Mantener el mismo pipeline de preprocesamiento entre el entrenamiento y la inferencia resulta indispensable para que el modelo reciba datos con las mismas características con las que fue entrenado.

3.4.7. python-jose

`python-jose` es una biblioteca para la generación y validación de JSON Web Tokens (JWT). Se incorpora al backend para implementar los mecanismos de autenticación y autorización que restringen el acceso al sistema únicamente a usuarios autorizados –profesionales de la salud e investigadores–, tal como se establece en la sección 7.7.4 del Marco Teórico sobre gestión de seguridad y privacidad de datos, dado que el sistema procesa videos de menores de edad.

3.5. Servicios en la Nube

3.5.1. Google Drive

Google Drive es un servicio de almacenamiento en la nube que permite guardar y compartir archivos de forma centralizada. Se incorpora al flujo de trabajo del proyecto para almacenar el conjunto de datos (videos originales, fotogramas extraídos y modelos entrenados), por dos razones concretas: centralización entre los integrantes del equipo e integración directa con Google Colab.

3.5.2. Firebase Firestore

Firebase Firestore es una base de datos NoSQL orientada a documentos, alojada en la nube y ofrecida por Google como parte de la plataforma Firebase. Se incorpora al sistema para almacenar la información generada en cada análisis: el identificador del video procesado, la conducta identificada, el nivel de confianza asignado a cada una de las tres clases evaluadas y la fecha del análisis.

Esta información resulta necesaria para sostener la etapa de **Validación Externa** planteada en el diseño del sistema, en la cual un profesional de la salud revisa los resultados generados por el modelo de forma posterior al procesamiento del video, y no únicamente en el momento en que este se lleva a cabo. Se seleccionó Firestore, en lugar de una base de datos relacional tradicional, por dos motivos: la información a almacenar tiene una estructura simple y no requiere relaciones complejas entre tablas, y su integración nativa con el ecosistema de Google simplifica la configuración del backend mediante el SDK oficial de Firebase para Python.

3.6. Herramientas de Desarrollo

Las herramientas de desarrollo comprenden tanto el entorno de cómputo en la nube utilizado para el entrenamiento (Google Colaboratory), como las herramientas empleadas para la escritura, depuración y control de versiones del código del proyecto.

3.6.1. Entorno de cómputo: Google Colaboratory

Google Colaboratory (Colab) es un servicio de Google que permite ejecutar código Python en un entorno de tipo Jupyter Notebook alojado en la nube, con acceso gratuito a unidades de procesamiento gráfico (GPU) para tareas de cómputo intensivo. En su nivel gratuito, Colab asigna típicamente una GPU NVIDIA Tesla T4, dotada de 16 GB de memoria VRAM GDDR6 y núcleos Tensor de primera generación, orientados a acelerar operaciones de aprendizaje profundo mediante precisión mixta (FP16) [35].

La selección de Colab como entorno de entrenamiento, frente al uso de la GPU local (RTX 4070, no aprovechable de forma nativa en Windows) o del procesador local (Ryzen 7 7800, sin aceleración por GPU), se fundamentó en un análisis comparativo considerando los siguientes criterios:

- **Rendimiento computacional**: capacidad para acelerar el entrenamiento y la extracción de características mediante las arquitecturas

preentrenadas.

- **Memoria disponible**: cantidad de VRAM necesaria para procesar secuencias de video de forma eficiente.
- **Soporte para frameworks**: compatibilidad nativa con TensorFlow y Keras sin requerir configuración adicional.
- **Disponibilidad**: continuidad de acceso al recurso de cómputo a lo largo de las distintas etapas del proyecto.
- **Costo**: gastos asociados al uso del recurso de cómputo.
- **Facilidad de configuración**: tiempo y complejidad necesarios para dejar el entorno operativo.

Para reflejar el desempeño relativo de cada opción, se empleó una escala del 1 al 3, donde 3 indica el mejor desempeño y 1 el más limitado:

Tabla 3.3: Comparativa de entornos de cómputo

Criterio	**CPU local (Ryzen 7 7800)**	**Google Colab (GPU T4)**	**GPU local vía WSL2 (RTX 4070)**
Rendimiento computacional	1	3	3
Memoria disponible	2	3	2
Soporte para frameworks	3	3	2
Disponibilidad	3	2	3
Costo	3	3	3
Facilidad de configuración	3	3	1
Total	**15**	**17**	**14**

De acuerdo con los resultados obtenidos, Google Colab resultó la opción con mejor puntaje total, al combinar un rendimiento computacional equivalente al de una GPU local con una configuración inmediata, sin costo y sin requerir instalación alguna en el equipo de trabajo. La GPU local mediante WSL2 queda contemplada como una posible mejora a futuro si las limitaciones de sesión y cuota dinámica de Colab llegaran a interferir con el desarrollo del proyecto.

3.6.2. Entorno de desarrollo integrado: Visual Studio Code

Visual Studio Code (VS Code) es un editor de código fuente liviano y extensible, desarrollado por Microsoft. Se utiliza para el desarrollo local de los distintos scripts de Python que conforman el proyecto: extracción de fotogramas, construcción del conjunto de datos, definición de las arquitecturas de los modelos y scripts de entrenamiento, aprovechando extensiones específicas para Python (resaltado de sintaxis, autocompletado, depuración integrada) que facilitan la iteración rápida sobre el código antes de ejecutar las etapas de mayor costo computacional en Google Colab.

3.6.3. Git y GitHub

Git es un sistema de control de versiones distribuido, y GitHub es la plataforma utilizada para alojar el repositorio del proyecto de forma remota. Se incorporan al flujo de trabajo para que los integrantes del equipo puedan colaborar sobre el mismo código de forma organizada, llevar un registro de los cambios realizados a lo largo del proceso iterativo de ajuste de las arquitecturas (por ejemplo, las sucesivas modificaciones a la arquitectura CNN-LSTM documentadas en este trabajo), y recuperar versiones anteriores del código en caso de que un cambio introduzca un error.

3.7. Librerías Especializadas

A continuación se detallan las bibliotecas de Python que cumplen funciones específicas dentro del pipeline de procesamiento de video y evaluación de los modelos, complementando a TensorFlow/Keras (sección 3.2) como herramientas de propósito más acotado.

3.7.1. YOLOv8n (Ultralytics)

YOLOv8n es la versión "nano" —la más liviana— de la familia de modelos YOLOv8 (You Only Look Once) para detección de objetos en tiempo real, distribuida a través de la biblioteca Ultralytics [36]. Se incorpora al pipeline de preprocesamiento para detectar y recortar al sujeto dentro de cada fotograma, antes de que este sea procesado por las arquitecturas de extracción de características.

La variabilidad espacial del sujeto dentro del cuadro (el niño cambia de posición y de encuadre a lo largo del video) y la influencia de objetos y otras

personas presentes en la escena. Al recortar el cuadro delimitador (bounding box) correspondiente a la clase "persona", se reduce la proporción de fondo, objetos y otras personas que llega a la red, concentrando el análisis en el sujeto de interés. Se seleccionó específicamente la variante "nano"por ser preentrenada, gratuita, y lo suficientemente liviana como para ejecutarse en CPU sin una GPU dedicada, en línea con el entorno de desarrollo del proyecto.

3.7.2. CLAHE (OpenCV)

CLAHE (*Contrast Limited Adaptive Histogram Equalization*) es una técnica de ecualización de histograma disponible en OpenCV, que mejora el contraste de una imagen de forma local, dividiendo en regiones y ecualizando cada una por separado, en lugar de aplicar una única corrección global a toda la imagen.

Se incorpora al pipeline de preprocesamiento para atenuar otro de los desafíos documentados en el mismo trabajo: la iluminación no controlada entre los distintos videos del conjunto de datos, que provienen de fuentes heterogéneas (YouTube, grabaciones propias) con condiciones de luz muy variables entre sí.

3.7.3. NumPy

NumPy es la biblioteca fundamental de Python para el cómputo numérico, y provee la estructura de arreglo multidimensional (*ndarray*) sobre la cual se construyen tanto TensorFlow/Keras como el resto de las bibliotecas científicas del proyecto. Se utiliza a lo largo de todo el pipeline para representar las secuencias de video como tensores (video $\times$ fotograma $\times$ alto $\times$ ancho $\times$ canal), así como para las operaciones de aumento de datos aplicadas durante el entrenamiento.

3.7.4. scikit-learn

scikit-learn es una biblioteca de aprendizaje automático de propósito general, utilizada en este proyecto no para el modelo de clasificación en sí, sino para dos tareas auxiliares específicas: la partición estratificada del conjunto de datos en entrenamiento, validación y prueba, y el cálculo de las métricas de evaluación del modelo (precisión, *recall*, F1-score y matriz de confusión).

Capítulo 4

Método

4.1. Tipo de investigación

El trabajo propuesto se enmarca en la investigación aplicada porque busca resolver una necesidad práctica mediante el desarrollo de una herramienta tecnológica. Su enfoque es cuantitativo porque se utilizan métricas numéricas para evaluar y comparar el desempeño de los modelos. El diseño es experimental porque se realizan pruebas controladas para analizar los resultados obtenidos con diferentes modelos. Finalmente, la prototipación funcional se refleja en el desarrollo de una aplicación web que integra el análisis de videos y la presentación de resultados.

4.2. Alcance de la investigación

El análisis se centra en tres patrones de motricidad visualmente observables: aleteo de manos, balanceo corporal y movimientos repetitivos de cabeza. Estos patrones se consideran clases de análisis dentro de los modelos, sin que ello implique la emisión de un diagnóstico clínico definitivo.

4.3. Especificaciones de diseño y arquitectura del sistema

El análisis se realiza a partir de videos previamente seleccionados y etiquetados, que sirven como fuente de datos para el entrenamiento y la evaluación de los modelos. Por tanto, la propuesta no busca establecer un diagnóstico clínico definitivo, sino apoyar la identificación de patrones de motricidad que puedan orientar una posterior evaluación profesional.

Desde el punto de vista técnico, el diseño contempla cinco etapas principales: organización del conjunto de videos, preprocesamiento de fotogramas, construcción de los modelos de inteligencia artificial, evaluación comparativa del desempeño e integración del modelo seleccionado en una plataforma web. En la primera etapa, los videos se clasifican según la conducta predominante observada. Posteriormente, se extraen los fotogramas, se normalizan las imágenes y se preparan los datos para su procesamiento computacional.

Para el análisis se utilizan dos enfoques de modelado. El primero consiste en una red neuronal convolucional (CNN) propia, entrenada desde cero, que permite extraer características espaciales de los fotogramas y clasificarlos según los patrones de motricidad establecidos. El segundo utiliza una arquitectura híbrida ResNet50-LSTM, en la que ResNet50, preentrenada con ImageNet, extrae características visuales de cada fotograma, mientras que la red LSTM procesa la secuencia temporal de dichas características para reconocer patrones repetitivos a lo largo del video.

La utilización de ambos enfoques permite estudiar las diferencias entre la clasificación basada en características espaciales y aquella que incorpora información temporal. Para ello, se compara el desempeño de los modelos utilizando las mismas clases de análisis, los mismos conjuntos de datos y métricas de evaluación, considerando las características y limitaciones de cada arquitectura. Esta comparación permitió determinar que ResNet50-LSTM presenta mejores resultados para el conjunto de datos utilizado, por lo que fue el modelo integrado en el prototipo web.

El desempeño de los modelos se evalúa mediante métricas cuantitativas de clasificación, tales como precisión, recall y F1-score. Asimismo, se analizan las matrices de confusión para identificar los aciertos y errores de clasificación en cada una de las clases.

La Figura 4.1 presenta la arquitectura funcional del prototipo web implementado para apoyar la identificación de patrones de motricidad asociados al Trastorno del Espectro Autista. A continuación se describen las interacciones entre sus componentes tal como funcionan en la versión actual del prototipo.

Interacción en el cliente (frontend). La interfaz web se organiza en cuatro secciones: Inicio, Analizar video, Historial e Información. El análisis de un video sigue un flujo guiado de tres pasos. En el primer paso, el usuario selecciona un archivo en formato MP4, MOV, AVI o WEBM, o lo arrastra a la zona de carga; también dispone de la opción de probar el sistema con un video de ejemplo. En el segundo paso, el sistema informa el estado del procesamiento mientras el video se analiza. En el tercer paso se presenta el resultado preliminar.

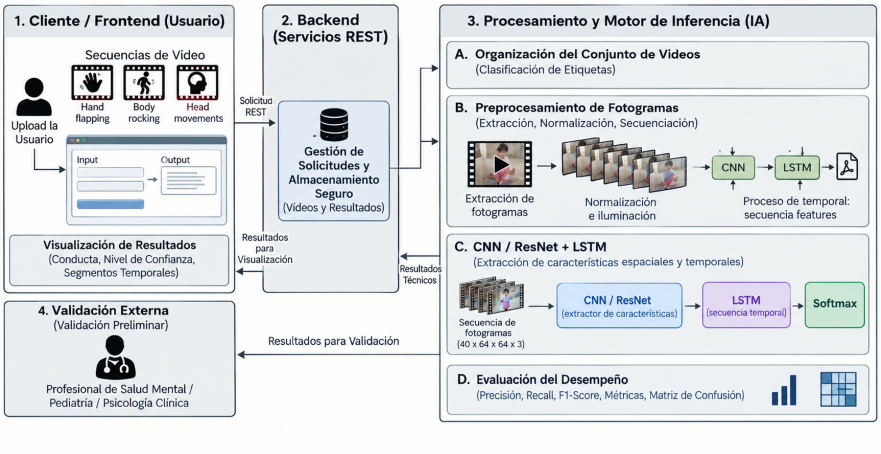


Figura 4.1: Arquitectura funcional para el prototipo web de apoyo a la identificación de patrones de motricidad.

Comunicación con el servidor (backend). Al confirmar la carga, el frontend envía el video al backend mediante una solicitud HTTP a un servicio REST. El backend recibe el archivo, comprueba que su formato sea admitido, aplica el mismo preprocesamiento utilizado en el entrenamiento (extracción de 40 fotogramas, mejora de contraste, redimensión a 64×64 y normalización) y entrega las secuencias resultantes al motor de inferencia.

Inferencia. El motor de inferencia carga el modelo ResNet50-LSTM entrenado. Las características de ResNet50 se calculan para cada fotograma y la LSTM las procesa como secuencia, devolviendo la probabilidad de cada una de las tres clases. Como el video cargado por el usuario no tiene una ventana de conducta anotada, el análisis se realiza sobre segmentos del video, y la clase que aparece con mayor frecuencia se informa como el movimiento más frecuente.

Resultado devuelto al usuario. El backend responde con los datos del análisis y el frontend los presenta en una pantalla de resultado preliminar. Esta pantalla muestra el nombre del archivo, la fecha y la duración del video, una imagen del video, el movimiento más frecuente identificado, su nivel de confianza (expresado como porcentaje y como una indicación cualitativa, por ejemplo «coincidencia alta»), una descripción del patrón y el tiempo total y la cantidad de momentos del video en que apareció. Junto con el resultado se muestra siempre un aviso que aclara que se trata de un resultado preliminar, que no constituye un diagnóstico y que conviene compartirlo con

un profesional de la salud.

La validación del funcionamiento del sistema con un profesional vinculado al área del TEA (pediatría, neurología infantil, psicología clínica o desarrollo infantil) está prevista como etapa posterior y aún no se ha realizado. Esta validación tendrá carácter complementario y no reemplazará el diagnóstico clínico profesional.

4.4. Obtención de datos

4.4.1. Delimitación del estudio de los datos

El estudio se delimita a la clasificación de segmentos de video en tres conductas motoras estereotipadas descritas en la literatura sobre el TEA: aleteo de manos (*ArmFlapping*), movimientos repetitivos de cabeza (*HeadBanging*) y balanceo corporal (*Spinning*). Cada segmento se trata como una unidad de análisis independiente y recibe exactamente una de las tres etiquetas, por lo que el problema se formula como una clasificación multiclase de una sola etiqueta por secuencia.

Quedan fuera del alcance los videos sin conducta anotada, la clasificación de la ausencia de conductas, la detección de otras manifestaciones del TEA (por ejemplo, contacto visual o lenguaje) y la determinación de la edad, el sexo o el diagnóstico de la persona filmada. El modelo no recibe información clínica alguna, sino que procesa únicamente los fotogramas extraídos de los videos.

4.4.2. Selección de videos y fuentes

Como fuente de datos se utilizó el conjunto público *Self-Stimulatory Behaviour Dataset* (SSBD), que reúne videos de conductas autoestimulatorias de niños obtenidos de plataformas abiertas, con anotaciones de los intervalos temporales en los que ocurre cada conducta. Se contó con 75 anotaciones, distribuidas de forma equilibrada, con 25 anotaciones por clase, todas provenientes de YouTube. Al tratarse de material de acceso público utilizado con fines de investigación, no se realizaron grabaciones propias de menores de edad.

Las anotaciones se organizaron en un archivo de etiquetas `labels_TEA.csv`, que contiene el identificador del video, la clase asignada y los instantes de inicio y fin de cada ventana temporal. Este archivo se utilizó como referencia para localizar los segmentos correspondientes a las conductas de interés y organizar los datos para su posterior procesamiento.

Durante la selección se descartaron los videos que no estaban disponibles, presentaban enlaces rotos o no permitían observar la conducta anotada porque la persona quedaba fuera de cuadro. Después de aplicar estos criterios, se trabajó inicialmente con 57 videos. De cada video se extrajeron 40 fotogramas (Sección 4.4.4), por lo que el conjunto inicial quedó compuesto por $57 \times 40 = 2\,280$ fotogramas. La Tabla 4.1 presenta la distribución de las anotaciones, los videos y los fotogramas por categoría.

El tamaño reducido del conjunto inicial constituye una limitación del estudio y podrá ampliarse en etapas posteriores.

4.4.3. Criterios de selección, exclusión y verificación de los videos

Para garantizar que los datos utilizados fueran adecuados para el objetivo de clasificación, se establecieron criterios de selección y exclusión relacionados con la disponibilidad del material audiovisual, la correspondencia con las anotaciones y la visibilidad de la conducta motora.

Se consideraron como criterios de inclusión la disponibilidad del video, la posibilidad de acceder al intervalo temporal anotado y la visibilidad suficiente de la conducta de interés para extraer los fotogramas correspondientes. Por otra parte, se excluyeron los registros cuyos videos no estaban disponibles, presentaban enlaces rotos o no permitían observar la conducta debido a que la persona quedaba fuera de cuadro. Estos criterios permitieron reducir la incorporación de secuencias sin información visual útil para la clasificación.

La asignación de las clases se basó en las anotaciones disponibles en el conjunto SSBD. Para cada registro se conservaron el identificador del video, la categoría de conducta y los instantes de inicio y fin del intervalo anotado. Las etiquetas se utilizaron para organizar los videos en las tres clases definidas en el estudio, sin incorporar información clínica adicional ni inferir un diagnóstico a partir de las imágenes.

La verificación de los datos comprendió la comprobación de la correspondencia entre los intervalos temporales anotados y los segmentos seleccionados para la extracción de fotogramas. Asimismo, se consideró la revisión visual de las secuencias para comprobar la visibilidad de la conducta y la correspondencia con la categoría asignada. Se verificó también que cada secuencia estuviera asociada a una única etiqueta y contuviera 40 fotogramas.

Cuando un fotograma no podía decodificarse, se reintentaba su lectura en posiciones temporales cercanas. Si el problema persistía, se repetía el último fotograma válido hasta completar la secuencia. Este procedimiento permitió mantener una longitud uniforme para los datos utilizados en el procesamiento

de los modelos.

La verificación visual permite comprobar la correspondencia entre los datos procesados y las anotaciones disponibles, pero no constituye una validación clínica de las conductas observadas. Por tanto, las clases utilizadas representan categorías de análisis visual y no diagnósticos clínicos.

Tabla 4.1: Distribución de videos y fotogramas por categoría.

Clase	**Anotaciones**	**Videos**	**Fotogramas**	**Porcentaje**
Aleteo de manos	25	20	800	35,1 %
Movimientos de cabeza	25	18	720	31,6 %
Balanceo corporal	25	19	760	33,3 %
Total	**75**	**57**	**2 280**	**100 %**

División en entrenamiento, validación y prueba. La división de los datos se realizó por video, de modo que los 40 fotogramas de un mismo video no se distribuyeran entre diferentes conjuntos. En primer lugar, se separó aproximadamente el 25 % de los videos como conjunto de prueba, mediante una división estratificada por clase y con semilla fija (42). De esta forma, se obtuvieron 42 videos para el conjunto de desarrollo y 15 para el conjunto de prueba.

Posteriormente, del conjunto de desarrollo se reservó aproximadamente el 20 % de los videos para validación, también mediante una división estratificada. Este conjunto se utiliza exclusivamente para supervisar el entrenamiento y aplicar la parada temprana. El conjunto de prueba se mantiene separado y no interviene en las decisiones de entrenamiento ni en la selección de los modelos.

La distribución final de los videos se presenta en la Tabla 4.2.

Al conjunto de entrenamiento se le añade la versión especular de cada secuencia (Sección 4.5.2), con lo que se dispone de 66 secuencias para el entrenamiento, equivalentes a 2 640 fotogramas, de los cuales la mitad corresponde a versiones reflejadas. La validación y la prueba no se aumentan, con el propósito de evaluar los modelos sobre secuencias que no hayan sido modificadas mediante esta técnica.

Debido al tamaño reducido del conjunto de prueba, los resultados obtenidos a partir de los 15 videos pueden presentar variabilidad. Por este motivo, se complementa la evaluación con validación cruzada de cinco pliegues sobre los 57 videos (Sección 4.7).

Tabla 4.2: División de los videos en entrenamiento, validación y prueba.

Clase	**Entrenamiento**	**Validación**	**Prueba**	**Total**
Aleteo de manos	12	3	5	20
Movimientos de cabeza	10	3	5	18
Balanceo corporal	11	3	5	19
Videos	**33**	**9**	**15**	**57**
Fotogramas	1 320	360	600	2 280
Porcentaje	57,9 %	15,8 %	26,3 %	100 %

La duración de las ventanas anotadas es heterogénea. La mediana global es de 9 segundos, con medianas de 6 segundos para aleteo de manos, 9 segundos para movimientos repetitivos de cabeza y 13 segundos para balanceo corporal. La duración mínima registrada es de 3 segundos y la máxima de 69 segundos.

4.4.4. Extracción de fotogramas por ventana de conducta

En lugar de procesar el video completo, se extrajeron fotogramas únicamente dentro de la ventana temporal en la que la conducta está anotada. De este modo, cada secuencia se concentra en el movimiento de interés y se reduce la incorporación de segmentos irrelevantes.

Para cada ventana se seleccionaron $T = 40$ fotogramas equiespaciados entre los instantes de inicio y fin. Así, todas las secuencias presentan la misma longitud, independientemente de la duración de la conducta. Considerando una ventana de duración mediana de 9 segundos, se obtiene una frecuencia de muestreo aproximada de 4,4 fotogramas por segundo.

Cuando un fotograma no podía decodificarse, se reintentaba su lectura en posiciones temporales cercanas y, si el fallo persistía, se repetía el último fotograma válido hasta completar los 40 fotogramas requeridos. Las imágenes extraídas se almacenaron en una carpeta correspondiente a cada video, lo que facilita su identificación, organización y revisión visual antes del entrenamiento de los modelos.

4.5. Preprocesamiento

La Figura 4.2 resume el flujo desde el video original hasta el tensor que recibe el modelo, y las Figuras 4.3, 4.4 y 4.5 muestran el efecto de cada etapa sobre un video real de la clase *HeadBanging*. Todos los parámetros del preprocesamiento (longitud de secuencia, tamaño de imagen, activación de cada filtro) se concentran en un único archivo de configuración, lo que garantiza que el entrenamiento y la aplicación web apliquen exactamente las mismas transformaciones.

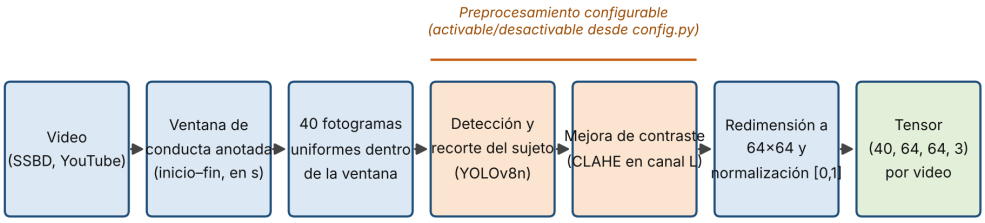


Figura 4.2: Flujo de preprocesamiento: de la ventana anotada al tensor de entrada del modelo.

4.5.1. Normalización de imágenes

Cada fotograma se lee con OpenCV y se procesa en el siguiente orden:

1. **Mejora de contraste (CLAHE).** Se aplica ecualización adaptativa del histograma con límite de contraste sobre el canal de luminosidad (L) del espacio LAB, con límite de recorte de 2,0 y cuadrícula de 8×8. Al trabajar solo sobre la luminosidad se conserva el color original. Su propósito es compensar la iluminación irregular de los videos domésticos.

2. **Redimensionado.** El fotograma se redimensiona directamente a 64×64 píxeles, sin conservar la relación de aspecto, de modo que todas las secuencias tengan las mismas dimensiones. Se eligió esta resolución como compromiso entre la información visual necesaria para distinguir posturas y el costo de memoria: una secuencia de 40 fotogramas ocupa

$40 \times 64 \times 64 \times 3$ valores, y el conjunto completo debe caber en la memoria de un entorno de ejecución gratuito.

3. **Escalado.** Los valores de píxel se convierten a RGB y se dividen por 255 para llevarlos al rango $[0, 1]$, lo que estabiliza la optimización.

Entrada de la ResNet50. Para ingresar a la ResNet50, cada fotograma de 64×64 se amplía a 224×224 (el tamaño con que fue preentrenada la red), se devuelve a la escala 0–255 y se le aplica la normalización propia de ImageNet (conversión a BGR y resta de la media por canal). Esta etapa forma parte del extractor y no tiene parámetros entrenables.

Ejemplos del efecto de cada etapa. La Figura 4.3 presenta, para dos fotogramas de un video de *HeadBanging*, el resultado de cada transformación: el fotograma original, el resultado de CLAHE, la imagen de 64×64 píxeles con valores en $[0, 1]$, su ampliación a 224×224 y la imagen tras la normalización de ImageNet. CLAHE realza el contraste local (textura del sofá, rasgos del rostro y pliegues de la ropa) sin alterar los colores. La reducción a 64×64 elimina detalle fino pero conserva la postura general del cuerpo y de la cabeza, que es la información que interesa para el análisis del movimiento; la ampliación posterior a 224×224 no recupera ese detalle, solo adapta el tamaño a la entrada de la red. Por último, la normalización de ImageNet desplaza los valores alrededor de cero, por lo que la última columna se muestra reescalada únicamente para poder visualizarla.



Figura 4.3: Efecto de cada etapa del preprocesamiento sobre dos fotogramas de un video de *HeadBanging* ($t = 11$ y $t = 31$). De izquierda a derecha: original, tras CLAHE, normalizado a 64×64 con valores en $[0, 1]$, ampliado a 224×224 (entrada de la ResNet50) y tras la normalización de ImageNet. *Reescalada solo para su visualización.

Las etiquetas se codifican en formato *one-hot* de tres posiciones. El resultado de esta etapa es un arreglo de dimensiones $(N, 40, 64, 64, 3)$ en punto flotante de 32 bits, donde N es el número de videos.

4.5.2. Generación de secuencias de video

Cada video se representa como una secuencia ordenada de 40 imágenes, que es la unidad que consumen las capas recurrentes. Los 40 fotogramas se toman a intervalos regulares dentro de la ventana anotada, y el orden temporal se conserva estrictamente, ya que el patrón repetitivo se manifiesta en la evolución del movimiento y no en un fotograma aislado. La Figura 4.4 muestra la secuencia generada para un video de *HeadBanging*: los 40 fotogramas, numerados en orden temporal, ya procesados y con el tamaño que recibe el modelo.

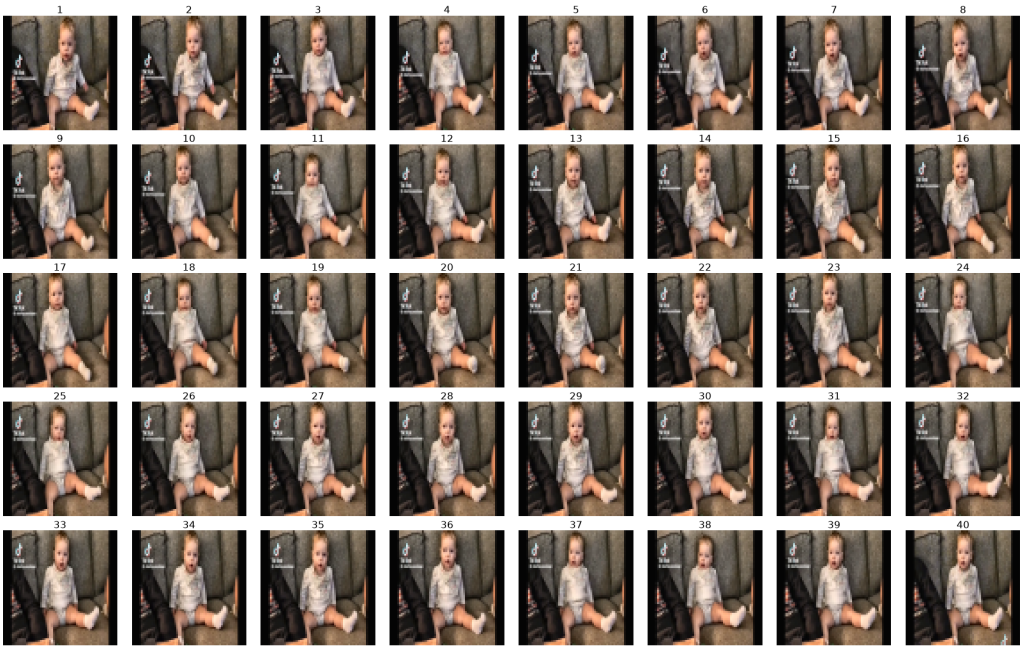


Figura 4.4: Secuencia de 40 fotogramas de 64×64 píxeles generada para un video de *HeadBanging* (lectura de izquierda a derecha y de arriba abajo, $t = 1, \ldots, 40$).

La partición en entrenamiento, validación y prueba se realizó a nivel de video, como se describió en la Sección 4.4.4 y en la Tabla 4.2, con la estratificación por clase y la semilla fija de scikit-learn, de modo que ninguna secuencia del conjunto de prueba procede de un video usado para entrenar.

Para ampliar el conjunto de entrenamiento se aplicó aumento de datos por reflexión horizontal: cada secuencia se duplica con su versión especular (Figura 4.5). El aumento se realiza únicamente después de la partición y solo sobre el entrenamiento, para evitar que una versión espejada de un video de prueba contamine el aprendizaje. La reflexión es adecuada porque las tres conductas no dependen de la lateralidad del cuerpo. Como el extractor ResNet50 está congelado, las características de la versión original y de la especular de cada video se calculan una sola vez y se reutilizan en todas las épocas.

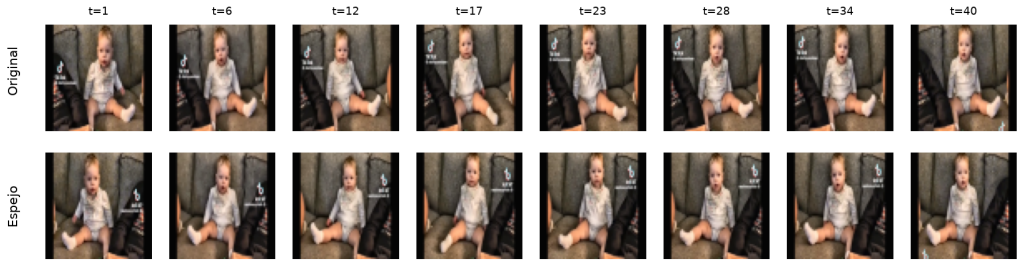


Figura 4.5: Aumento de datos por reflexión horizontal: fotogramas de una secuencia original (arriba) y su versión especular (abajo).

4.6. Diseño y entrenamiento del modelo

El modelo sigue el enfoque de redes convolucionales recurrentes de largo plazo : una red convolucional procesa cada fotograma por separado y una LSTM integra la secuencia de características resultante. Se evaluaron dos arquitecturas que comparten exactamente el mismo clasificador temporal y se diferencian únicamente en el extractor espacial (Tabla 4.3): una red convolucional **propia**, entrenada **desde cero**, y una **ResNet50 preentrenada** en ImageNet. Ambas se comparan en el capítulo de Resultados; el prototipo web integra la variante con ResNet50 + LSTM.

Flujo de trabajo. La Figura 4.6 resume el procedimiento completo. Primero se carga la configuración, que concentra los hiperparámetros de entrenamiento, el preprocesamiento y los parámetros de la división. En el Paso 1 se extraen los fotogramas de cada ventana de conducta y se arma el tensor del conjunto. En el Paso 2 se dividen los videos en entrenamiento, validación y prueba y se aplica el aumento por reflexión al entrenamiento. A continuación, cada modelo se entrena y se evalúa por turnos, con parada temprana, y en el Paso 3 se comparan ambos mediante validación cruzada de 5 pliegues.

4.6.1. Extractor espacial: ResNet50 (capa espacial)

Como extractor de características visuales del modelo del prototipo se utiliza ResNet50 [33], una red convolucional residual de 50 capas cuyo bloque fundamental es

$$y = F(x, \{W_i\}) + x, \tag{4.1}$$

Tabla 4.3: Arquitecturas evaluadas.

Característica	**CNN-LSTM propia**	**ResNet50 + LSTM**
Origen de los pesos del extractor	Inicializados al azar; se aprenden con los videos del proyecto (**desde cero**)	**Preentrenados** en ImageNet y **congelados** (no se reajustan)
Extractor espacial	4 bloques convolucionales (16–64 filtros)	ResNet50 de 50 capas con conexiones residuales
Entrada al extractor	$64 \times 64 \times 3$	$224 \times 224 \times 3$ (ampliada)
Características por fotograma	64	2 048, proyectadas a 64
Parámetros entrenables	73 027	143 651
Parámetros congelados	0	23,5 millones
Estrategia	Entrenamiento completo	Extracción de características (aprendizaje por transferencia)
Rol en el trabajo	Referencia de comparación	Modelo integrado en el prototipo

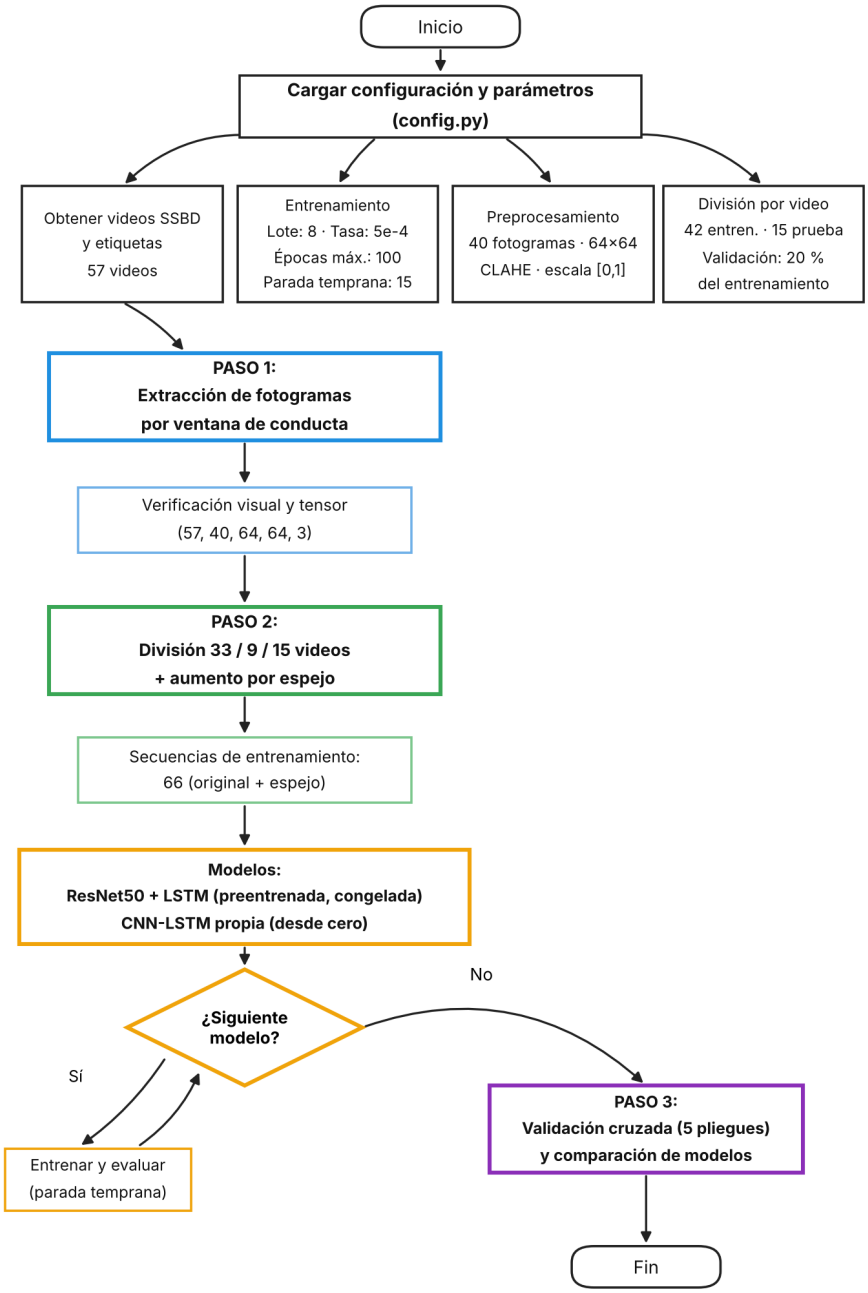


Figura 4.6: Diagrama de flujo del proceso de entrenamiento y evaluación.

donde x es la entrada del bloque, $F(x, \{W_i\})$ la transformación convolucional con pesos $\{W_i\}$ e y su salida. La conexión de atajo $(+\,x)$ permite que la información y el gradiente fluyan directamente y evita la degradación en redes profundas.

La red se emplea **preentrenada**, con los pesos de ImageNet, y **congelada**: no se entrena desde cero ni se reajusta (*fine-tuning*) durante el proyecto, sino que se aplica la estrategia de extracción de características del aprendizaje por transferencia [**?**]. Se elimina su clasificador final (`include_top=False`) y se aplica un promedio global (*global average pooling*), de modo que cada fotograma queda representado por un vector de 2 048 características. La red se aplica a los 40 fotogramas de la secuencia mediante `TimeDistributed`, con los mismos pesos para todos.

Se eligió el aprendizaje por transferencia porque con 33 videos de entrenamiento una red de 23,5 millones de parámetros entrenada desde cero se sobreajustaría de inmediato, mientras que las características aprendidas en ImageNet (bordes, texturas, partes del cuerpo) son reutilizables. Como los pesos no cambian, las características de cada video (y de su versión especular) se calculan una sola vez y se almacenan, lo que reduce el tiempo de entrenamiento de forma considerable.

4.6.2. Extractor alternativo: CNN propia (desde cero)

Como referencia de comparación se diseñó una red convolucional ligera, aplicada a cada fotograma mediante `TimeDistributed` y entrenada completamente desde cero. Consta de cuatro bloques que combinan una convolución de 3×3 con activación ReLU y *max pooling*, con *dropout* de 0,3 en los tres primeros, y termina en un vector de 64 características por fotograma (Tabla 5.2). La Figura 4.7 muestra su arquitectura. Se optó por pocos filtros y reducciones espaciales agresivas porque el conjunto de entrenamiento es de decenas de videos; el modelo completo suma 73 027 parámetros.

Tabla 4.4: Capas del extractor CNN propio (por fotograma).

Bloque	**Filtros**	**Pooling**	**Dropout**	**Salida**
Entrada	–	–	–	$64 \times 64 \times 3$
1	16	4×4	0,3	$16 \times 16 \times 16$
2	32	4×4	0,3	$4 \times 4 \times 32$
3	64	2×2	0,3	$2 \times 2 \times 64$
4	64	2×2	–	$1 \times 1 \times 64$
Aplanado	–	–	–	64

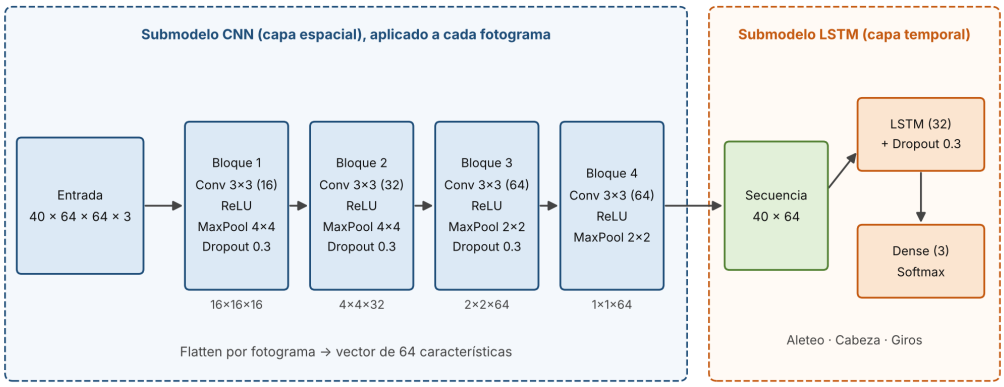


Figura 4.7: Arquitectura CNN-LSTM propia, entrenada desde cero (modelo de referencia).

4.6.3. Arquitectura LSTM (capa temporal)

El clasificador temporal es común a ambos modelos. En la variante con ResNet50, la secuencia de 40 vectores de 2 048 componentes se proyecta, fotograma a fotograma, a 64 dimensiones mediante una capa densa con activación ReLU (`TimeDistributed`); esta proyección sí es entrenable y adapta las características generales de ImageNet a la tarea. En la CNN propia los vectores ya tienen 64 componentes. A continuación, una capa LSTM de 32 unidades resume la secuencia en un único vector (se conserva el último estado), seguida de *dropout* de 0,3 y una capa densa de tres neuronas con activación *softmax* que entrega la probabilidad de cada clase. La memoria de la LSTM permite detectar la repetición periódica del movimiento, rasgo distintivo de las conductas estereotipadas. En el modelo con ResNet50, la parte entrenable suma 143 651 parámetros, frente a los 23,5 millones congelados de la red (Tabla 4.5).

4.6.4. Integración del modelo y selección de la arquitectura

Los modelos se implementaron con la API funcional de Keras sobre TensorFlow. En la variante con ResNet50, dado que el extractor está congelado, el entrenamiento se divide en dos pasos: (1) el cálculo único de las características de ResNet50 para cada video original y su versión especular, y (2) el entrenamiento de la proyección y la LSTM sobre esas características. En

Tabla 4.5: Capas del modelo ResNet50 + LSTM.

Etapa	**Capa**	**Salida**	**Entrenable**
Entrada	Secuencia de fotogramas	$(40, 64, 64, 3)$	–
Preproceso	Ampliación a 224×224 y normalización ImageNet	$(40, 224, 224, 3)$	No
Extractor	ResNet50 (ImageNet) + pooling global	$(40, 2048)$	No
Proyección	Dense(64), ReLU, por fotograma	$(40, 64)$	Sí
Temporal	LSTM(32) + Dropout(0,3)	(32)	Sí
Salida	Dense(3), softmax	(3)	Sí

la CNN propia, el extractor y la LSTM se entrenan conjuntamente.

La comparación de ambas arquitecturas se realiza con el procedimiento descrito en la Sección 4.7, y sus resultados se presentan en el capítulo correspondiente. El prototipo web integra la variante ResNet50 + LSTM.

4.6.5. Hiperparámetros de entrenamiento y épocas

El entrenamiento minimiza la entropía cruzada categórica con el optimizador Adam. Los hiperparámetros son los mismos para ambos modelos, de modo que la comparación sea justa (Tabla 4.6).

Épocas. Una época equivale a una pasada completa por las 66 secuencias de entrenamiento (originales y espejadas), en lotes de 8, es decir, 9 actualizaciones de pesos por época. Se fijó un máximo de 100 épocas, pero el número real lo determina la **parada temprana** (*early stopping*) el entrenamiento se interrumpe cuando la pérdida sobre los 9 videos de validación no mejora durante 15 épocas consecutivas y se restauran los pesos de la mejor época. De esta forma la cantidad de épocas no se fija a mano, sino que se ajusta a cada corrida y reduce el sobreajuste. El número de épocas efectivamente ejecutadas en cada corrida se registra y se informa en el capítulo de Resultados.

La Figura 4.8 muestra la definición de los hiperparámetros y de los demás parámetros del algoritmo en el archivo de configuración (`config.py`), del cual

Tabla 4.6: Hiperparámetros de entrenamiento (comunes a ambos modelos).

Parámetro	**Valor**
Extractor espacial (modelo del prototipo)	ResNet50 preentrenada en ImageNet, congelada
Extractor espacial (referencia)	CNN propia, entrenada desde cero
Optimizador	Adam
Función de pérdida	Entropía cruzada categórica
Tasa de aprendizaje	5×10^{-4}
Recorte de gradiente (*clipnorm*)	1,0
Tamaño de lote	8
Épocas máximas	100
Parada temprana (paciencia)	15 épocas sobre la pérdida de validación
Épocas efectivas por corrida	Definidas por la parada temprana
Proporción de validación	20 % del entrenamiento (9 videos)
Dropout en la LSTM	0,3
Dropout en la CNN propia	0,3
Regularización L2	0 (desactivada)
Aumento de datos	Reflexión horizontal (duplica el entrenamiento)
Semilla base	42

leen todos los *scripts* de preprocesamiento, entrenamiento y evaluación, de modo que cada experimento queda documentado por un único conjunto de valores.

```
CONFIG = {
    'sequence_length': 40,
    'image_size': 64,
    'test_size': 0.2,
    'seed': 42,

    'batch_size': 8,
    'learning_rate': 5e-4,
    'clipnorm': 1.0,
    'epochs': 100,
    'early_stopping_patience': 15,

    'semilla_inicio': 0,
    'semilla_fin': 10,
    'umbral_accuracy': 0.6,
    'kfold_splits': 5,
    'kfold_repeticiones': 1,

    'frames_dir': 'Frames_TEA_yolo_clahe',


    'yolo_margen': 0.3,
    'yolo_suavizado': 0.6,
    'usar_clahe': True,
    'clahe_clip_limit': 2.0,
    'clahe_tile_grid': 8,


    'augmentation_multiplier': 2,
    'horizontal_flip': True,

    'usar_batch_norm': False,
    'dropout_cnn': 0.3,
    'dropout_lstm': 0.3,
    'l2_reg': 0.0,
}
```

Figura 4.8: Definición de hiperparámetros y parámetros en el archivo de configuración (`config.py`).

Entorno experimental. El cálculo de características y el entrenamiento se ejecutaron en Google Colaboratory, con los datos almacenados en Google Drive, mientras que el preprocesamiento de video y la depuración del código se realizaron en el equipo local (Capítulo 3). Se empleó Python con TensorFlow/Keras, OpenCV y scikit-learn.

Como control del sobreajuste se emplea *dropout* con valor 0,3, además de la parada temprana y el aumento por reflexión. Debido a que el conjunto

de prueba es de solo 15 videos, el resultado de un único entrenamiento es muy sensible a la inicialización de los pesos de la proyección y la LSTM. Por ello se estudió la variabilidad entre semillas aleatorias (Sección 4.7). Seleccionar la mejor semilla observando el conjunto de prueba introduce un sesgo optimista; por esa razón los resultados principales se reportan mediante validación cruzada.

4.7. Evaluación del modelo

La evaluación sigue tres niveles, de menor a mayor robustez estadística.

Partición fija. Se entrena con los 33 videos de entrenamiento (más su versión especular), se vigila la pérdida sobre los 9 de validación y se mide el desempeño sobre los 15 videos de prueba. Se repite el procedimiento con un rango de semillas (por ejemplo, de 0 a 10), dado que la inicialización aleatoria puede alterar de forma apreciable el resultado , y se informan el promedio y la desviación estándar de la exactitud, con el fin de cuantificar la sensibilidad a la inicialización.

Validación cruzada estratificada . Dado que 15 videos producen estimaciones muy inestables, los 57 videos se reúnen y se reparten en $k = 5$ pliegues estratificados por clase. Cada video se evalúa una vez con un modelo que no lo vio durante el entrenamiento; dentro de cada pliegue, una parte del entrenamiento se reserva para la parada temprana y el aumento por reflexión se aplica solo al entrenamiento. Las predicciones de todos los pliegues se concatenan para calcular las métricas globales fuera de muestra, y se registra además el número de épocas de cada pliegue.

Comparación de arquitecturas. Los mismos pliegues, la misma semilla y el mismo clasificador LSTM se emplean para la CNN propia (referencia) y para ResNet50 + LSTM, de modo que la diferencia observada se deba al extractor de características. Con solo 15 videos de prueba, cada video equivale a 6,7 puntos porcentuales de exactitud, por lo que las diferencias pequeñas entre variantes no son concluyentes con la partición fija y se contrastan con la validación cruzada.

Las métricas de clasificación son la exactitud (*accuracy*), la precisión, la exhaustividad (*recall*) y la medida F1 por clase:

$$\begin{aligned} \text{Exactitud} &= \frac{VP + VN}{VP + VN + FP + FN}, \\ \text{Precisión} &= \frac{VP}{VP + FP}, \qquad \text{Recall} = \frac{VP}{VP + FN}. \end{aligned} \tag{4.2}$$

$$F_1 = 2 \cdot \frac{\text{Precisión} \cdot \text{Recall}}{\text{Precisión} + \text{Recall}}. \tag{4.3}$$

4.8. Desarrollo e integración de la aplicación web

Con el fin de poner el modelo a disposición de un usuario no técnico, se desarrolló un prototipo de aplicación web. Se trata de una versión funcional orientada a demostrar el flujo completo, desde la carga de un video hasta la visualización de un resultado preliminar, y no de un producto final.

4.8.1. Análisis de requisitos

Se identificaron los requisitos funcionales y no funcionales esenciales para el prototipo, priorizando la carga del video, el análisis automático y la presentación comprensible del resultado. Su descripción se resume en la Tabla 4.7.

Tabla 4.7: Requisitos y características del prototipo.

Requisito	**Descripción**	**Prioridad**
Carga de video	Componente que permita seleccionar o arrastrar un video en formatos MP4, MOV, AVI o WEBM	Alta
Análisis automático	Procesamiento del video con el modelo ResNet50 + LSTM y obtención de la conducta más frecuente	Alta
Resultado con nivel de confianza	Presentación del movimiento identificado, su descripción en lenguaje sencillo y el nivel de confianza	Alta
Aviso de no diagnóstico	Mensaje visible que indique que el resultado es orientativo y no reemplaza la evaluación profesional	Alta
Interfaz intuitiva	Flujo guiado en tres pasos y lenguaje comprensible para familias	Alta
Protección de datos	Uso del video únicamente para el análisis solicitado y resguardo de la información	Alta
Información	Sección con la descripción de los movimientos observados y de los alcances del sistema	Media

4.8.2. Arquitectura tecnológica

El prototipo sigue una arquitectura cliente–servidor de tres capas, coherente con la Figura 4.1. El *frontend* se desarrolló con Next.js, React y TypeScript, con estilos en Tailwind CSS, gráficos con Recharts y comunicación con el servidor mediante Axios. El *backend* es un servicio REST desarrollado con FastAPI sobre Uvicorn, con validación de datos mediante Pydantic y recepción de archivos con `python-multipart`; la autenticación prevista utiliza tokens JWT (`python-jose`). Los usuarios, los metadatos de los análisis y los resultados se almacenan en Cloud Firestore.

4.8.3. Integración del modelo

Al recibir un video, el servicio aplica *exactamente* el mismo preprocesamiento que en el entrenamiento (extracción de 40 fotogramas, mejora de contraste, redimensión y normalización), ejecuta el modelo ResNet50 + LSTM y devuelve la clase predicha con su nivel de confianza. Como la ventana de conducta de un video cargado por un usuario no está anotada, el sistema debe dividir el video en segmentos y clasificar cada uno, o bien analizar el video completo como una única secuencia de 40 fotogramas, y resumir la conducta más frecuente y los momentos en que aparece.

4.8.4. Interfaz de usuario

La interfaz se construyó con componentes reutilizables y un menú lateral con las secciones *Inicio*, *Analizar video*, *Historial* e *Información*. La pantalla de inicio (Figura 4.9) da la bienvenida al usuario, explica en lenguaje sencillo qué hace el sistema, ofrece los accesos a un nuevo análisis y a los análisis anteriores, y muestra de forma destacada el aviso de que los resultados son orientativos y no constituyen un diagnóstico.

El análisis se guía en tres pasos. En el primero (Figura 4.10), el usuario selecciona un video o lo arrastra a la zona de carga; se indican los formatos admitidos y se recomienda elegir un video donde el niño o la niña se vea de cuerpo entero. También se ofrece un video de ejemplo para probar el sistema sin cargar material propio.

En el último paso (Figura 4.11) se presenta el resultado preliminar: el nombre del archivo, la fecha y la duración del video, una imagen representativa, el movimiento más frecuente con su descripción en lenguaje sencillo, la cantidad de momentos del video en que aparece y el nivel de confianza expresado en porcentaje. Se mantiene visible el aviso de que el resultado no



Figura 4.9: Pantalla de inicio del prototipo.

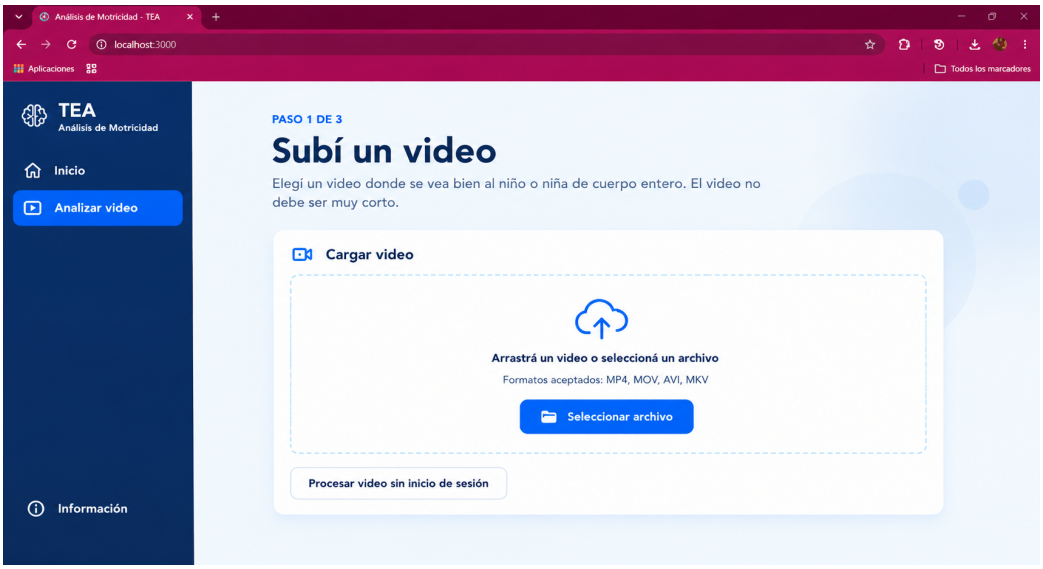


Figura 4.10: Paso 1 del análisis: carga del video.

confirma ni descarta el autismo y se recomienda compartirlo con un profesional de la salud.

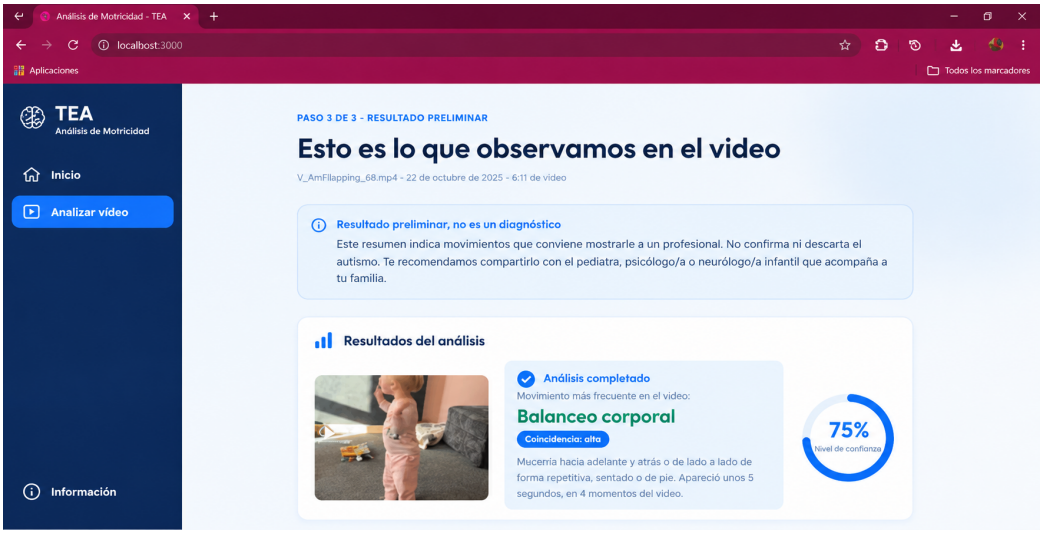


Figura 4.11: Paso 2 del análisis: resultado preliminar con nivel de confianza.

4.8.5. Protección de datos y validación

Se contemplan medidas de protección acordes con la naturaleza sensible del material: el video se utiliza únicamente para el análisis solicitado, el acceso se restringe mediante autenticación y no se registran datos de identificación personal. La validación funcional del prototipo está prevista con la participación de un profesional vinculado al área del TEA, quien evalúa la utilidad y claridad de los resultados mediante un cuestionario con escala de Likert.

4.9. Diseño de pruebas

Las pruebas se organizan por nivel, desde los componentes individuales hasta la valoración por un experto (Tabla 4.8).

Tabla 4.8: Diseño de pruebas del sistema.

Nivel	**Qué se verifica**	**Criterio de aceptación**
Unitarias del extractor CNN propio (TC-CNN-01 a 07)	Dimensiones de entrada y salida, número de parámetros, ausencia de valores NaN, determinismo con semilla fija, comportamiento con `TimeDistributed` y con lotes de distinto tamaño	Todas las pruebas automáticas aprobadas
Unitarias del clasificador LSTM (TC-LSTM-01 a 05)	Forma de la salida $(\cdot, 3)$, probabilidades que suman 1, aprendizaje de una secuencia sintética, rechazo de entradas inválidas	Todas las pruebas automáticas aprobadas
Integración del modelo	El modelo ResNet50 + LSTM entrena una época y predice sobre un lote	Salida de dimensión correcta sin errores
Funcionales con videos retenidos	Clasificación de videos que no participaron en el entrenamiento	Métricas de la Sección 4.7
Preprocesamiento	Salida $(40, 64, 64, 3)$ en $[0, 1]$ y consistencia entre entrenamiento y aplicación web	Mismo tensor para el mismo video
Rendimiento	Tiempo de respuesta de la aplicación para un video típico de pocos segundos	Por definir (p. ej., menos de 30 s)
Seguridad	Acceso con y sin token válido; tipo y tamaño de archivo admitidos	Rechazo de solicitudes no autorizadas o inválidas
Validación por experto	Claridad, utilidad y concordancia con la valoración profesional, con escala de Likert de 5 puntos	Por definir según los objetivos del proyecto

Capítulo 5

Resultados

En este capítulo se presentan los resultados obtenidos durante la evaluación de los modelos CNN y ResNet50 + LSTM, desarrollados para clasificar tres patrones de motricidad asociados al trastorno del espectro autista (TEA): aleteo de manos, movimientos repetitivos de cabeza y balanceo corporal.

La evaluación se realizó utilizando un conjunto de prueba compuesto por 15 muestras, distribuidas equitativamente entre las tres clases, con cinco muestras por patrón. Para analizar el desempeño de los modelos se consideraron las métricas Accuracy, F1-Score (Weighted) y F1-Score (Micro). Asimismo, se analizaron las matrices de confusión para identificar los aciertos y errores de clasificación de cada modelo.

5.1. Resultados de la evaluación de los modelos

Evaluación del modelo ResNet50 + LSTM

La Tabla 5.1 presenta las métricas obtenidas por el modelo ResNet50 + LSTM durante la evaluación con el conjunto de prueba.

Tabla 5.1: Métricas de evaluación para ResNet50 + LSTM

Métrica	**Valor**
Accuracy	73,33 %
F1-Score (Weighted)	74,00 %
F1-Score (Micro)	73,33 %

Los resultados muestran que el modelo ResNet50 + LSTM alcanzó una exactitud del 73,33 %, lo que significa que clasificó correctamente 11 de las

15 muestras evaluadas. Las cuatro muestras restantes fueron clasificadas incorrectamente.

En cuanto al F1-Score (Weighted), se obtuvo un valor del 74,00 %, que representa el desempeño global del modelo considerando las métricas de cada clase y su correspondiente cantidad de muestras. Por su parte, el F1-Score (Micro) fue del 73,33 %, coincidiendo con el valor de Accuracy en este problema de clasificación multiclase de etiqueta única.

El análisis individual de las clases muestra que el modelo obtuvo un F1-Score de 0,67 para ArmFlapping, 0,67 para HeadBanging y 0,89 para Spinning. Estos resultados indican un mejor equilibrio entre precisión y sensibilidad en la clasificación de Spinning, mientras que las otras dos clases presentaron mayores dificultades de discriminación.

Evaluación del modelo CNN

La Tabla 5.2 presenta las métricas obtenidas por el modelo CNN.

Tabla 5.2: Métricas de evaluación para CNN

Métrica	**Valor**
Accuracy	60,00 %
F1-Score (Weighted)	57,00 %
F1-Score (Micro)	60,00 %

El modelo CNN obtuvo una exactitud del 60,00 %, equivalente a nueve clasificaciones correctas de un total de 15 muestras. En consecuencia, seis muestras fueron clasificadas incorrectamente.

El F1-Score (Weighted) alcanzó el 57,00 %, lo que refleja un desempeño global inferior al obtenido por ResNet50 + LSTM. Por su parte, el F1-Score (Micro) fue del 60,00 %, coincidiendo con la exactitud global del modelo.

Estos resultados muestran que el modelo CNN presentó mayores dificultades para distinguir algunos de los patrones evaluados. Por lo tanto, resulta pertinente comparar su desempeño con el modelo ResNet50 + LSTM para determinar cuál obtuvo mejores resultados en el conjunto de prueba.

Comparación de los resultados

La Tabla 5.3 presenta la comparación de las principales métricas obtenidas por ambos modelos.

Tabla 5.3: Comparación de métricas entre CNN y ResNet50 + LSTM

Métrica	**CNN**	**ResNet50 + LSTM**	**Diferencia**
Accuracy	60,00 %	73,33 %	13,33 p.p.
F1-Score (Weighted)	57,00 %	74,00 %	17,00 p.p.
F1-Score (Micro)	60,00 %	73,33 %	13,33 p.p.

Como se observa en la Tabla 5.3, el modelo ResNet50 + LSTM obtuvo mejores resultados en las tres métricas consideradas. La diferencia en Accuracy fue de 13,33 puntos porcentuales, mientras que en F1-Score (Weighted) alcanzó una ventaja de 17,00 puntos porcentuales.

Matrices de confusión de los modelos

Las matrices de confusión permiten analizar detalladamente el comportamiento de clasificación de los modelos desarrollados para identificar tres patrones de motricidad asociados al trastorno del espectro autista (TEA): aleteo de manos, movimientos repetitivos de cabeza y balanceo corporal. Estas matrices muestran la relación entre las clases reales y las clases predichas por cada modelo, lo que permite identificar tanto las clasificaciones correctas como los errores cometidos durante la evaluación.

En este análisis, los valores ubicados en la diagonal principal representan las muestras clasificadas correctamente, mientras que los valores situados fuera de ella indican las confusiones entre las distintas clases. Para ambos modelos se utilizó un conjunto de prueba compuesto por 15 muestras, distribuidas en cinco muestras por cada patrón de movimiento.

Matriz de confusión del modelo CNN

En la Figura 5.1 se presenta la matriz de confusión del modelo CNN, que permite observar las predicciones correctas e incorrectas para cada patrón de movimiento.

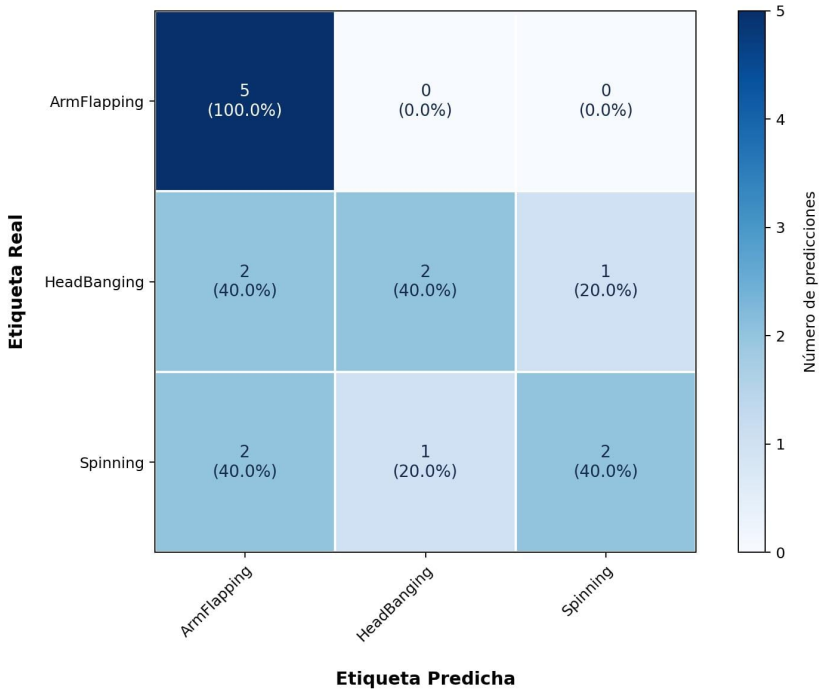


Figura 5.1: Matriz de confusión del modelo CNN.

En la matriz de confusión del modelo CNN se observa que la clase con mejor resultado es aleteo de manos, con cinco predicciones correctas de un total de cinco muestras, lo que representa una sensibilidad del 100 %. El modelo logró identificar correctamente todas las muestras correspondientes a este patrón.

Para la clase movimientos repetitivos de cabeza, el modelo clasificó correctamente dos de las cinco muestras, alcanzando una sensibilidad del 40 %. De las tres muestras restantes, dos fueron clasificadas como aleteo de manos y una como balanceo corporal.

En cuanto a la clase balanceo corporal, se identificaron correctamente dos de las cinco muestras, lo que también corresponde a una sensibilidad del 40 %. Las tres muestras restantes fueron clasificadas incorrectamente: dos como aleteo de manos y una como movimientos repetitivos de cabeza.

En conjunto, el modelo CNN obtuvo nueve clasificaciones correctas de las 15 muestras evaluadas, alcanzando una exactitud global del 60,00 %. Aunque logró reconocer adecuadamente todas las muestras de aleteo de manos, presentó dificultades para diferenciar los movimientos repetitivos de cabeza y el balanceo corporal.

Matriz de confusión del modelo ResNet50 + LSTM

En la Figura 5.2 se presenta la matriz de confusión correspondiente al modelo ResNet50 + LSTM.

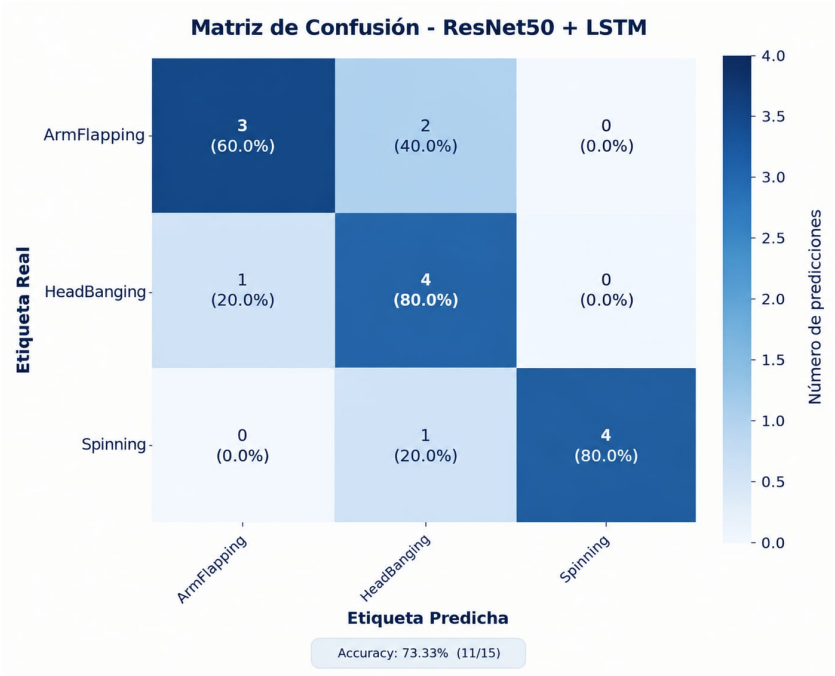


Figura 5.2: Matriz de confusión del modelo ResNet50 + LSTM.

En la matriz de confusión del modelo ResNet50 + LSTM se observa una mejora en la clasificación global respecto al modelo CNN. Las clases movimientos repetitivos de cabeza y balanceo corporal alcanzaron cuatro predicciones correctas de un total de cinco muestras, lo que representa una sensibilidad del 80,00 % para cada clase.

En la clase aleteo de manos, el modelo clasificó correctamente tres de las cinco muestras, alcanzando una sensibilidad del 60,00 %. Las dos muestras restantes fueron clasificadas incorrectamente como movimientos repetitivos de cabeza.

Para la clase movimientos repetitivos de cabeza, se obtuvieron cuatro clasificaciones correctas de las cinco muestras evaluadas, equivalentes a una sensibilidad del 80,00 %. La muestra restante fue clasificada como aleteo de manos.

Por su parte, la clase balanceo corporal también alcanzó cuatro predicciones correctas de cinco muestras, correspondientes al 80,00 % de sensibilidad. La única clasificación incorrecta fue identificada como movimientos repetitivos de cabeza.

En términos generales, el modelo ResNet50 + LSTM obtuvo 11 clasificaciones correctas de un total de 15 muestras, alcanzando una exactitud global del 73,33 %. Este resultado representa una mejora de 13,33 puntos porcentuales respecto al 60,00 % obtenido por CNN.

Comparación de las matrices de confusión

Al comparar las matrices de confusión de ambos modelos, se observa que ResNet50 + LSTM presentó un mejor desempeño global que CNN. Mientras que CNN clasificó correctamente nueve de las 15 muestras, ResNet50 + LSTM logró 11 aciertos.

La principal diferencia se encuentra en el reconocimiento de los movimientos repetitivos de cabeza y el balanceo corporal. En ambas clases, CNN alcanzó una sensibilidad del 40,00 %, mientras que ResNet50 + LSTM obtuvo un 80,00 %.

En el caso del aleteo de manos, CNN alcanzó una sensibilidad del 100,00 %, mientras que ResNet50 + LSTM obtuvo un 60,00 %. Por lo tanto, CNN presentó un mejor resultado en esta clase específica, aunque su desempeño fue inferior en las otras dos categorías.

En conclusión, ResNet50 + LSTM logró un mejor equilibrio en la clasificación de los tres patrones de motricidad, alcanzando una exactitud del 73,33 %, frente al 60,00 % obtenido por CNN. Sin embargo, debido al reducido tamaño del conjunto de prueba, estos resultados deben considerarse una evaluación experimental inicial.

5.2. Resultados de las pruebas del sistema web.

Capítulo 6

Discusión

El presente capítulo se centra en la discusión de los resultados obtenidos hasta el momento, abordando los logros alcanzados en el desarrollo del modelo de reconocimiento de patrones de motricidad y del prototipo de la aplicación web. Posteriormente, se presenta la solución al problema de investigación y se proponen sugerencias para futuras investigaciones. Dado que las pruebas funcionales del sistema y la evaluación con un profesional del área aún no se han realizado, los logros que se describen corresponden al desarrollo del modelo, a su evaluación experimental inicial y a la construcción del prototipo.

6.1. Logros alcanzados

En consecuencia al cumplimiento de los objetivos planteados en el primer capítulo, se han alcanzado los siguientes logros, que representan la materialización de la propuesta hasta esta etapa del trabajo:

- Se construyó un conjunto de datos de videos de conductas motoras estereotipadas a partir del conjunto público SSBD, compuesto inicialmente por 57 videos y 2 280 fotogramas distribuidos en tres clases (aleteo de manos, movimientos repetitivos de cabeza y balanceo corporal, denominado *Spinning* en el conjunto de datos). La extracción de 40 fotogramas por ventana de conducta anotada y la división por video en entrenamiento, validación y prueba permitieron disponer de datos organizados, sin mezcla de fotogramas de un mismo video entre conjuntos.
- Se diseñó e implementó un flujo de preprocesamiento configurable, que incluye la mejora de contraste, el recorte centrado en el sujeto, la redimensión, la normalización y el aumento de datos por reflexión. Al

concentrar todos los parámetros en un único archivo de configuración, se logró que los experimentos sean reproducibles y que la aplicación web pueda aplicar exactamente las mismas transformaciones que el entrenamiento.

- Se desarrollaron y compararon dos arquitecturas híbridas convolucional-recurrentes: una red CNN-LSTM propia, entrenada desde cero y de 73 027 parámetros, y un modelo ResNet50 + LSTM, que aprovecha una red preentrenada y congelada como extractor de características y entrena únicamente 143 651 parámetros. Esta comparación permitió seleccionar la arquitectura más adecuada para el prototipo con base en evidencia experimental.

- Se obtuvo un desempeño superior con ResNet50 + LSTM, que alcanzó una exactitud del 73,33 % en el conjunto de prueba, frente al 60,00 % de la CNN propia, y un F1-Score ponderado del 74,00 % frente al 57,00 %. Ambos valores superan ampliamente el azar para tres clases (33,33 %), lo que indica que los modelos aprendieron rasgos útiles para distinguir los patrones, aunque todavía no alcanzan el umbral planteado inicialmente en la hipótesis.

- Se implementó un protocolo de evaluación que va más allá de una única partición: estudio de la variabilidad entre semillas aleatorias, validación cruzada estratificada de cinco pliegues sobre los 57 videos, reportes de clasificación por clase, matrices de confusión e intervalos de confianza de Wilson. Con ello se identificaron las limitaciones del tamaño muestral y se evitó basar las conclusiones en un único resultado favorable.

- Se comprobó el correcto funcionamiento de la canalización de entrenamiento y evaluación mediante una prueba complementaria con un conjunto de datos externo (UCF101), donde ResNet50 + LSTM alcanzó una exactitud del 94 %. Aunque este resultado no puede trasladarse directamente al problema del TEA, respalda que el procedimiento aprende adecuadamente cuando se dispone de mayor cantidad de datos y señala el tamaño del conjunto como principal limitante.

- Se verificó el código de los componentes del modelo mediante pruebas automáticas unitarias del extractor CNN y del clasificador LSTM, que comprueban las dimensiones de entrada y salida, la ausencia de valores no válidos y la consistencia de los pesos compartidos.

- Se desarrolló un prototipo de la aplicación web con una interfaz clara y orientada a usuarios no técnicos. El flujo se organiza en tres pasos: la

carga de un video (con formatos MP4, MOV, AVI y WEBM, y la opción de probar con un video de ejemplo), el procesamiento y la presentación de un resultado preliminar. Este último muestra el movimiento más frecuente identificado, su nivel de confianza, una descripción del patrón y el tiempo y los momentos del video en que aparece. La aplicación cuenta además con secciones de inicio, historial de análisis e información.

- Se incorporaron en el prototipo mensajes explícitos que aclaran que el resultado es orientativo y preliminar, que no constituye un diagnóstico y que debe conversarse con un profesional de la salud. De este modo, el diseño respeta el alcance del trabajo, que busca apoyar la identificación preliminar de patrones de motricidad y no reemplazar la evaluación clínica.

En conjunto, estos logros constituyen la base técnica del sistema: los datos, los modelos, el procedimiento de evaluación y un prototipo funcional de interfaz. No obstante, deben interpretarse como resultados experimentales iniciales, ya que el conjunto de prueba es reducido (15 videos) y la validación del sistema integrado, tanto funcional como con un profesional del área, queda pendiente de realizarse.

6.2. Solución del problema de investigación

Se desarrolló un prototipo de aplicación web que, mediante un modelo híbrido ResNet50 + LSTM, analiza un video y devuelve el patrón de motricidad más frecuente, su nivel de confianza y los momentos en que aparece. Este desarrollo constituye un primer paso hacia una solución tecnológica al problema planteado: la dificultad de contar con herramientas accesibles que ayuden a identificar de forma preliminar conductas motoras repetitivas asociadas al TEA y a orientar la consulta con un profesional. El sistema se concibe como una herramienta de apoyo y no como un sustituto de la evaluación clínica.

6.2.1. Análisis de las métricas de los modelos

La comparación entre ambas arquitecturas muestra una ventaja clara de ResNet50 + LSTM: 13,33 puntos porcentuales más de exactitud y 17,00 puntos más de F1-Score ponderado que la CNN propia. Esta diferencia es coherente con el hecho de que, con apenas 33 videos de entrenamiento, una red preentrenada en millones de imágenes parte con características visuales

generales ya aprendidas, mientras que una red entrenada desde cero debe aprenderlas con muy pocos ejemplos.

El análisis por clase de ResNet50 + LSTM indica un buen equilibrio en el balanceo corporal (F1-Score de 0,89), mientras que el aleteo de manos y los movimientos repetitivos de cabeza obtuvieron 0,67 cada uno. Las matrices de confusión muestran que los errores se concentran entre aleteo de manos y movimientos de cabeza, conductas en las que gran parte del movimiento ocurre en la parte superior del cuerpo y puede resultar visualmente similar en resolución reducida. Por su parte, la CNN propia reconoció todas las muestras de aleteo de manos, pero confundió con frecuencia las otras dos clases, lo que muestra un modelo menos equilibrado.

Estos resultados deben leerse con cautela: provienen de un conjunto de prueba de 15 videos y, en parte, de la selección de semillas observando dicho conjunto, lo que introduce un sesgo optimista. Por esa razón, la validación cruzada es el criterio principal para contrastar la hipótesis una vez aprobado el umbral definitivo.

6.2.2. Limitaciones del trabajo

Las principales limitaciones identificadas son las siguientes:

- El conjunto de datos es reducido (57 videos) y proviene de una única fuente pública, lo que limita la diversidad de entornos, edades, encuadres e iluminación.
- La resolución de 64×64 píxeles, elegida por restricciones de memoria, puede eliminar detalles finos del movimiento, como la posición de las manos.
- El conjunto de prueba es pequeño, por lo que los intervalos de confianza son amplios.
- Las pruebas funcionales del sistema integrado y la valoración por un profesional del área aún no se han realizado, por lo que la utilidad práctica del prototipo no está validada.
- El sistema no distingue la ausencia de conductas: ante un video sin movimientos repetitivos, el modelo siempre asignará alguna de las tres clases.

6.3. Sugerencias para futuras investigaciones

A partir de los resultados y de las limitaciones identificadas, se proponen las siguientes líneas de trabajo:

- **Explorar el ajuste fino y otras arquitecturas.** Reentrenar parcialmente las capas finales de ResNet50 y evaluar otras redes consideradas en este trabajo, como MobileNetV2 o Vision Transformer, así como modelos basados en la estimación de la postura corporal, que podrían captar mejor el movimiento de manos y cabeza.
- **Aumentar la resolución y mejorar la detección del sujeto.** Evaluar tamaños de imagen mayores y un seguimiento más robusto del niño cuando hay varias personas u objetos en escena.
- **Detectar los segmentos temporales con mayor precisión.** Clasificar el video por ventanas deslizantes para indicar con exactitud en qué momentos aparece cada patrón.
- **Ampliar el repertorio de conductas.** Incluir otras conductas motoras repetitivas descritas en la literatura, además de las tres evaluadas.
- **Mejorar la interpretabilidad.** Mostrar qué regiones del video influyeron en la predicción para que el profesional pueda comprender y contrastar el resultado.
- **Desarrollar una aplicación móvil.** Ofrecer las mismas funcionalidades desde el teléfono, de modo que las familias puedan grabar y analizar un video con mayor facilidad.

Referencias bibliográficas

[1] Ministerio de Salud Pública y Bienestar Social, "Protocolo para la atención del trastorno del espectro autista en paraguay," 2023, [En línea]. Disponible: https://www.mspbs.gov.py/dependencias/progsalud/adjunto/54eaa6-protocoloTEA.pdf.

[2] Organización Mundial de la Salud, "Trastornos del espectro autista," Hoja informativa, 2024, [En línea]. Disponible: https://www.who.int/es/news-room/fact-sheets/detail/autism-spectrum-disorders.

[3] Instituto de Previsión Social, "Datos sobre el trastorno del espectro autista en paraguay," 2024, [En línea]. Disponible: https://portal.ips.gov.py/sistemas/ipsportal/noticia.php?cod=2999.

[4] Congreso de la Nación Paraguaya, "Ley nº 6103 que crea el programa nacional de atención integral a los trastornos del espectro autista (PNAITEA)," Asunción, Paraguay, 2018.

[5] Diario Hoy, "Autismo: Desafíos pendientes en diagnóstico, educación e inclusión laboral," [En línea], 2025, [En línea]. Disponible: https://www.hoy.com.py/nacionales/2025/04/06/autismo-desafios-pendientes-en-diagnostico-educacion-e-inclusion-laboral.

[6] Poder Ejecutivo de la República del Paraguay, "Decreto nº 3624 por el cual se reglamenta la ley nº 6103/2018," Asunción, Paraguay, 2020.

[7] S. Russell y P. Norvig, *Artificial Intelligence: A Modern Approach*, 4th ed. Upper Saddle River, NJ: Pearson, 2020.

[8] T. M. Mitchell, *Machine Learning*. New York, NY: McGraw-Hill, 1997.

[9] I. Goodfellow, Y. Bengio, y A. Courville, *Deep Learning*. Cambridge, MA: MIT Press, 2016.

[10] Z. Sherkatghanad *et al.*, "Automated detection of autism spectrum disorder using a convolutional neural network," *Frontiers in Neurology*, vol. 10, p. 1325, 2020, [En línea]. Disponible: https://pmc.ncbi.nlm.nih.gov/articles/PMC6971220/.

[11] C. M. Bishop, *Pattern Recognition and Machine Learning*. New York, NY: Springer, 2006.

[12] I. Goodfellow, Y. Bengio, y A. Courville, *Deep Learning*. MIT Press, 2016.

[13] K. P. Murphy, *Machine Learning: A Probabilistic Perspective*. MIT Press, 2012.

[14] World Health Organization, "Use of artificial intelligence in health care," 2021.

[15] Diversos estudios, "Machine learning aplicado a diagnóstico médico y detección de TEA mediante análisis de video y comportamiento," 2021, referencia genérica.

[16] R. Szeliski, *Computer Vision: Algorithms and Applications*, 2nd ed. Cham, Suiza: Springer, 2022.

[17] D. A. Forsyth y J. Ponce, *Computer Vision: A Modern Approach*, 2nd ed. Upper Saddle River, NJ: Pearson, 2011.

[18] A. Voulodimos, N. Doulamis, A. Doulamis, y E. Protopapadakis, "Deep learning for computer vision: A brief review," *Computational Intelligence and Neuroscience*, vol. 2018, p. 7068349, 2018.

[19] IBM, "What is computer vision?" 2023, [En línea]. Disponible: https://www.ibm.com/topics/computer-vision.

[20] C. I. Orozco, M. E. Buemi, y J. J. Berlles, "CNN-LSTM con mecanismo de atención para el reconocimiento de acciones en video," *Revista Elektron*, vol. 5, no. 1, pp. 37–44, 2021.

[21] G. P. Martinsanz, P. J. H. Caro, y E. B. Porlas, *Aprendizaje profundo*. México: Alfaomega, 2018.

[22] J. Patterson y A. Gibson, *Aprendizaje profundo: fundamentos y aplicaciones*. O'Reilly / Ediciones Paraninfo, 2024.

[23] C. Bishop, *Reconocimiento de patrones y aprendizaje automático.* Springer, 2006.

[24] ISO/IEC, "Systems and software engineering — systems and software quality requirements and evaluation (SQuaRE) — system and software quality models," 2011, iSO/IEC 25010:2011.

[25] L. Bass, P. Clements, y R. Kazman, *Software Architecture in Practice*, 3rd ed. Addison-Wesley Professional, 2012.

[26] World Health Organization, "Ethics and governance of artificial intelligence for health," Ginebra, 2021.

[27] C. Ware, *Information Visualization: Perception for Design*, 3rd ed. Morgan Kaufmann, 2013.

[28] G. I. M. Pintle, "Patrones gestuales para la detección de autismo en niños," Master's thesis, Centro de Investigación Científica y de Educación Superior de Ensenada, Ensenada, Baja California, México, 2018, [En línea]. Disponible en: https://cicese.repositorioinstitucional.mx/jspui/bitstream/1007/2441/1/tesis_Monarca%20Pintle_Gloria%20Ivonne_05_sep_2018B.pdf.

[29] X. Li, L. Fan, H. Wu, K. Chen, X. Yu, C. Che, Z. Cai, X. Niu, A. Cao, y X. Ma, "Enhancing autism spectrum disorder early detection with the parent-child dyads block-play protocol and an attention-enhanced gcn-xlstm hybrid deep learning framework," 2024, [En línea]. Disponible en: https://arxiv.org/abs/2408.16924.

[30] Universitat Politècnica de València, "Nuevo sistema de detección temprana del autismo," Apr. 2025, [En línea]. Disponible en: https://aplicat.upv.es/exploraupv/ficha-prensa/noticia/15133.

[31] NVIDIA Corporation, "GeForce RTX 4070 Family," 2023, [En línea]. Disponible: https://www.nvidia.com/en-us/geforce/graphics-cards/40-series/rtx-4070/. [Accedido: 24-sep-2026].

[32] Advanced Micro Devices, Inc., "AMD Ryzen 7 7800X3D," 2023, [En línea]. Disponible: https://www.amd.com/en/products/processors/desktops/ryzen/7000-series/amd-ryzen-7-7800x3d.html. [Accedido: 24-sep-2026].

[33] K. He, X. Zhang, S. Ren, y J. Sun, "Deep residual learning for image recognition," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, Las Vegas, NV, EE.UU., 2016, pp. 770–778.

[34] A. Dosovitskiy *et al.*, "An image is worth 16x16 words: Transformers for image recognition at scale," arXiv:2010.11929, 2020.

[35] E. Bisong, "Google Colaboratory," in *Building Machine Learning and Deep Learning Models on Google Cloud Platform.* Berkeley, CA, EE.UU.: Apress, 2019, pp. 59–64.

[36] G. Jocher, A. Chaurasia, y J. Qiu, "Ultralytics YOLOv8," Ultralytics, 2023, [En línea]. Disponible: https://github.com/ultralytics/ultralytics. [Accedido: 24-sep-2026].

[37] C. Arberas y V. Ruggieri, "Autismo. aspectos genéticos y biológicos," *Medicina*, vol. 79, no. Supl. 1, pp. 16–21, 2019.

[38] Naciones Unidas, "Transformar nuestro mundo: la agenda 2030 para el desarrollo sostenible," 2015, [En línea]. Disponible: https://sdgs.un.org/goals.

[39] A. Vaswani *et al.*, "Attention is all you need," arXiv, 2024, [En línea]. Disponible: https://arxiv.org/html/2408.16924v1.

[40] NVIDIA Corporation, "Geforce rtx 4070 family," [En línea], 2023, [Accedido: 24-sep-2026]. [Online]. Available: https://www.nvidia.com/en-us/geforce/graphics-cards/40-series/rtx-4070/

[41] Advanced Micro Devices, Inc., "Amd ryzen 7 7800x3d," [En línea], 2023, [Accedido: 24-sep-2026]. [Online]. Available: https://www.amd.com/en/products/processors/desktops/ryzen/7000-series/amd-ryzen-7-7800x3d.html

[42] K. He, X. Zhang, S. Ren, y J. Sun, "Deep residual learning for image recognition," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Las Vegas, NV, EE.UU., 2016, pp. 770–778.

[43] A. Dosovitskiy *et al.*, "An image is worth 16x16 words: Transformers for image recognition at scale," *arXiv preprint arXiv:2010.11929*, 2020.

[44] E. Bisong, "Google colaboratory," in *Building Machine Learning and Deep Learning Models on Google Cloud Platform.* Berkeley, CA, EE.UU.: Apress, 2019, pp. 59–64.

[45] G. Jocher, A. Chaurasia, y J. Qiu, "Ultralytics yolov8," [En línea], 2023, [Accedido: 24-sep-2026]. [Online]. Available: https://github.com/ultralytics/ultralytics

[46] S. S. Rajagopalan, A. Dhall, y R. Goecke, “Self-stimulatory behaviours in the wild for autism diagnosis,” in *Proc. IEEE Int. Conf. Comput. Vis. Workshops (ICCVW)*, Sydney, Australia, 2013, pp. 755–761.